中国科学: 数学 2025 年 第 55 卷 第 2 期: 361 ~ 384
SCIENTIA SINICA Mathematica
论 文

求解含非离散分布的分布鲁棒多阶段线性随机规划的 Benders 分解 - 动态逼近方法

献给韩继业教授 90 寿辰

俞昊东[1], 廖立志[2], 孙捷[3,4*]

1. 上海立信会计金融学院统计与数学学院, 上海 201209;
2. 香港浸会大学数学系, 香港;
3. School of Electrical Engineering, Computing and Mathematical Sciences, Curtin University, Bentley 6102, Australia;
4. School of Business, National University of Singapore, Singapore 119245, Singapore
E-mail: nianchuixiao@msn.com, liliao@hkbu.edu.hk, Jie.Sun@curtin.edu.au

收稿日期: 2024-05-28; 接受日期: 2024-11-30; 网络出版日期: 2025-01-14; * 通信作者
香港研究基金 (GRF) (批准号: HKBU12302019 和 HKBU12300920) 资助项目

摘要 本文对包含非离散分布的一类分布鲁棒多阶段随机线性规划问题提出了一种基于 Benders 分解的动态逼近方法. 在随机因素按阶段独立、分布模糊集由矩约束给出等条件下, 利用 Benders 分解构建了各阶段决策函数的近似函数, 从而将多阶段决策问题近似分解为一系列具有锥约束形式的凸优化子问题. 为分析算法的收敛性, 本文构建了一个新的基于变分分析的收敛性分析框架, 并证明了算法构建的近似问题对原问题具有上图收敛性. 最后通过数值试验展示了算法的有效性.

关键词 分布鲁棒 多阶段随机规划 Benders 分解 近似动态规划

MSC (2020) 主题分类 90C15, 90C25

1 引言

多阶段随机规划问题的基本结构是, 决策者在每一个决策阶段 t $(t = 1,\dots,T)$ 开始时观察到随机信息向量 $\xi_t \in \mathbb{R}^{m_t}$ 的取值, 而后根据到该时刻为止的历史信息决定决策变量 $x_t \in \mathbb{R}^{n_t}$ 的取值, 其目的是使得某个总体目标函数得到最优化. 为表述方便, 记 $\xi = (\xi_1^\top,\dots,\xi_T^\top)^\top \in \Xi \subset \mathbb{R}^m$, 其中 $m = m_1 + \cdots + m_T$, 决策变量 $x(\xi) = (x_1(\xi_1)^\top, x_2(\xi_1,\xi_2)^\top,\dots, x_T(\xi_1,\dots,\xi_T)^\top)^\top \in \mathbb{R}^n$, 其中 $n = n_1 + \cdots + n_T$. "$\top$" 是转置记号, $\Xi = \Xi_1 \times \Xi_2 \times \cdots \times \Xi_T$ 表示 ξ 的支撑集合. 根据解的非预期性 (nonanticipativity) 原则, x_t 的确定只能取决于已观察到的 $\xi_1,\dots,\xi_t$ 的值, 而不能依赖于尚未观察到的 $\xi_{t+1},\dots,\xi_T$ 的取值, 因此可以将 x_t 写作 $x_t(\xi_1,\dots,\xi_t)$. 同时应注意到, 第一阶段的信息 ξ_1 实际上是确定的. 为简化记号, 以下将 $(\xi_1^\top,\dots,\xi_t^\top)^\top$ 记作 $\xi_{[t]}$, 并将 $(x_1^\top,\dots,x_t^\top)^\top$ 记作 $x_{[t]}$.

英文引用格式: Yu H D, Liao L-Z, Sun J. A Benders decomposition approximate dynamic method for distributionally robust multistage linear stochastic programming with nondiscrete distributions (in Chinese). Sci Sin Math, 2025, 55: 361–384, doi: 10.1360/SSM-2024-0177

© 2025《中国科学》杂志社 www.scichina.com mathcn.scichina.com

中国知网 https://www.cnki.net

考虑以下多阶段线性随机规划问题:

$$\min_{x_1\in C_1} c_1^\top x_1+\mathbb{E}\Big[\min_{x_2\in C_2(x_1,\xi_{[2]})} c_2^\top x_2+\mathbb{E}\Big[\cdots+\mathbb{E}\Big[\min_{x_T\in C_T(x_{T-1},\xi_{[T]})} c_T^\top x_T\Big]\Big]\Big], \tag{1.1}$$

其中 $\mathbb{E}$ 表示数学期望, $C_1,\ldots,C_T(x_{T-1},\xi_{[T]})$ 是由 $x_{[T-1]}$ 和 $\xi_{[T]}$ 确定的多面体集合, 其定义如下:

$$\begin{aligned}
&C_1=\{x_1\in\mathbb{R}^{n_1}: A_1x_1=b_1, x_1\geqslant 0\},\\
&C_2(x_1,\xi_{[2]})=\{x_2\in\mathbb{R}^{n_2}: B_2(\xi_{[2]})x_1+A_2x_2=b_2(\xi_{[2]}), x_2\geqslant 0\},\\
&\quad\vdots\\
&C_T(x_{T-1},\xi_{[T]})=\{x_T\in\mathbb{R}^{n_T}: B_T(\xi_{[T]})x_{T-1}+A_Tx_T=b_T(\xi_{[T]}), x_T\geqslant 0\}.
\end{aligned} \tag{1.2}$$

传统的随机规划模型假设 ξ 的分布是已知的. 但在实践中, 这往往是不现实的. 很多时候, 我们只能获取关于分布的部分信息. 这种情况刺激了分布鲁棒随机规划 (distributionally robust stochastic programming, DRSP) 的发展. 在模型 (1.1) 中, 期望算子 $\mathbb{E}$ 被替换成以下最坏情形的期望:

$$\mathbb{E}_P[F(x,\xi)]\longrightarrow\sup_{P\in\mathcal{P}}\mathbb{E}_P[F(x,\xi)], \tag{1.3}$$

其中 $\mathcal{P}$ 是一个由概率测度组成的集合, 称为模糊集. 分布鲁棒模型的重要性使得它在近年来被广泛的研究. 首先被研究的是静态的分布鲁棒模型, 即 $T=1$ 时的情形. 关于此问题, 可以参考 Delage 和 Ye [9]、Bertsimas 等 [4]、Wiesemann 等 [43]、Xu 等 [44] 等诸多学者的工作, 包括我们的研究, 参见文献 [46] 等.

进一步地, 二阶段 DRSP 问题, 即 $T=2$ 时的情形也已吸引了很多研究. 例如, 文献 [2, 13] 讨论了带矩约束的二阶段 DRSP 问题, 文献 [21, 24, 25, 38, 39] 等讨论了风险度量是 CVaR_α (conditional value at risk, 下标 α 是置信水平) 等非数学期望时的二阶段线性 - 二次 DRSP 模型. 关于分布的模糊集方面, 文献 [18] 研究了基于 L_1 范数的模糊集以及相应的风险厌恶型二阶段随机规划; 文献 [16] 考虑了模糊集由 Wasserstein 距离定义的情形. 此外, 文献 [8] 等考虑了原始 - 对偶混合梯度 (primal-dual hybrid gradient, PDHG) 方法在二阶段模型中的应用, 该方法具有不依赖于特定的模糊集结构的特点.

与二阶段问题的研究现状相比, 多阶段 DRSP 问题 (即 $T\geqslant 3$) 的研究文献仍然十分有限. 较早的工作有文献 [1, 27], 其研究主要基于情景树之间的嵌套距离 (nested distance, 关于其定义及性质可参见文献 [28]). 还有文献 [45] 关于分布鲁棒 Markov 决策过程的研究、文献 [23] 关于鲁棒多阶段组合投资问题的研究和文献 [20, 22] 的研究等.

近期的一些研究开始关注嵌套 Benders 分解以及随机对偶动态规划 (stochastic dual dynamic programming, SDDP) 方法在多阶段 DRSP 问题中的应用. Benders 分解算法是一种在传统的多阶段随机规划中被广泛使用的技术, 其作用主要是针对离散的风险结构中的每一个节点, 基于切平面方法构建该节点的决策成本函数 (cost-to-go function) 的下方逼近. 在此基础上, Pereira 和 Pinto [26] 通过进一步引入一个统计上界, 发展出了著名的 SDDP 方法. 关于 Benders 分解和 SDDP 方法在随机规划中应用的细节, 可参见文献 [33, 35] 等专著.

对于分布鲁棒问题, 文献 [47] 对具有情景树结构的多阶段 - 分布鲁棒随机线性规划问题提出了一类 Benders 分解算法. 而对于 SDDP 方法, 文献 [10, 29] 分别对基于 Wasserstein 距离和 χ^2 距离的多阶段 - 分布鲁棒问题提出了分布鲁棒 SDDP 方法. 这几种方法的共同点是引入了一个嵌套的 min-max

中国知网 https://www.cnki.net

结构, 也就是对情景树的每个节点都引入了分布鲁棒性. 对此, 文献 [47] 中曾指出, 这种结构符合动态随机决策的时间一致性 (time consistency) 原则.

由于决策的动态性, 多阶段随机决策模型通常要求随机风险具有离散结构, 如情景树或离散的 Markov 链, 由于它们的状态空间是有限的, 因而可以对每一个情景下的决策予以描述. 这一特征严重限制了分布鲁棒模型在多阶段问题中的应用. 同时, Benders 分解算法在传统的动态规划问题中也很少使用.

本文的主要工作是考虑多阶段分布鲁棒问题中包含非离散型分布的情形. 在此情形下, 由于可能有无穷多个路径或情景, 像处理离散模型那样对每一个路径或情景分别描述最优策略的方式是不现实的. 一种可行的方式是采用动态规划的视角, 将每一个阶段的决策函数视为决策变量的函数, 并设法对其构建逼近函数, 从而实现各决策阶段的分解, 此即所谓近似动态规划 (approximate dynamic programming, ADP) 方法, 关于此方法的详细介绍可参见 Powell 的专著 [30]. 在传统的近似动态规划问题中, 决策函数 Benders 分解算法使用很少. 本文的主要贡献之一是将我们在文献 [47] 中对情景树模型使用的嵌套 Benders 分解算法与近似动态规划方法相结合, 从而可以在包含非离散分布的情形下实现多阶段分布鲁棒问题的动态分解并完成求解.

具体而言, 本文考虑以下形式的线性多阶段分布鲁棒问题:

$$\min_{x_1\in C_1} c_1^\top x_1 + \sup_{P_2\in\mathbb{P}_2}\mathbb{E}_{P_2}\Big[\min_{x_2\in C_2(x_1,\xi_{[2]})} c_2^\top x_2 + \sup_{P_3\in\mathbb{P}_3}\mathbb{E}_{P_3}\Big[\cdots + \sup_{P_T\in\mathbb{P}_T}\mathbb{E}_{P_T}\Big[\min_{x_T\in C_T(x_{T-1},\xi_{[T]})} c_T^\top x_T\Big]\Big]\Big], \quad (1.4)$$

其中 $C_t(x_{t-1},\xi_{[t]})$ 的定义由 (1.2) 给出, $\mathbb{P}_t$, $t=2,\ldots,T$ 是由矩约束定义的模糊集, 具体形式将在下一节给出. 本文对模型采用以下假设:

假设 1.1 (1) 假设随机变量 $\xi_1,\ldots,\xi_T$ 是相互独立的 (即随机变量是按阶段独立的. 因此 P_t 是 ξ_t 的分布, 而不再是一个条件分布).

(2) 假设模型中的 c_t 是非随机向量. 同时假定约束 (1.2) 中的补偿 (recourse) 矩阵 A_t 也是确定的, 这样的补偿矩阵在随机规划中被称为是相对完全的 (relatively complete).

在近似动态规划的框架下, 一个重要的理论问题是如何分析各阶段的近似函数对决策成本函数的收敛性. 这是本文的第二个主要贡献, 我们建立了一个新的收敛性分析框架来解决这一问题. 该框架以参数优化和变分分析理论为基础, 由此我们证明了近似函数在上图收敛 (epi-converge) 的意义下收敛到相应的决策成本函数. 由证明过程可以看出, 这一分析框架可以应用于许多具有类似动态结构的模型和算法的理论分析, 因而是一个具有一般性的分析框架.

本文余下内容的安排如下. 第 2 节对算法的基本原理给出推导, 并对新算法给出具体描述. 第 3 节给出关于算法收敛性的理论分析. 第 4 节对算法实施过程中涉及的一些具体技术进行讨论, 随后通过一些数值试验来检验算法的有效性. 最后第 5 节给出本文的结论.

2 基于 Benders 分解的近似动态框架

如上节所述, 即使在随机变量的分布信息精确已知的情况下, 对于带非离散分布的多阶段随机规划问题的求解也是十分困难的. 本节对于更为困难的分布鲁棒问题 (1.4), 首先对各阶段决策成本函数 $\mathcal{Q}_t$ (参见 (2.2)–(2.4)) 的动态逼近框架给出推导, 随后给出算法的具体描述.

关于模糊集的选择, 文献中已有很多讨论, 本文采用以下由 Delarge 和 Ye [9] 提出的矩约束形式:

中国知网 https://www.cnki.net

$$\mathbb{P}_t(\Xi_t,\mu_t,\Sigma_t,\gamma_1,\gamma_2)=\left\{\int_{\mathbb{R}^{m_t}} dP_t=1, P_t\geqslant 0 \;\middle|\; \begin{array}{l}\displaystyle\int_{\Xi_t}\xi_t dP_t=1,\\ \mathbb{E}_{P_t}[(\xi_t-\mu_t)(\xi_t-\mu_t)^\top]\preceq\gamma_2\Sigma_t,\\ (\mathbb{E}_{P_t}[\xi_t]-\mu_t)^\top\Sigma_t^{-1}(\mathbb{E}_{P_t}[\xi_t]-\mu_t)\leqslant\gamma_1\end{array}\right\},\tag{2.1}$$

其中记号 $\succ 0$ 和 $\succeq 0$ 分别表示正定或半正定. 类似地, $\prec$ 和 $\preceq$ 分别表示负定或半负定. 如文献 [9] 所指出的, (2.1) 的矩约束形式具有明显的统计含义, 且能包含范围广泛的一大类概率分布. 从优化角度看, 包含该约束的优化问题本质上是一类带有锥约束的凸优化问题.

假设 2.1 在 (2.1) 中有 $\gamma_1>0$, $\gamma_2\geqslant 1$, 且对每个阶段 t 都有 $\Sigma_t\succ 0$. 此外, 假设 (1.2) 中的随机矩阵 B_t 和 b_t 仅依赖于 ξ_t, 即 $B_t(\xi_{[t]})=B_t(\xi_t)$, $b_t(\xi_{[t]})=b_t(\xi_t)$. 此时, 约束 $C_t(x_{t-1},\xi_{[t]})$ 可以被记为 $C_t(x_{t-1},\xi_t)$.

由以上假设易知, 由 (2.1) 定义的模糊集 $\mathbb{P}_t(\Xi_t,\mu_t,\Sigma_t,\gamma_1,\gamma_2)$ 是非空的, 因为它包含了单点测度 (或称作 Dirac 测度) δ_{μ_t} (即在点 μ_t 概率为 1、其余部分概率为 0 的测度). 实际上, δ_{μ_t} 是 $\mathbb{P}_t(\Xi_t,\mu_t,\Sigma_t,\gamma_1,\gamma_2)$ 的一个相对内点.

为表述方便, 将 $C_t(x_{t-1},\xi_t)$ 简记为 C_t. 根据假设 2.1 及随机变量按阶段独立的假设, 模型 (1.4) 可转化为以下动态规划形式:

$$Q_1=\min_{x_1}\{c_1^\top x_1+\mathcal{Q}_2(x_1): A_1x_1=b_1, x_1\geqslant 0\},\tag{2.2}$$

$$Q_t(x_{t-1},\xi_t)=\min_{x_t}\{c_t^\top x_t+\mathcal{Q}_{t+1}(x_t): B_t(\xi_t)x_{t-1}+A_tx_t=b_t(\xi_t), x_t\geqslant 0\},\quad t=2,\ldots,T,\tag{2.3}$$

以及 $Q_{T+1}(x_T,\xi_{T+1})\equiv 0$. 我们将由下式定义的函数 $\mathcal{Q}_{t+1}(\cdot)$ 称为决策成本函数 (cost-to-go functions):

$$\begin{aligned}\mathcal{Q}_{t+1}(x_t)&:=\sup_{P_{t+1}\in\mathbb{P}_{t+1}}\mathbb{E}_{P_{t+1}}[Q_{t+1}(x_t,\xi_{t+1})|\xi_{[t]}]\\ &=\sup_{P_{t+1}\in\mathbb{P}_{t+1}}\mathbb{E}_{P_{t+1}}[Q_{t+1}(x_t,\xi_{t+1})]\quad(t=1,\ldots,T-1).\end{aligned}\tag{2.4}$$

首先引用如下结果, 并证明 $\mathcal{Q}_t(\cdot)$ 等函数的凸性.

引理 2.1 [31] 设 X 和 U 是实线性空间, $F: X\times U\to[-\infty,+\infty]$ 是一个凸函数, 则以下最优值函数 $\varphi(\cdot)$ 也是凸的:

$$\varphi(u):=\inf_{x\in X}F(x,u),\quad u\in U.\tag{2.5}$$

引理 2.2 由 (2.3) 定义的函数 $Q_t(\cdot)$ 和 (2.4) 定义的函数 $\mathcal{Q}_t(\cdot)$ 都是凸函数.

证明 首先由定义可知, $\mathcal{Q}_{T+1}(\cdot)\equiv 0$, 显然是凸函数. 接下来采用与 Shapiro 等的专著 [36, 第 3.2.1 小节] 相同的归纳推理法可知, 若对某 $t<T$, $\mathcal{Q}_{t+1}(\cdot)$ 是一个凸函数, 则 $Q_t(\cdot,\xi_t)$ 是凸函数.

另外, 若已知 $Q_t(\cdot,\xi_t)$ 是凸函数, 则对任意的 $P_t\in\mathbb{P}_t$, $\mathbb{E}_{P_t}[Q_t(x_{t-1},\xi_t)]$ 显然是关于 x_{t-1} 的凸函数. 而 $\mathcal{Q}_t(\cdot)$ 对该函数取上确界, 因而也是凸函数.

由以上分析可知, 可以建立数学归纳法. 因此 $Q_t(\cdot)$ 和 $\mathcal{Q}_t(\cdot)$ 都是凸函数. □

现用 $\tilde{\mathcal{Q}}_{t+1}$ 表示函数 $\mathcal{Q}_{t+1}$ 的一个由切平面产生的分片线性逼近, 即令

$$\tilde{\mathcal{Q}}_{t+1}(x_t;l_1,\ldots,l_{K_t})=\max_{1\leqslant k\leqslant K_t}l_k(x_t):=\max_{1\leqslant k\leqslant K_t}\alpha_k^\top x_t+\beta_k\quad(t=1,\ldots,T-1),\tag{2.6}$$

中国知网 https://www.cnki.net

其中 $l_k(x_t)=\alpha_k^\top x_t+\beta_k$ $(k=1,\dots,K_t)$ 是 $\mathcal{Q}_{t+1}(\cdot)$ 在 x_t 的切平面, K_t 表示切平面数量, 用以对函数 $\mathcal{Q}_{t+1}(\cdot)$ 构建近似. 同时, 令 $\tilde{\mathcal{Q}}_{T+1}(x_T)\equiv 0$.

将 (2.2) 及 (2.3) 中的 $\mathcal{Q}_{t+1}$ 替换为 $\tilde{\mathcal{Q}}_{t+1}$, 即可得到

$$\hat{Q}_t(x_{t-1},\xi_t,;l_1,\dots,l_{K_t})=\min_{x_t}\{c_t^\top x_t+\tilde{\mathcal{Q}}_{t+1}(x_t;l_1,\dots,l_{K_t}):B_t(\xi_t)x_{t-1}+A_tx_t=b_t(\xi_t),x_t\geqslant 0\},\quad(2.7)$$

其中 $t=2,\dots,T$. 同时, 当 $t=1$ 时, 有

$$\hat{Q}_1^{l_1,\dots,l_{K_1}}=\min_{x_1}\{c_1^\top x_1+\tilde{\mathcal{Q}}_2(x_1;l_1,\dots,l_{K_1}):A_1x_1=b_1,x_1\geqslant 0\}.\quad(2.8)$$

注意到, 当 $t=T$ 时, 有 $\hat{Q}_T(x_{T-1},\xi_T)=Q_T(x_{T-1},\xi_T)$. 由 (2.7) 可得, 当 $t=2,\dots,T$ 时,

$$\begin{aligned}\hat{Q}_t(x_{t-1},\xi_t;l_1,\dots,l_{K_t})=\min_{x_t,h_t}\ & c_t^\top x_t+h_t\\ \text{s.t.}\ & B_t(\xi_t)x_{t-1}+A_tx_t=b_t(\xi_t),\quad x_t\geqslant 0,\\ & h_t\geqslant\alpha_k^\top x_t+\beta_k\quad(k=1,\dots,K_t).\end{aligned}\quad(2.9)$$

同理, 当 $t=1$ 时, 有

$$\begin{aligned}\hat{Q}_1^{l_1,\dots,l_{K_1}}=\min_{x_1,h_1}\ & c_1^\top x_1+h_1\\ \text{s.t.}\ & A_1x_1=b_1,\quad x_1\geqslant 0,\\ & h_1\geqslant\alpha_k^\top x_1+\beta_k\quad(k=1,\dots,K_1).\end{aligned}\quad(2.10)$$

特别地, 当 $t=T$ 时, 在 (2.9) 中有 $\alpha_k\equiv 0$, $\beta_k\equiv 0$ (对所有的 $k=1,\dots,K_t$). 为简化表达, 以下在不涉及切平面的具体参数取值时, 将 $\tilde{\mathcal{Q}}_{t+1}(x_t;l_1,\dots,l_{K_t})$ 和 $\hat{Q}_t(x_{t-1},\xi_t;l_1,\dots,l_{K_t})$ 分别简记为 $\tilde{\mathcal{Q}}_{t+1}(x_t)$ 和 $\hat{Q}_t(x_{t-1},\xi_t)$. 进一步地, 可以通过定义 $\hat{Q}_1(x_0,\xi_1)\equiv\hat{Q}_1$, 从而将 $\hat{Q}_1$ 统一到 $\hat{Q}_t(x_{t-1},\xi_t)$ 的形式中. 相应地, 通过定义 $B_1(\xi_1)=0$, 可以将 (2.10) 视为是 (2.9) 的一个特例.

定义

$$\hat{\mathcal{Q}}_t(x_{t-1}):=\sup_{P_t\in\mathbb{P}_t}\mathbb{E}_{P_t}[\hat{Q}_t(x_{t-1},\xi_t)]\quad(t=2,\dots,T),\quad(2.11)$$

并将其视作为是 $\mathcal{Q}_t(x_{t-1})$ 的一个逼近. 接下来说明, 在适当的正则化条件下, $\hat{\mathcal{Q}}_t(x_{t-1})$ 及其次梯度 $\partial\hat{\mathcal{Q}}_t(x_{t-1})$ 可以通过求解一个凸约束凸优化问题得到.

首先考虑 $\hat{\mathcal{Q}}_t(x_{t-1})$ 的计算. 由假设 2.1 及文献 [9, 引理 1] 可得, 对所有的 $t=2,\dots,T$, $\hat{\mathcal{Q}}_t(x_{t-1})$ 等于以下半定规划问题的最优解:

$$\begin{aligned}\min_{S,q,r,v}\ & r+v\\ \text{s.t.}\ & r+\xi_t^\top S\xi_t+\xi_t^\top q\geqslant\hat{Q}_t(x_{t-1},\xi_t),\quad\forall\,\xi_t\in\Xi_t,\\ & v\geqslant(\gamma_2\Sigma_t+\mu_t\mu_t^\top)\bullet S+\mu_t^\top q+\sqrt{\gamma_1}\|\Sigma_t^{1/2}(q+2S\mu_t)\|,\\ & S\succeq 0,\end{aligned}\quad(2.12)$$

其中 S 表示实对称矩阵, "$\bullet$" 表示矩阵的 Frobenius 内积. 注意到 (2.12) 中的第一个约束的涵义是以下问题的最优解是非负的:

$$\min_{\xi_t\in\Xi_t}\quad r+\xi_t^\top S\xi_t+\xi_t^\top q-\hat{Q}_t(x_{t-1},\xi_t)\geqslant 0.\quad(2.13)$$

中国知网 https://www.cnki.net

注意到 (2.9) 及 (2.10) 的对偶规划为

$$\begin{aligned}\hat{Q}_t(x_{t-1},\xi_t) = \max_{\eta,v_k} \ & \sum_k v_k\beta_k - \eta^\top(B_t(\xi_t)x_{t-1} - b_t(\xi_t)) \\ \text{s.t.} \ & \sum_k v_k = 1, \quad v_k \geqslant 0, \\ & A_t^\top\eta \leqslant c_t + \sum_k v_k\alpha_k \quad (k=1,\ldots,K_t).\end{aligned} \tag{2.14}$$

将以上对偶形式代入 (2.13), 可得以下问题的最优值是非负的:

$$\begin{aligned}\min_{\xi_t,\eta,v_k} \ & r + \xi_t^\top S\xi_t + \xi_t^\top q + \eta^\top(B_t(\xi_t)x_{t-1} - b_t(\xi_t)) - \sum_k v_k\beta_k \\ \text{s.t.} \ & \sum_k v_k = 1, \quad v_k \geqslant 0, \\ & A_t^\top\eta \leqslant c_t + \sum_k v_k\alpha_k \quad (k=1,\ldots,K_t).\end{aligned} \tag{2.15}$$

假设 2.2 假设随机矩阵 B_t 和 b_t 仿射依赖 (affinely dependent) 于 ξ_t, 即

$$B_t(\xi_t) = B_0^t + \sum_{j=1}^{m_t}\xi_t(j)B_j^t, \quad b_t = b_0^t + \sum_{j=1}^{m_t}\xi_t(j)b_j^t, \tag{2.16}$$

其中 $B_0^t, B_1^t, \ldots, B_{m_t}^t$ 为非随机矩阵, $b_0^t, b_1^t, \ldots, b_{m_t}^t$ 为非随机向量.

上述仿射依赖假设又被称为线性决策规则 (linear decision rule, LDR), 是鲁棒优化中经常使用的假设 (参见文献 [2] 及 Shapiro 的专著 [35, 第 5.3.1 小节]). 在该假设下, 容易验证 (2.15) 中的目标函数可以表达为以下形式:

$$(\xi_t^\top, 1)\begin{pmatrix} S & \begin{bmatrix} \frac{\eta^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix} + \frac{q}{2} \\ \frac{q^\top}{2} + \begin{bmatrix} \frac{\eta^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix}^\top & r + \eta^\top(B_0^t x_{t-1} - b_0^t) - \sum_k v_k\beta_k \end{pmatrix}(\xi_t^\top, 1)^\top. \tag{2.17}$$

为处理 ξ_t 可能为非连续变量的情况, 现在考虑最宽泛的情形, 即令 $\Xi_t = \mathbb{R}^{m_t}$. 此时, 原约束 $r+\xi_t^\top S\xi_t+\xi_t^\top q \geqslant \hat{Q}_t(x_{t-1},\xi_t)$ $(\forall\,\xi_t\in\Xi_t)$ 可等价地表达为: 集合 $\Theta_t = \{\eta, v_k\ (k=1,\ldots,K_t) \mid \sum_k v_k = 1, v_k \geqslant 0, A_t^\top\eta \leqslant c_t + \sum_k v_k\alpha_k\}$ 中的所有元素都满足

$$M_t(\eta, v_k; S, q, r) := \begin{pmatrix} S & \begin{bmatrix} \frac{\eta^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix} + \frac{q}{2} \\ \frac{q^\top}{2} + \begin{bmatrix} \frac{\eta^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix}^\top & r + \eta^\top(B_0^t x_{t-1} - b_0^t) - \sum_k v_k\beta_k \end{pmatrix} \succeq 0, \tag{2.18}$$

中国知网 https://www.cnki.net

即由集合 Θ_t 的元素 (η, v_k) 及 S, q 和 r 确定的矩阵 M_t 都是半正定的.

假设 2.3 对所有的阶段 $t=1,\ldots,T$, 集合 $\{\eta \mid A_t^\top \eta \leqslant c_t\}$ 都是有界的.

假设 2.3 的意义是使得集合 Θ_t 没有极方向. 假设 Θ_t 共有 L_t 个顶点 $(\eta_l, v_l^1, \ldots, v_l^{K_t})$, $l \in \{1, \ldots, L_t\}$. 注意到, $L_t = L_t(\alpha_1, \ldots, \alpha_{K_t})$, 即 L_t 依赖于 $\alpha_1, \ldots, \alpha_{K_t}$. 在算法迭代过程中, 顶点会随着切平面的增多而变化. 注意到, 对阶段 $t=T$, 由于 $\alpha_k = 0$ 和 $\beta_k = 0$, 因此有 $\Theta_T = \{\eta \mid A_T^\top \eta \leqslant c_T\}$ 且 $\sum_k v_k \beta_k \equiv 0$. 定义

$$M_t^l(S,q,r) := \begin{pmatrix} S & \begin{bmatrix} \frac{\eta_l^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta_l^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix} + \frac{q}{2} \\ \frac{q^\top}{2} + \begin{bmatrix} \frac{\eta_l^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta_l^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix}^\top & r + \eta_l^\top (B_0^t x_{t-1} - b_0^t) - \sum_k v_k^l \beta_k \end{pmatrix}, \tag{2.19}$$

$l = 1, \ldots, L_t(\alpha_1, \ldots, \alpha_{K_t})$.

令 $p = \frac{q}{2} + S\mu_t$, 并记

$$M_t^l(S,q,r) = \begin{pmatrix} S & p - S\mu_t \\ p^\top - \mu_t^\top S & r \end{pmatrix} + \bar{M}_t^l(x_{t-1}),$$

其中

$$\begin{aligned} \bar{M}_t^l(x_{t-1}) &= \begin{pmatrix} 0 & a_l(x_{t-1}) \\ a_l^\top(x_{t-1}) & r_l(x_{t-1}) \end{pmatrix} \\ &:= \begin{pmatrix} 0 & \begin{bmatrix} \frac{\eta_l^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta_l^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix} \\ \begin{bmatrix} \frac{\eta_l^\top}{2}(B_1^t x_{t-1} - b_1^t) \\ \vdots \\ \frac{\eta_l^\top}{2}(B_{m_t}^t x_{t-1} - b_{m_t}^t) \end{bmatrix}^\top & \eta_l^\top (B_0^t x_{t-1} - b_0^t) - \sum_k v_k^l \beta_k \end{pmatrix}. \end{aligned} \tag{2.20}$$

因此, $\hat{\mathcal{Q}}_t(x_{t-1})$ 等于以下问题的最优解:

$$\begin{aligned} \min_{S,q,r,v} \ & r + v \\ \text{s.t.} \ & M_t^l(S,q,r) \succeq 0, \quad l = 1, \ldots, L_t(\alpha_1, \ldots, \alpha_{K_t}), \\ & v \geqslant (\gamma_2 \Sigma_t + \mu_t \mu_t^\top) \bullet S + \mu_t^\top q + \sqrt{\gamma_1} \|\Sigma_t^{1/2}(q + 2S\mu_t)\|, \\ & S \succeq 0. \end{aligned} \tag{2.21}$$

也就是说, 我们可以通过求解 (2.21) 来得到 $\hat{\mathcal{Q}}_t(x_{t-1})$ 的值.

中国知网 https://www.cnki.net

进一步注意到, 问题 (2.21) 又等价于

$$\begin{aligned}
&\min_{S,p,P,r,s}\ (\gamma_2\Sigma_t-\mu_t\mu_t^\top)\bullet S+r+(\Sigma_t\bullet P)-2\mu_t^\top p+\gamma_1 s\\
&\text{s.t.}\quad \begin{pmatrix} S & p-S\mu_t\\ p^\top-\mu_t^\top S & r\end{pmatrix}+\bar{M}_t^l(x_{t-1})\succeq 0,\quad l=1,\dots,L_t(\alpha_1,\dots,\alpha_{K_t}),\\
&\qquad \begin{bmatrix} P & p\\ p^\top & s\end{bmatrix}\succeq 0,\quad S\succeq 0.
\end{aligned}\tag{2.22}$$

下面, 基于这一事实来给出 $\hat{\mathcal{Q}}_t(x_{t-1})$ 的次微分的一个计算公式, 这是进行 Benders 分解的基础. 为简化表达, 以下叙述中, 将 $L_t(\alpha_1,\dots,\alpha_{K_t})$ 简记为 L_t.

定理 2.1 若假设 2.1–2.3 成立, 则有

$$\partial\hat{\mathcal{Q}}_t(x_{t-1})=\frac{1}{2}\sum_l((B_1^t)^\top\eta_l,\dots,(B_{m_t}^t)^\top\eta_l)\pi_l+(B_0^t)^\top\sum_l\nu_l\eta_l,\tag{2.23}$$

其中 π_l 和 ν_l $(l=1,\dots,L_t)$ 是以下问题的最优解:

$$\begin{aligned}
&\max_{\pi_l,\nu_l}\ \sum_l\pi_l^\top a_l(x_{t-1})+\sum_l\nu_l r_l(x_{t-1})\\
&\text{s.t.}\ \ \pi_l,\nu_l\in\Pi,
\end{aligned}\tag{2.24}$$

且

$$\Pi=\left\{\pi_l,\ \nu_l\ (l=1,\dots,L_t)\ \middle|\ \begin{array}{l}
-\displaystyle\sum_{\{l:\nu_l<0\}}\frac{1}{4\nu_l}\pi_l\pi_l^\top+\mu_t\sum_l\pi_l^\top+\mu_t\mu_t^\top\preceq\gamma_2\Sigma_t,\\
\left(\mu_t+\dfrac{1}{2}\displaystyle\sum_l\pi_l\right)\left(\mu_t+\dfrac{1}{2}\sum_l\pi_l\right)^\top\preceq\gamma_1\Sigma_t,\\
\displaystyle\sum_l\nu_l=-1,\ \nu_l\leqslant 0,\\
(\nu_l=0,\ \text{若}\ \pi_l=0)
\end{array}\right\}.\tag{2.25}$$

证明 记 $a=(a_1^\top,\dots,a_{L_t}^\top)^\top$, $\tilde{r}=(r_1,\dots,r_{L_t})$, 其中 $a_l\in\mathbb{R}^{n_t}$, $r_l\in\mathbb{R}$ $(l=1,\dots,L_t)$. 并记 $\varphi(a,\tilde{r})$ 是以下问题的最优值 (以 a 和 $\tilde{r}$ 为参数):

$$\begin{aligned}
&\min_{S,p,P,r,s}\ (\gamma_2\Sigma_t-\mu_t\mu_t^\top)\bullet S+r+(\Sigma_t\bullet P)-2\mu_t^\top p+\gamma_1 s\\
&\text{s.t.}\quad \begin{pmatrix} S & p-S\mu_t\\ p^\top-\mu_t^\top S & r\end{pmatrix}+\begin{pmatrix} 0 & a_l\\ a_l^\top & r_l\end{pmatrix}\succeq 0,\\
&\qquad \begin{bmatrix} P & p\\ p^\top & s\end{bmatrix}\succeq 0,\quad S\succeq 0\quad (l=1,\dots,L_t).
\end{aligned}\tag{2.26}$$

在 (2.20) 中记 $a_l^0=a_l(x_{t-1})$, $r_l^0=r_l(x_{t-1})$, 则由 (2.22) 可得 $\varphi(a^0,\tilde{r}^0)=\hat{\mathcal{Q}}_t(x_{t-1})$. 另外, 易知 (2.26)

中国知网 https://www.cnki.net

的对偶问题为

$$\begin{aligned}
\max_{A_l,\pi_l,\nu_l,v}\ & \sum_l \pi_l^\top a_l + \sum_l \nu_l r_l \\
\text{s.t.}\ \ & \gamma_2\Sigma_t - \mu_t\mu_t^\top - \mu_t\sum_l \pi_l^\top \succeq \sum_l A_l, \\
& v - \frac{1}{2}\sum_l \pi_l = \mu_t, \quad \sum_l \nu_l = -1, \\
& \begin{bmatrix} \Sigma_t & v \\ v^\top & \gamma_1 \end{bmatrix} \succeq 0, \quad \begin{bmatrix} A_l & -\frac{1}{2}\pi_l \\ -\frac{1}{2}\pi_l^\top & -\nu_l \end{bmatrix} \succeq 0 \quad (l=1,\ldots,L_t).
\end{aligned} \tag{2.27}$$

由于 $\gamma_1 > 0$, 约束

$$\begin{bmatrix} \Sigma_t & v \\ v^\top & \gamma_1 \end{bmatrix} \succeq 0$$

可改写为 $\gamma_1\Sigma_t \succeq vv^\top$. 同时, 由最后一个约束可知, (1) 若 $\nu_l = 0$, 则有 $\pi_l = 0$ 及 $A_l \succeq 0$; (2) 若 $\nu_l < 0$, 则 $A_l + \frac{1}{4\nu_l}\pi_l\pi_l^\top \succeq 0$. 因此, 问题 (2.27) 可以被等价地改写为如下形式:

$$\begin{aligned}
&\max_{\pi_l,\nu_l} \left(\langle \pi, a\rangle + \langle \nu, \tilde{r}\rangle\right) = \sum_l \pi_l^\top a_l + \sum_l \nu_l r_l \\
&\text{s.t.}\ \ (\pi,\nu) \in \Pi,
\end{aligned} \tag{2.28}$$

其中 $\pi = (\pi_1^\top, \ldots, \pi_{L_t}^\top)^\top$, $\nu = (\nu_1, \ldots, \nu_{L_t})$, 集合 Π 的定义由 (2.25) 给出. Π 显然是一个闭凸集. 最后, (2.28) 可改写为

$$\varphi(a,\tilde{r}) = \max_{\pi,\nu}\{\langle \pi, a\rangle + \langle \nu, \tilde{r}\rangle - I_\Pi(\pi,\nu)\}, \tag{2.29}$$

其中 $I_\Pi(\cdot,\cdot)$ 是集合 Π 的示性函数, 因而 $I_\Pi(\cdot,\cdot)$ 是一个凸的下半连续函数. 因此, (2.29) 表明 $\varphi(\cdot,\cdot)$ 和 $I_\Pi(\cdot,\cdot)$ 互为共轭函数, 且有

$$\partial\varphi(a,\tilde{r}) = \arg\max_{(\pi,\nu)\in\Pi}\{\langle \pi, a\rangle + \langle \nu, \tilde{r}\rangle\}, \tag{2.30}$$

这就证明了 (2.24) 和 (2.25). 最后, 由 $a_l(\cdot)$ 和 $r_l(\cdot)$ 的表达式 (2.20) 可得 (2.23) 成立. □

到这里为止的分析表明, 我们可以分别利用 (2.27) 和 (2.23) 来计算 $\hat{\mathcal{Q}}_t(\cdot)$ 在给定点 x_{t-1} 处的函数值和次梯度. 这为切平面的计算以及由此构建 $\mathcal{Q}_t(\cdot)$ 的近似函数奠定了基础. 因此, 现在可以给出算法的基本框架, 其核心是一个基于 Benders 分解的递归过程:

$$\begin{aligned}
&\tilde{\mathcal{Q}}_{t+1}(x_t) \\
&\ \downarrow \text{ 代入} \\
&\hat{Q}_t(x_{t-1},\xi_t) = \min_{x_t\in C_t(x_{t-1},\xi_t)}\{c_t^\top x_t + \tilde{\mathcal{Q}}_{t+1}(x_t)\} \\
&\ \downarrow \text{ 代入} \\
&\hat{\mathcal{Q}}_t(x_{t-1}) = \sup_{P_t\in\mathbb{P}_t} \mathbb{E}_{P_t}[\hat{Q}_t(x_{t-1},\xi_t)]
\end{aligned} \tag{2.31}$$

中国知网 https://www.cnki.net

$$\begin{array}{rl} & \downarrow \qquad \text{(利用 (2.27) 和 (2.23) 计算切平面)} \\ \tilde{\mathcal{Q}}_t(x_{t-1}) & = \max\limits_{k=1,2,\ldots} l_k(x_{t-1}), \quad l_k(\cdot) \text{ 是 } \hat{\mathcal{Q}}_t \text{ 的一系列切平面.} \end{array}$$

基于嵌套 Benders 分解的动态逼近是一个反向 (backward) 的递归过程: 对每一个阶段 t, 假设已有关于 $\mathcal{Q}_{t+1}(\cdot)$ 的近似函数 $\tilde{\mathcal{Q}}_{t+1}(\cdot)$, 因此可以利用 (2.27) 和 (2.23) 来计算一系列切平面, 并基于这些切平面构建当前阶段 t 的逼近函数 $\tilde{\mathcal{Q}}_t$. 这个过程从最后阶段开始, 不断反向递归, 直到抵达初始阶段, 这就完成了各个阶段逼近函数的构建.

在第 1 节中曾提到, 传统的随机规划在嵌套 Benders 分解的基础上进一步引入了向前迭代步, 其作用是通过构建统计上界, 以提高计算精度并加快算法运行速度. 这就是 SDDP 方法. 然而, 这种引入统计上限的向前步并不能直接应用于本文所讨论的多阶段 DRSP 问题, 因为在分步鲁棒问题中, 随机参数的分布信息是不精确的. 当然, 在近期的一些研究中, Duque 和 Morton[10] 以及 Philpott 等[29] 提出了几类可以使用向前步的分布鲁棒模型. 但这些文献中讨论的模糊集与本文讨论的矩约束有很大不同, 不能直接应用过来. 简而言之, 在分布鲁棒问题中引入向前步或统计上界需要专门而详细的讨论, 这种讨论也会大大增加理论分析的复杂性. 鉴于此, 在接下去的讨论中, 我们将专注于考虑只含有后退步的近似动态方法.

记 X 为问题 (1.4) 中的可行集, 即 $X = \{x_{[T]} \in \mathbb{R}^n \mid \text{存在 } \xi_t \in \Xi_t, \text{使得 } x_t \in C_t\}$. 进一步地, 为便于讨论, 我们对各阶段目标函数的水平集给出以下假设:

假设 2.4 (a) 存在 $M > 0$ 及 $\alpha \in \mathbb{R}$ 使得对所有的 $t = 1, \ldots, T$, 水平集

$$\mathrm{lev}_\alpha^t(x_{t-1}, \xi_t) := \{x_t \in C_t(x_{t-1}, \xi_t) : c_t^\top x_t + \mathcal{Q}_{t+1}(x_t) \leqslant \alpha\}, \quad x_{t-1} \in C_{t-1}, \quad \xi_t \in \Xi_t \tag{2.32}$$

均非空有界, 且被集合 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 所包含;

(b) 进一步假设集合 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 属于 $\mathrm{int}\,\mathrm{dom}\mathcal{Q}_{t+1}$.

现对以上假设进行简要的讨论: 假设条件 (a) 中, 水平集有界的一种容易实现的情形是 C_t 本身包含在一个与 x_{t-1} 无关的有界约束中, 如要求 $x_t(1) + \cdots + x_t(n_t) = 1$, $x_t \geqslant 0$ 等. 此外, 如果函数 $c_t^\top x_t + \mathcal{Q}_{t+1}(x_t)$ 以某个具有强制性的凸函数为下界, 水平集的有界性也自然成立. 因此水平集有界的要求并不是十分困难的. 关于支撑集 Ξ_t, 算法推导过程中曾考虑最宽泛的情形, 令其等于 $\mathbb{R}^{m_t}$, 从而推导出 (2.18), 即 M_t 的正定性. 对于实际问题, 如果 ξ_t 各量的取值范围相对于 1 来说充分大, 则可以认为该条件近似成立. 在一般情形下, 若 Ξ_t 的范围显著小于 $\mathbb{R}^{m_t}$, 则可将 (2.18) 视为是一个加强的约束. 假设条件 (b) 要求集合 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 都属于有效域 $\mathrm{dom}\mathcal{Q}_{t+1}$ 的内部. 再结合 (a), 这实际上保证了算法所涉及的水平集都在有效域 $\mathrm{dom}\mathcal{Q}_{t+1}$ 的内部. 这个要求是常见的, 达到也并不困难. 这两个条件为下面正式给出近似动态逼近算法提供了基础, 也为后续进行算法的理论分析准备了条件. 现在正式给出算法描述, 见算法 1.

算法 1 多阶段 DRSP 问题的近似动态方法

第 1 步: (初始化) 对每个阶段 t, 设定样本容量 N_t $(t = 1, \ldots, T-1)$, 并从区域 $\{x_t \geqslant 0 \mid \|x_t\| \leqslant M\}$ 内抽取试验点 $x_t^1, \ldots, x_t^{N_t}$. 令 $t = T-1$;

第 2 步: (近似动态逼近) 对每一个试验点 x_t^k $(k = 1, \ldots, N_t)$, 通过求解 (2.27) 计算 $\hat{\mathcal{Q}}_{t+1}(x_t^k)$, 并通过求解 (2.23) 计算次梯度 $g_{t+1}^k \in \partial\hat{\mathcal{Q}}_{t+1}(x_t^k)$. 由此产生切平面 $l_k(x) = \hat{\mathcal{Q}}_{t+1}(x_t^k) + (g_{t+1}^k)^\top(x - x_t^k)$.

第 3 步: (递归更新) 将 $\tilde{\mathcal{Q}}_{t+1}(x_t) = \max_{1 \leqslant k \leqslant K_t} l_k(x_t)$ 作为阶段 t 的近似决策成本函数. 令 $t = t-1$. 若 $t = 1$, 执行下面的第 4 步, 否则返回第 2 步.

第 4 步: (第一阶段问题) 在第一阶段, 求解问题 (2.2) 以得到第一阶段问题的最优解和整个多阶段问题的最优值.

中国知网 https://www.cnki.net

如前所述, 以上近似动态算法的执行从阶段 $T-1$ 开始, 在每一个阶段均利用下一个阶段返回的信息计算产生近似决策成本函数, 并将其返回给上一个阶段, 从而形成一个逐步后退的递归过程. 在每个阶段 t, 首先通过某种抽样方法抽取容量为 N_t 的试验点, 而后在这些样本点产生 $\hat{\mathcal{Q}}_t$ 的诸多切平面, 由此得到第 t 阶段的决策成本函数的下方多面体逼近. 当对所有的阶段 t 都得到了这种逼近后, 就实现了动态决策问题的分解. 注意到, 算法第 2 步中对每一个试验点计算一个 $\hat{\mathcal{Q}}_t$ 的切平面, 因而实际上切平面数量 $K_t = N_t$. 当然, 从计算角度出发, 算法 1 采用的切平面技术可以采用冗余切平面删除等技术进行改进, 此时 K_t 与 N_t 就没有必然相等的关系了.

算法执行过程中的一个重要问题是试验点的抽取方式. 这种抽样可以是随机的, 也可以是确定性的. 随机抽样的基本形式就是简单随机抽样 (simple random sampling, SRS), 即假设总体在抽样区域内服从均匀分布, 样本点以独立同分布的方式产生. 确定性抽样的一种典型方式是均匀抽样 (uniform design, UD), 即按照某种 "均匀设计" 的原理或表格将试验点平均地散布在整个抽样区域中. 关于均匀设计的原理及其应用可参见文献 [12].

不论哪种抽样方式, 需要共同遵循的原则就是样本点应在水平集区域内分布得足够稠密, 以使得所构造的近似决策成本函数足够 "精确". 下一节将对这一原则的确切含义进行严格讨论 (参见假设 3.1). 样本点 "稠密" 往往通过设置足够大的样本容量 N_t 来实现. 事实上, 无论是 SRS 和 UD 抽样, 或是其他抽样方法, 样本量的增大都会使得样本点在抽样区域内越来越 "稠密", 因而它们都是在算法实施过程中可以采用的方法. 当然, 在实践当中, 不同抽样方式会对算法效率产生很大影响, 第 4 节将对此进行深入讨论.

3 收敛性分析

本节研究上节所提出的算法的收敛性. 迄今为止, 现有文献中关于嵌套 Benders 分解及其推广算法的收敛性已有很多研究. 早期文献主要考虑含离散随机变量的线性问题, 其中关于 Benders 分解的收敛性分析可参见文献 [33, 定理 18] 或 [5, 第六章, 定理 1], 关于 SDDP 方法的收敛性分析则可参见 Shapiro 的著作 [34]. 近期的一些研究中, Guigues [15] 和 Georghiou 等 [14] 考虑了目标函数为非线性、约束可行区域为非多面体的情形, 并在较一般的情形下建立了收敛性分析. 而文献 [47] 也建立了一个关于带锥约束结构的多阶段随机优化问题的一般性收敛框架.

本文考虑的是一种更切合实际但也更复杂的情形: 分布鲁棒问题所涉及的分布族包含了一般的非离散分布. 在此情形下, 需要建立新的收敛性分析框架来分析近似问题对原问题的收敛性. 这与只包含离散分布的情形有很大区别. 本节的分析将表明, 随着样本量的增加, 各阶段的近似决策成本函数 $\tilde{\mathcal{Q}}_t$ 将在上图收敛的意义下收敛到真实的 $\mathcal{Q}_t$. 由此又可得到, 近似问题 (2.7) 和 (2.8) 的解也会收敛到相应的原始问题的解.

上图收敛是随机规划和变分分析中十分重要的概念, 其定义如下:

定义 3.1 (参见文献 [32, 定义 7.1]) 设有一个函数序列 $f_k : \mathbb{R}^n \to \bar{\mathbb{R}}, k = 1, \ldots$ 及函数 $f : \mathbb{R}^n \to \bar{\mathbb{R}}$, 若 f_k 的上图像 (在 Painlevè-Kuratowski 点集收敛的意义下) 收敛到函数 f 的上图像, 则称 f_k 上图收敛到函数 f, 记作 $f_k \xrightarrow{e} f$.

上图收敛的一种等价定义可表述如下:

定义 3.2 (参见文献 [36, 定义 7.25]) 函数序列 $f_k : \mathbb{R}^n \to \bar{\mathbb{R}}, k = 1, \ldots$ 上图收敛到函数 $f : \mathbb{R}^n \to \bar{\mathbb{R}}$, 若对于任意点 $x \in \mathbb{R}^n$, 以下两个条件成立:

中国知网 https://www.cnki.net

(1) 任意一个收敛到点 x 的序列 x_k 都满足

$$\liminf_{k\to\infty} f_k(x_k) \geqslant f(x); \tag{3.1}$$

(2) 存在一个收敛到点 x 的序列 x_k, 使得

$$\limsup_{k\to\infty} f_k(x_k) \leqslant f(x). \tag{3.2}$$

关于上图收敛性的详细研究可参见专著 [3,32]. 函数序列的上图收敛性和由这些函数所定义的最优化问题的最优值收敛性之间有着紧密的联系, 对此我们引用如下命题.

命题 3.1 (参见文献 [36, 命题 7.26]) 假设 $f_k \xrightarrow{e} f$, 则有

$$\limsup_{k\to\infty}[\inf f_k(x)] \leqslant \inf f(x). \tag{3.3}$$

进一步地, 假设存在数列 $\varepsilon_k \downarrow 0$ 及收敛的点列 $\{x_k\}$ (记其极限点为 $\bar{x}$), 使得 x_k 是 $f_k(\cdot)$ 的一个 ε_k- 最优解 (即 $f_k(x_k) \leqslant \inf f_k(x) + \varepsilon_k$), 则有 $\bar{x} \in \operatorname{argmin} f$ 且

$$\lim_{k\to\infty}[\inf f_k(x)] = \inf f(x). \tag{3.4}$$

另外, 以下两个命题刻画了上图收敛性的成立条件.

命题 3.2 (参见文献 [32, 定理 7.17]) 设 $f_k : \mathbb{R}^n \to \bar{\mathbb{R}}$ 是凸函数序列, $f : \mathbb{R}^n \to \bar{\mathbb{R}}$ 是一个下半连续凸函数且其定义域 $\mathrm{dom} f$ 的内点集非空, 则 $f_k \xrightarrow{e} f$ 当且仅当存在一个 $\mathbb{R}^n$ 中的稠密子集 D 使得对所有的 $x \in D$, 都有 $f_k(x) \to f(x)$.

命题 3.3 (参见文献 [6, 定理 2.7]) 设 $\{f; f_k, k = 1, \ldots\}$ 是一族定义在 $\mathbb{R}^n \times \Xi$ 上取值在 $\bar{\mathbb{R}}$ 上的函数, 且对所有的 $\xi \in \Xi$, 函数序列 $\{f_k(\cdot, \xi)\}$ $(k = 1, \ldots)$ 均上图收敛到 $f(\cdot, \xi)$. 进一步假设存在一个一致可积函数 g 使得 $|f_k| \leqslant g$, 则有 $\mathbb{E}(f_k)$ 上图收敛到 $\mathbb{E}(f)$.

在正式进行收敛性分析之前, 首先需要讨论函数 $Q_t(\cdot, \xi_t)$ 和 $\mathcal{Q}_t(\cdot)$ 及它们的近似函数的性质.

命题 3.4 若假设 2.4 成立, 则对各阶段 $t = 1, \ldots, T$ 及任意的 $\xi_t \in \Xi_t$, 由 (2.3) 和 (2.4) 分别定义的函数 $Q_t(\cdot, \xi_t)$ 和 $\mathcal{Q}_t(\cdot)$ 关于 $\{x_{t-1} \mid x_{t-1} \geqslant 0\}$ 是适当的, 且在 $\{x_{t-1} \geqslant 0 : \|x_{t-1}\| \leqslant M\}$ 连续. (某函数 f 关于集合 D 是适当的, 是指: 对任意的 $x \in D$, 都有 $f(x) > -\infty$, 且存在某个 $x \in D$ 使得 $f(x) < +\infty$.)

证明 证明采用归纳法. 首先, 对于阶段 $T+1$, 注意到 $\mathcal{Q}_{T+1}(x_T)$ 和 $Q_{T+1}(x_T, \xi_{T+1})$ 都恒等于 0, 它们当然是适当的连续函数. 因而命题平凡成立. 一般地, 对于阶段 $t = 1, \ldots, T$, 假设命题对阶段 $t+1$ 成立. 先考察适当性. 由假设 2.4 可知, 存在某 $\alpha > 0$ 使得水平集 $\mathrm{lev}^t_\alpha(x_{t-1}, \xi_t)$ 是有界的. 结合 $\mathcal{Q}_{t+1}(x_t)$ 的连续性, 这表明 $Q_t(x_{t-1}, \xi_t)$ 存在有限的上下界, 因此 $Q_t(x_{t-1}, \xi_t)$ 和 $\mathcal{Q}_t(x_{t-1})$ 都是关于 x_{t-1} 的适当函数.

接着考察连续性. 由引理 2.2 及假设 2.4 可知, 函数 $Q_t(\cdot, \xi_t)$ 及 $\mathcal{Q}_t(\cdot)$ 是凸的, 且有效域内部包含 $\{x_{t-1} \geqslant 0 : \|x_{t-1}\| \leqslant M\}$. 由于有限维空间上的凸函数在有效域内部是连续的 (参见文献 [7, 推论 2.109] 等), 因此立即得到 $Q_t(\cdot, \xi_t)$ 及 $\mathcal{Q}_t(\cdot)$ 在 $\{x_{t-1} \geqslant 0 : \|x_{t-1}\| \leqslant M\}$ 上的连续性. □

命题 3.5 若假设 2.4 成立, 则对各阶段 $t = 1, \ldots, T$ 及任意的 $\xi_t \in \Xi_t$, 函数 $\hat{Q}_t(\cdot, \xi_t)$ 和 $\tilde{\mathcal{Q}}_t(\cdot)$ 以及 $\hat{\mathcal{Q}}_t(\cdot)$ 都是适当的, 且在 $\{x_{t-1} \geqslant 0 : \|x_{t-1}\| \leqslant M\}$ 上连续.

中国知网 https://www.cnki.net

证明 证明采用归纳法. 首先, 对于阶段 $t=T$, 由 $\hat{Q}_T \equiv Q_T$ 和 $\tilde{\mathcal{Q}}_T \leqslant \hat{\mathcal{Q}}_T \equiv \mathcal{Q}_T$ 可知命题平凡成立. 一般地, 对某个 $t<T$, 假设命题对阶段 $t+1$ 成立. 由于 $\tilde{\mathcal{Q}}_{t+1}(\cdot)$ 是连续的, 所以由假设 2.4 可知 $\hat{Q}_t(\cdot,\xi_t)$ 是上下均有界的. 这意味着 $\hat{\mathcal{Q}}_t(\cdot)$ 也有有限的上下界. 因此 $\hat{Q}_t(\cdot,\xi_t)$ 和 $\hat{\mathcal{Q}}_t(\cdot)$ 都是适当函数. 又因为 $\tilde{\mathcal{Q}}_t(\cdot)$ 是由 $\hat{\mathcal{Q}}_t(\cdot)$ 的一系列切平面构成的, 因而 $\tilde{\mathcal{Q}}_t(\cdot)$ 也是适当的. 最后, 采用与命题 3.4 同样的证明方法可得 $\hat{Q}_t(\cdot,\xi_t)$ 与 $\hat{\mathcal{Q}}_t(\cdot)$ 都在 $\{x_{t-1}\geqslant 0:\|x_{t-1}\|\leqslant M\}$ 上连续. 另外, $\tilde{\mathcal{Q}}_t(\cdot)$ 的连续性可由其定义直接得到. 故归纳法完成. □

命题 3.6 对所有的阶段 $t=2,\ldots,T$ 都成立 $\hat{Q}_t(x_{t-1},\xi_t)\leqslant Q_t(x_{t-1},\xi_t)$,$\tilde{\mathcal{Q}}_t(x_{t-1})\leqslant\hat{\mathcal{Q}}_t(x_{t-1})\leqslant\mathcal{Q}_t(x_{t-1})$. 此外, 当 $t=1$ 时有 $\hat{Q}_1\leqslant Q_1$.

证明 证明采用归纳法. 对于阶段 $t=T$, 命题是平凡成立的. 一般地, 对 $t<T$, 假设命题对阶段 $t+1$ 成立. 则有 $\tilde{\mathcal{Q}}_{t+1}(x_t)\leqslant\mathcal{Q}_{t+1}(x_t)$, 这意味着 $\hat{Q}_t(x_{t-1},\xi_t)\leqslant Q_t(x_{t-1},\xi_t)$. 从而得到 $\hat{\mathcal{Q}}_t(x_{t-1})\leqslant\mathcal{Q}_t(x_{t-1})$. 因为 $\tilde{\mathcal{Q}}_t(\cdot)$ 是基于 $\hat{\mathcal{Q}}_t(\cdot)$ 的一系列切平面构造成的, 因此有 $\tilde{\mathcal{Q}}_t(x_{t-1})\leqslant\hat{\mathcal{Q}}_t(x_{t-1})$. 故归纳法完成. □

接下来开始研究算法的收敛性. 首先, 基于假设 2.4, 可以不失一般性地假设函数 $Q_t(\cdot,\xi_t)$ 和 $\mathcal{Q}_t(\cdot)$ 及其近似函数的定义域都在 $\{x_{t-1}\geqslant 0:\|x_{t-1}\|\leqslant M\}$ 内, 因为该集合以外的区域实际上与最优化问题的求解无关. 由于多阶段决策问题的复杂性, 在正式开始收敛性证明之前, 首先对整个证明过程的结构进行一些说明.

整体上, 证明采用归纳法. 首先证明 $\tilde{\mathcal{Q}}_T$ 上图收敛到 $\mathcal{Q}_T$. 随后, 根据归纳推理, 我们证明: 对一般的 $t<T$, 若 $\tilde{\mathcal{Q}}_{t+1}$ 上图收敛到 $\mathcal{Q}_{t+1}$, 则这种上图收敛性对当前的阶段 t 也成立, 即 $\tilde{\mathcal{Q}}_t \xrightarrow{e} \mathcal{Q}_t$.

回顾 (2.31) 所刻画的 $\tilde{\mathcal{Q}}_t$ 与 $\tilde{\mathcal{Q}}_{t+1}$ 之间的联系, 可将上述归纳推理分解为以下几个步骤:

(i) 证明 $\tilde{\mathcal{Q}}_{t+1} \xrightarrow{e} \mathcal{Q}_{t+1}$;

(ii) 证明对任意的 $\xi_t\in\Xi_t$, 成立 $\hat{Q}_t(\cdot,\xi_t) \xrightarrow{e} Q_t(\cdot,\xi_t)$;

(iii) 证明 $\hat{\mathcal{Q}}_t \xrightarrow{e} \mathcal{Q}_t$;

(iv) 最后证明 $\tilde{\mathcal{Q}}_t \xrightarrow{e} \mathcal{Q}_t$.

整个归纳推理的流程即按照 (i) ⇒ (ii) ⇒ (iii) ⇒ (iv) 的步骤进行.

下面给出一些记号与说明. 记 $\mathcal{N}_0=(N_1,N_2,\ldots,N_{T-1})^\top$ 为由各阶段的样本容量组成的向量. $\mathcal{N}_0\to\infty$ 表示对所有的 $t=1,\ldots,T-1$, 都有 $N_t\to\infty$. 进一步地, 用 "$\mathcal{N}_0$ 充分大" 表示所有的分量 N_t 都充分大. 为表达方便, 进一步在某些记号中将 $\mathcal{N}_0$ 作为上标引入, 例如, 记 $\tilde{\mathcal{Q}}_t^{\mathcal{N}_0}$, $\hat{Q}_t^{\mathcal{N}_0}(\cdot,\xi_t)$ 以及 $\hat{\mathcal{Q}}_t^{\mathcal{N}_0}$ 以表明此时的样本容量向量为 $\mathcal{N}_0$.

假设 3.1 对任何给定的点 $x_t\in\mathrm{lev}_\alpha^t$, 随着样本量的增大, x_t 与第 t 阶段的样本集合 $S_t^{\mathcal{N}_0}=\{x_t^i\mid i=1,\ldots,N_t\}$ 的距离收敛到 0, 即

$$\lim_{\mathcal{N}_0\to+\infty}\mathrm{dist}\,(x_t,S_t^{\mathcal{N}_0})=0. \tag{3.5}$$

以上假设的意义是, 随着样本量的增加, 样本点会在可行区域内越来越稠密. 从统计角度来说, 只要采用某些常见的随机抽样方法, 上述假设中的事件 (3.5) 就会以概率 1 成立, 后续的各种收敛性分析结果也会以概率 1 成立. 为表述简单起见, 以下将省略诸如 "概率 1 成立" 这样的表述.

假设 3.2 存在上界 C 使得对所有的 $x_{[T]}\in X$ 以及每一个阶段 $t=1,\ldots,T$, 都有 $\|g\|\leqslant C$ 和 $\|g_1\|\leqslant C$, 其中 $g\in\partial\mathcal{Q}_t(x_{t-1})$, $g_1\in\partial\hat{\mathcal{Q}}_t(x_{t-1})$.

以上假设的作用是保证各决策成本函数 $\mathcal{Q}_t(x_{t-1})$ 及其近似函数的次梯度是有界的. 这一假设是较温和的, 因而在随机优化中使用很广 (参见文献 [33, 第 2.5 小节] 对这一条件的讨论).

中国知网 https://www.cnki.net

现在正式开始使用归纳法来分析算法 1 的收敛性. 首先要讨论 $t=T$ 时的情形, 即证明 $\tilde{\mathcal{Q}}_T$ 上图收敛到 $\mathcal{Q}_T$, 为此有如下命题.

命题 3.7 若假设 2.4, 3.1 和 3.2 都成立, 则当 $\mathcal{N}_0\to\infty$ 时, 对阶段 $t=T$ 成立 $\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}\xrightarrow{e}\mathcal{Q}_T$.

证明 给定样本容量 $\mathcal{N}_0$, 记 $\mathcal{A}_T^{\mathcal{N}_0}=\{x_T^1,\dots,x_T^{N_T}\}$ 是阶段 T 的样本点集合. 由此立即得到 $\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}(x_{T-1}^k)=l_k(x_{T-1}^k)=\mathcal{Q}_T(x_{T-1}^k)$ $(k=1,\dots,N_T)$. 任选可行点 x_T^0 以及 $\epsilon>0$, 由假设 3.1 可得, 对充分大的 N_0, 存在 $y_T\in\mathcal{A}_T^{\mathcal{N}_0}$ 使得 $\|x_T^0-y_T\|<\epsilon$. 这意味着 $\lim_{\mathcal{N}_0\to\infty}y_T=x_T^0$.

由于 $y_T\in\mathcal{A}_T^{\mathcal{N}_0}$, 记 $l_y(x_T):=\alpha_y^\top(x_T-y_T)+\mathcal{Q}_T(y_T)$ 为函数 $\mathcal{Q}_T$ 在 y_T 处计算得到的切平面. 显然, $\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}(y_T)=l_y(y_T)=\mathcal{Q}_T(y_T)$. 由函数的凸性可得

$$\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}(x_T^0)\geqslant\mathcal{Q}_T(y_T)+\alpha_y^\top(x_T^0-y_T). \tag{3.6}$$

由题设 $\mathcal{N}_0\to\infty$, 根据 $\mathcal{Q}_T$ 的连续性以及假设 3.2, 可得

$$\liminf_{\mathcal{N}_0\to\infty}\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}(x_T^0)\geqslant\mathcal{Q}_T(x_T^0). \tag{3.7}$$

另外, 由命题 3.6 可得 $\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}(x_T^0)\leqslant\mathcal{Q}_T(x_T^0)$ 成立. 结合 (3.7) 即可得到 $\lim_{N_0\to\infty}\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}(x_T^0)=\mathcal{Q}_T(x_T^0)$.

由 x_T^0 的任意性, 这意味着 $\tilde{\mathcal{Q}}_T^{\mathcal{N}_0}$ 逐点收敛到 $\mathcal{Q}_T$. 再由命题 3.2 即可得上图收敛性成立. □

接下来证明归纳推理成立, 即由 $\tilde{\mathcal{Q}}_{t+1}\xrightarrow{e}\mathcal{Q}_{t+1}$ 可推导出 $\tilde{\mathcal{Q}}_t\xrightarrow{e}\mathcal{Q}_t$. 如前文所述, 这一证明框架可分解为 3 个证明步骤, 以下是第 1 步, 即说明 (i) ⇒ (ii).

引理 3.1 若假设 2.4, 3.1 和 3.2 都成立, 且对某阶段 $t<T$ 成立 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}\xrightarrow{e}\mathcal{Q}_{t+1}$, 则对于任意 $\xi_t\in\Xi_t$ 及 $x_{t-1}\in C_{t-1}$, 有以下结果:

$$\lim_{\mathcal{N}_0\to\infty}\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t)=Q_t(x_{t-1},\xi_t). \tag{3.8}$$

证明 由假设 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}\xrightarrow{e}\mathcal{Q}_{t+1}$ 立即可得 $c_t^\top x_t+\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}(x_t)\xrightarrow{e}c_t^\top x_t+\mathcal{Q}_{t+1}(x_t)$ (参见文献 [32, 第 247 页]). 结合 $Q_t(x_{t-1},\xi_t)$ 与 $\hat{Q}_t(x_{t-1},\xi_t)$ 的定义 (即 (2.3) 和 (2.7)), 由 (3.3) 可得

$$\limsup_{\mathcal{N}_0\to\infty}\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t)\leqslant Q_t(x_{t-1},\xi_t). \tag{3.9}$$

另外, 记 $\mathcal{N}_0^k$, $k\in K$ 为样本容量序列的一个子列, 且满足 $\mathcal{N}_0^k\to+\infty$, 以及

$$\hat{Q}_t^{\mathcal{N}_0^k}(x_{t-1},\xi_t)\to\liminf_{\mathcal{N}_0\to\infty}\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t). \tag{3.10}$$

进一步地, 记 x_t^k 为 $\hat{Q}_t^{\mathcal{N}_0^k}(x_{t-1},\xi_t)$ 所定义的子问题的一个解. 由于水平集 lev_α^t 有界, 可以不失一般性地假定 $\{x_t^k\}$ 收敛到某点 $\bar{x}_t$. 则由 (3.4) 和命题 3.1, 并结合 $\mathcal{N}_0^k$ 的任意性, 可以得到

$$\liminf_{\mathcal{N}_0\to\infty}\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t)=Q_t(x_{t-1},\xi_t) \tag{3.11}$$

以及

$$\bar{x}_t\in\operatorname*{argmin}_{x_t\in C_t}\{c_t^\top x_t+\mathcal{Q}_{t+1}(x_t)\}.$$

结合 (3.9) 和 (3.11) 即可得到 (3.8) 成立. □

中国知网 https://www.cnki.net

推论 3.1 若假设 2.4, 3.1 和 3.2 都成立, 且对阶段 $t<T$ 成立 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_{t+1}$ 成立, 则对任意的 $\xi_t \in \Xi_t$, 以下结果成立:

$$\hat{Q}_t^{\mathcal{N}_0}(\cdot,\xi_t) \xrightarrow{e} Q_t(\cdot,\xi_t). \tag{3.12}$$

证明 由 (3.8) 及命题 3.2 立即可得上述结论. □

归纳推理的第 2 步是说明 (i) + (ii) ⇒ (iii), 由于上述推论已经说明了 (i) 能推导出 (ii), 因而这实际上意味着 (i) ⇒ (iii).

引理 3.2 若假设 2.4, 3.1 和 3.2 都成立, 且对某阶段 $t<T$ 及任意的 $\xi_t \in \Xi_t$, 都成立 $\hat{Q}_t^{\mathcal{N}_0}(\cdot,\xi_t) \xrightarrow{e} Q_t(\cdot,\xi_t)$, 且 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_{t+1}$, 则有

$$\hat{\mathcal{Q}}_t^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_t. \tag{3.13}$$

证明 首先, 根据 $\hat{\mathcal{Q}}_t$ 的定义, 可得

$$\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x_{t-1}) = \sup_{P_t\in\mathbb{P}_t} \mathbb{E}_{P_t}[\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t)].$$

为表述方便, 对每一个 $P_t \in \mathbb{P}_t$, 记 $f_{P_t}^{\mathcal{N}_0}(x_{t-1}) = \mathbb{E}_{P_t}[\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t)]$ 和 $f_{P_t}(x_{t-1}) = \mathbb{E}_{P_t}[Q_t(x_{t-1},\xi_t)]$. 从而, $\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x_{t-1}) = \sup_{P_t\in\mathbb{P}_t} f_{P_t}^{\mathcal{N}_0}(x_{t-1})$ 且 $\mathcal{Q}_t(x_{t-1}) = \sup_{P_t\in\mathbb{P}_t} f_{P_t}(x_{t-1})$. 命题的证明分两步完成: (甲) 对每一个 $P_t \in \mathbb{P}_t$ 都有 $f_{P_t}^{\mathcal{N}_0} \xrightarrow{e} f_{P_t}$; (乙) 以下结果成立:

$$\sup_{P_t\in\mathbb{P}_t} f_{P_t}^{\mathcal{N}_0} \xrightarrow{e} \sup_{P_t\in\mathbb{P}_t} f_{P_t}.$$

先证明 (甲), 为此需说明 $\hat{Q}_t^{\mathcal{N}_0}$ 在约束区域是一致有界的. 首先注意到, 函数 $c_t^\top x_t + \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}(x_t)$ (即 $\hat{Q}_t^{\mathcal{N}_0}(x_{t-1},\xi_t)$ 所定义的优化问题的目标函数) 在 $c_t^\top x_t + \mathcal{Q}_{t+1}(x_t)$ 下方. 注意到, $c_t^\top x_t + \mathcal{Q}_{t+1}(x_t)$ 是一个连续函数. 其在区域 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 上显然有界. 记该上界为 M_q, 显然 M_q 也是 $\hat{Q}_t^{\mathcal{N}_0}$ 一致的上界. 以下说明 $c_t^\top x_t + \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}(x_t)$ 在该区域有一致的下界. 为此只需要说明 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}(x_t)$ 有一致的下界. 记 $\mathcal{Q}_{t+1}$ 在区域 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 的下界为 L_f.

任取某点 x_t^*. 因为 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_{t+1}$, 由上图收敛定义 3.2 中的 (3.1) 可知, 对任意的 $\{x_t^k\} \to x_t^*$, 有

$$\liminf_{k\to\infty} \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^k) \geqslant \mathcal{Q}_{t+1}(x_t^*).$$

任取 $\epsilon_0 > 0$, 存在指标 k_0, 当 $k \geqslant k_0$ 时, $\|x_t^k - x_t^*\| < 1$ 且 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^k) \geqslant \mathcal{Q}_{t+1}(x_t^*) - \epsilon_0$.

由假设 3.2 可知, 次梯度 $\partial\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}$ 的模有公共的上界 C, 故易知

$$\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^*) \geqslant \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^k) - C\|x_t^k - x_t^*\| \geqslant \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^k) - C. \tag{3.14}$$

从而当 $k > k_0$ 时,

$$\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^*) \geqslant \mathcal{Q}_{t+1}(x_t^*) - \epsilon_0 - C \geqslant L_f - \epsilon_0 - C. \tag{3.15}$$

对任意的 $x_t \in \{x_t \geqslant 0 : \|x_t\| \leqslant M\}$, 同样由假设 3.2, 有以下结果:

$$\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t) \geqslant \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0^k}(x_t^*) - C\cdot 2M \geqslant L_f - \epsilon_0 - C(2M+1).$$

中国知网 https://www.cnki.net

故当 $k > k_0$ 时, $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}$ 在 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 上有一致的下界. 对于 $k \leqslant k_0$ 的情形, 由于 $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}$ 为连续函数, 易知其在该区域也有公共的下界. 综上可知, $\tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}$ 在 $\{x_t \geqslant 0 : \|x_t\| \leqslant M\}$ 上有一致的下界. 从而 $c_t^\top x_t + \tilde{\mathcal{Q}}_{t+1}^{\mathcal{N}_0}(x_t)$ 在该区域有一致的下界. 故 $\hat{Q}_t^{\mathcal{N}_0}$ 也有一致的下界.

综合以上结果, $\hat{Q}_t^{\mathcal{N}_0}$ 是一致有界的. 由于 $\hat{Q}_t^{\mathcal{N}_0}(\cdot, \xi_t) \xrightarrow{e} Q_t(\cdot, \xi_t)$, 所以由命题 3.3 可得结论 (甲) 成立, 即对任意的 $P_t \in \mathbb{P}_t$, 都有

$$\mathbb{E}_{P_t}[\hat{Q}_t^{\mathcal{N}_0}(\cdot, \xi_t)] \xrightarrow{e} \mathbb{E}_{P_t}[Q_t(\cdot, \xi_t)]. \tag{3.16}$$

接下来证明 (乙). 按照上图收敛的定义, 这意味着要证明 $\sup_{P_t \in \mathbb{P}_t} f_{P_t}^{\mathcal{N}_0}$ 的上图像集合 (在集值收敛的意义下) 收敛到 $\sup_{P_t \in \mathbb{P}_t} f_{P_t}$ 的上图像. 按运算法则容易验证以下结果成立, 即一族函数的上确界的上图像等于该族函数上图像的交:

$$\operatorname{epi}\Big(\sup_{P_t \in \mathbb{P}_t} f_{P_t}^{\mathcal{N}_0}\Big) = \bigcap_{P_t \in \mathbb{P}_t} \operatorname{epi}(f_{P_t}^{\mathcal{N}_0}), \quad \operatorname{epi}\Big(\sup_{P_t \in \mathbb{P}_t} f_{P_t}\Big) = \bigcap_{P_t \in \mathbb{P}_t} \operatorname{epi}(f_{P_t}).$$

记 $E_{P_t}^{\mathcal{N}_0} := \operatorname{epi}(f_{P_t}^{\mathcal{N}_0})$, $E_{P_t} := \operatorname{epi}(f_{P_t})$, $E_t^{\mathcal{N}_0} := \operatorname{epi}(\hat{\mathcal{Q}}_t^{\mathcal{N}_0})$ 和 $E_t := \operatorname{epi}(\mathcal{Q}_t)$, 则上式可简记为

$$E_t^{\mathcal{N}_0} = \bigcap_{P_t \in \mathbb{P}_t} E_{P_t}^{\mathcal{N}_0}, \quad E_t = \bigcap_{P_t \in \mathbb{P}_t} E_{P_t}.$$

为证明 (乙), 即要证明 $E_t^{\mathcal{N}_0}$ 在 Painlevè-Kuratowski 点集收敛的意义下收敛到 E_t, 即

$$\limsup_{\mathcal{N}_0 \to \infty} E_t^{\mathcal{N}_0} \subseteq E_t \subseteq \liminf_{\mathcal{N}_0 \to \infty} E_t^{\mathcal{N}_0}.$$

为此首先注意到, 对任意的 $P_t \in \mathbb{P}_t$ 都有 $f_{P_t}^{\mathcal{N}_0} \leqslant f_{P_t}$, 这说明 $E_{P_t} \subseteq E_{P_t}^{\mathcal{N}_0}$. 因此,

$$E_t \subseteq \liminf_{\mathcal{N}_0 \to \infty} E_t^{\mathcal{N}_0}.$$

另外, 记 $\mathcal{N}_0^k$, $k \in K$ 为样本容量序列的一个满足 $\mathcal{N}_0^k \to \infty$ 的子列, 并存在序列 $\{e_k\}$, $k \in K$ 使得 $e_k \in E_t^{\mathcal{N}_0^k}$ 且 $e_k \to e_*$. 因为对每个 $P_t \in \mathbb{P}_t$ 都有 $e_k \in E_{P_t}^{\mathcal{N}_0^k}$, 且已证明 (甲) 成立, 故极限点 e_* 属于 E_{P_t}. 因此, $e_* \in E_t$. 这意味着 $\limsup_{\mathcal{N}_0 \to \infty} E_t^{\mathcal{N}_0} \subseteq E_t$.

因此, $\lim_{\mathcal{N}_0 \to \infty} E_t^{\mathcal{N}_0} = E_t$. 证毕. □

归纳法框架的最后一步是说明 (iii) ⇒ (iv).

引理 3.3 若假设 2.4, 3.1 和 3.2 都成立, 且对阶段 $t < T$ 成立 $\hat{\mathcal{Q}}_t^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_t$, 则有 $\tilde{\mathcal{Q}}_t^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_t$.

证明 对任意的 $x^0 \in C_t$ 和 $\epsilon > 0$, 由命题 3.2 以及 $\mathcal{Q}_t$ 的连续性可得, 存在正数 $\delta_0 < \frac{\epsilon}{4C}$ (C 由假设 3.2 定义) 和点 $x^1 \in \mathcal{N}(x^0, \delta_0)$ 使得 $\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1) \to \mathcal{Q}_t(x^1)$ 且 $|\mathcal{Q}_t(x^1) - \mathcal{Q}_t(x^0)| < \frac{\epsilon}{4}$.

注意到 $\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1) \leqslant \mathcal{Q}_t(x^1)$, 故对充分大的 $\mathcal{N}_0$, 有

$$\mathcal{Q}_t(x^1) - \frac{\epsilon}{4} \leqslant \hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1) \leqslant \mathcal{Q}_t(x^1). \tag{3.17}$$

任取正数 $\delta_1 < \frac{\epsilon}{4C} - \delta_0$. 由假设 3.1, 对充分大的 $\mathcal{N}_0$, 存在点 $x^2 \in \{x_t^1, \ldots, x_t^{\mathcal{N}_0}\}$ (即 x^2 是样本集合中的点) 且满足 $x^2 \in \mathcal{N}(x^1, \delta_1)$. 因而, $\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2) = \tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2)$. 现在任选 $g_1 \in \partial \hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1)$, 则有

$$\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2) - \hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1) \geqslant g_1^\top (x^2 - x^1) \geqslant -C\delta_1 \geqslant -\frac{\epsilon}{4}.$$

中国知网 https://www.cnki.net

类似地, 任取 $g_2 \in \partial\tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2)$, 由 x^2 取法及假设 3.2 可得 $\|g_2\| \leqslant C$. 故有

$$\tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^0) - \tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2) \geqslant g_2^\top(x^0 - x^2) \geqslant -C(\delta_0 + \delta_1) \geqslant -\frac{\epsilon}{4}.$$

因此,

$$\begin{aligned} 0 &\geqslant \tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^0) - \mathcal{Q}_t(x^0) \\ &= (\tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^0) - \tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2)) + (\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^2) - \hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1)) \\ &\quad + (\hat{\mathcal{Q}}_t^{\mathcal{N}_0}(x^1) - \mathcal{Q}_t(x^1)) + (\mathcal{Q}_t(x^1) - \mathcal{Q}_t(x^0)) \\ &\geqslant -\frac{\epsilon}{4} - \frac{\epsilon}{4} - \frac{\epsilon}{4} - \frac{\epsilon}{4} \\ &= -\epsilon. \end{aligned}$$

这说明 $\tilde{\mathcal{Q}}_t^{\mathcal{N}_0}(x^0)$ 收敛到 $\mathcal{Q}_t(x^0)$. 再由命题 3.2 及 x^0 的任意性即可得到上图收敛性. □

引理 3.1–3.3 构成了一个完整的归纳法推理的证明链, 即 (i) ⇒ (ii) ⇒ (iii) ⇒ (iv). 再结合命题 3.7, 即可得到以下关于算法收敛性的完整证明.

定理 3.1 若假设 2.4, 3.1 和 3.2 都成立, 则对各阶段 $t = 2, \ldots, T$, 都有 $\tilde{\mathcal{Q}}_t^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_t$, 且对任意给定的 $x_{t-1} \in C_t$ 和 $\xi_t \in \Xi_t$ 都成立

$$\lim_{\mathcal{N}_0 \to +\infty} \hat{Q}_t^{\mathcal{N}_0}(x_{t-1}, \xi_t) = Q_t(x_{t-1}, \xi_t). \tag{3.18}$$

记 $x_t^{\mathcal{N}_0}$ 是由 $\hat{Q}_t^{\mathcal{N}_0}(x_{t-1}, \xi_t)$ 定义的优化问题的任一最优解, S_t 是由 $Q_t(x_{t-1}, \xi_t)$ 定义的最优化问题的解集, 则当 $\mathcal{N}_0 \to +\infty$ 时, $d(x_t^{\mathcal{N}_0}, S_t)$ 收敛到 0.

证明 证明采用归纳法. 首先, 由命题 3.7 可得 $\tilde{\mathcal{Q}}_T^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_T$. 注意到 $\hat{Q}_T(\cdot, \xi_T) \equiv Q_T(\cdot, \xi_T)$, 因而 (3.18) 对 $t = T$ 平凡成立, 且 $x_T^{\mathcal{N}_0}$ 是 S_T 的元素. 因此, 命题对阶段 T 成立. 一般地, 对 $t = 1, \ldots, T-1$ 的情形, 假设命题对阶段 $t+1$ 成立. 综合引理 3.1–3.3 可得 $\tilde{\mathcal{Q}}_t^{\mathcal{N}_0} \xrightarrow{e} \mathcal{Q}_t$, 且 (3.18) 对阶段 t 成立. 若存在不收敛到 S_t 的子序列 $x_t^{\mathcal{N}_0^k}$, 即 $d(x_t^{\mathcal{N}_0^k}, S_t) \nrightarrow 0$. 由于序列 $\{x_t^{\mathcal{N}_0}\}$ 是有界的, 不妨假设 $x_t^{\mathcal{N}_0^k}$ 收敛到某极限点 x_t^* (若序列不收敛, 则可通过取子序列实现). 由命题 3.1, 此时必然有 $x_t^* \in S_t$. 这导致了矛盾. 因此 $d(x_t^{\mathcal{N}_0}, S_t)$ 必然收敛到 0. 这表明命题对于阶段 t 成立. 因而归纳推理成立. □

对于初始阶段 $t = 1$, 由以上收敛性分析可知, $\hat{Q}_1$ 收敛到 Q_1, 且近似问题的最优值和最优解将各自收敛到原问题 (1.4) 的最优值和最优解.

4 数值试验

本节首先讨论算法实施的两个具体问题, 随后对几类测试问题进行数值试验.

4.1 算法实施的两个问题

第一个问题是第 2 节提到的试验点抽取方式. 如前所述, 理论上, 包括简单随机抽样 (SRS) 和均匀抽样 (UD) 在内的许多方法都可用于算法实施. 但从实践角度看, 样本容量越大意味着计算量也越大. 因而, SRS 在实际计算中的效率就太低了. 特别是在高维问题的计算中, 由于 "维数灾难" (curse of dimensionality) 效应的存在, 简单随机抽样无法直接使用. 另外, 均匀设计的思想是按照某种均匀性度

中国知网 https://www.cnki.net

量来分布样本, 从而达到有效降低样本容量的效果. 对于本文算法的实施, 这是一种可以采用的方法. 事实上, 这一特点也使得它在动态系统的计算中被广泛应用.

另外, 均匀抽样的主要缺点是缺乏随机性. 作为一种确定型方法, 它对同一个抽样区域产生的样本集合总是相同的. 因而有许多研究考虑了用均匀设计思想来对随机抽样方法进行改进. 其中一种重要思路是在随机性抽样中引入 "均匀性", 从而显著降低所需的样本容量. 由此而产生的一类重要方法是 Latin 超立方抽样 (Latin hypercube sampling, LHS), 该方法的详细研究可参见 Iman 的专著 [17]. 以下使用该方法来产生服从多元分布 F 的试验点 (见算法 2).

算法 2 Latin 超立方抽样 (LHS) [37]

假设分布为 F 的 K 维随机向量 $X := (X_1, \ldots, X_K)^\top$ 的各分量之间相互独立, 并记 F_k 为第 k 个分量 X_k 的累积概率函数. 从服从该分布的多元总体中, 按以下程序产生 N 个样本点, 记为 $x_1, \ldots, x_N$.

第 1 步: 首先生成一个 $N \times K$ 阶随机矩阵 $P = (p_{jk})$, P 的每一列是 $\{1, 2, \ldots, N\}$ 的一个随机排列.

第 2 步: 再产生 $N \times K$ 个独立同服从 $[0, 1]$ 上均匀分布的随机变量 ξ_{jk} $(j = 1, \ldots, N; k = 1, \ldots, K)$, 其产生过程独立于 P.

第 3 步: 最后按以下方式产生 x_{jk}:

$$x_{jk} = F_k^{-1}((p_{jk} - 1 + \xi_{jk})/N),$$

其中 x_{jk} 是样本 x_j 的第 k 个分量.

本节采用以上 LHS 方法产生试验点. 为简单起见, 设定随机样本 X 在抽样区域上服从均匀分布, 即可以将 F_k 设为均匀分布.

第二个需要讨论的问题是关于集合 $\Theta_t = \{\eta, v_k \ (k = 1, \ldots, K_t) \mid \sum_k v_k = 1, v_k \geqslant 0, A_t^\top \eta \leqslant c_t + \sum_k v_k \alpha_k\}$ 的顶点计算问题. 为了求解问题 (2.21) 和 (2.23), 我们需要满足约束 (2.18), 即对所有的 Θ_t 中的元素 $\{\eta, v_1, \ldots, v_{K_t}\}$, 应满足 $M_t \succeq 0$. 注意到 Θ_t 是一个凸多面体, 因而处理此约束的一种可能的方法是直接计算 Θ_t 的所有顶点.

另外, 注意到 Θ_t 表达式中的 K_t 实际上是第 t 阶段的样本容量 N_t, 这意味着该多面体顶点的数量与样本容量直接相关. 因而, 如果采用顶点枚举算法, 就需要考虑其对于高维问题可能具有很高的时间复杂性. 因而, 当 N_t 很大时, 直接使用顶点穷举方法是不实际的.

进一步观察 (2.18) 提示可以采用一个更简单的替代办法. 首先, 对于给定的 Θ_t, 记 $\Phi_t = \{(\eta, \nu) \mid \nu = \sum_k v_k \beta_k, (\eta, v_k) \in \Theta_t\}$. 容易验证 Φ_t 也是一个凸多面体. 另外, 注意到 M_t 的正定性实际上依赖于 (η, ν). 这意味着可以用计算 Φ_t 的顶点来取代计算 Θ_t 的顶点, 而前者的变量规模和样本量不再有必然的联系. 这大大降低了顶点计算所涉及的复杂性.

关于凸集顶点的算法目前文献中有两类. 其一是针对由线性不等式约束定义的凸多面体设计顶点枚举算法, 一个典型例子是专著 [42] 和文献 [41] 中给出的枚举算法, 顶点枚举算法的复杂性分析可参见文献 [11] 等. 另一类是针对给定的数据集寻找其凸包络的算法, 即寻找最少的点以使其凸包能够覆盖给定的数据集, 这在支持向量机等许多问题中有广泛应用. 此类算法的一个典型的实现版本由文献 [40] 提出, 而后是由文献 [19] 改进的算法.

本节的数值试验将区分两种情形, 并分别使用上述两种算法以满足约束 (2.18):

(i) 对阶段 T, 由于此时不需要构造切平面, 因此 $\Theta_T = \{\eta \mid A_T^\top \eta \leqslant c_T\}$ 且有 $\sum_k v_k \beta_k \equiv 0$. 此时问题较为简单, 不需要构造集合 Φ_T. 此种情形下直接使用文献 [42] 的算法找出 Θ_T 的所有顶点.

(ii) 对于阶段 $t < T$, 此时直接计算 Θ_T 的所有顶点是不现实的, 我们采用前述的转化为计算 Φ_t 顶点的方法. 由于计算量仍然很大, 需要使用近似方法, 此时采用文献 [19] 中的随机凸包络方法, 具体

中国知网 https://www.cnki.net

操作步骤如下:

(a) 在集合 Θ_t 内抽样, 产生一个很大的样本集合.

(b) 对于样本集合中的每一个成员 $(\eta, v_1, \ldots, v_{K_t})$, 计算 $\nu = \sum_k v_k\beta_k$, 得到 Φ_t 中的点 (η, ν). 这样就产生了 Φ_t 的样本集合;

(c) 对于上一步产生的数据集合, 使用凸包络算法寻找至多 M 个顶点以构建其近似凸包络.

(d) 对 Φ_t 中的这不超过 M 个顶点, 找出它们在 Θ_t 中的原像. 这就找到了 Θ_t 中的顶点集合的近似.

4.2 数值试验结果

我们针对本文提出的算法进行了一系列数值试验. 试验所用软件为 Matlab R2016b, 运行环境为一台装有 Windows 10 的台式机. 对于算法所涉及的半定规划子问题, 我们使用 CVX (convex) 平台下的 SDT3 (semidefinite programming solver 3) 求解器进行求解.

在对算法进行完整测试前, 首先对假设 2.3 的易满足性进行了测试.

试验 1 (假设 2.3 的易满足性) 假设 2.3 的要求是集合 $\{\eta \mid A_t^\top \eta \leqslant c_t\}$ 的有界性. 由凸分析理论易知, 这一条件等价于回收锥 (recession cone) $R(A_t) = \{\eta \mid A_t^\top \eta \leqslant 0\}$ 等于单点集 $\{0\}$, 后者是容易检验的. 我们采用前面提到的文献 [42] 中的顶点枚举算法以检验 $R(A_t)$ 是否有非零的极方向, 如果没有, 则说明假设正确.

检验过程: 对给定的阶数 m 和 n, 产生大量 $m \times n$ 阶随机矩阵, 矩阵的每个元素取值统一设定在 $[-5, 5]$, 并检验其是否符合假设 2.3. 满足条件的矩阵可称为 "好" 的矩阵.

例如, 对于阶数 $m = 8$, $n = 3$, 我们测试了 2,000 个随机矩阵, 结果表明其中约有 78.5% 的矩阵是 "好" 的. 如此经过多次反复试验, 对于 $m \times n$ 阶随机矩阵, 满足假设的矩阵比例总是在 $[75\%, 85\%]$ 内, 下面是一个 "好" 的矩阵的例子:

$$A_1 = \begin{bmatrix} 0.555 & 1.079 & -4.809 & -3.416 & 4.043 & -3.366 & 0.730 & 1.843 \\ 2.049 & -3.192 & -2.293 & -0.261 & 0.864 & -1.666 & 2.237 & -3.814 \\ 2.764 & 4.881 & 2.572 & -2.886 & 2.368 & -3.165 & -0.367 & -1.216 \end{bmatrix}.$$

进一步试验表明, 如果增大矩阵阶数, 则满足假设的比例会更高. 特别是当 m 比 n 大得多时, 假设 2.3 很容易满足. 例如, 设定矩阵阶数为 $m = 15$, $n = 4$, 试验显示 "好" 的矩阵的比例可以高达 97%. 这表明, 假设 2.3 的引入是合理的. 当然, 在某些特殊情况或额外的要求下 (例如, 要求 A 是一个非负矩阵), 此时假设也可能不成立.

试验 2 (二阶段问题) 我们对一个二阶段的 DRSP 问题进行了测试. 两个阶段的测试问题的规模都设为 $m = 12$, $n = 4$ (即每个阶段的问题有 12 个决策变量及 4 个等式约束), 并令假设 2.2 中的仿射相关因子 $m_t = 4$. 数值试验所涉及的参数矩阵, 包括 A_t, c_t, B_j^t 和 b_j^t $(t = 1, 2,\ j = 1, \ldots, d)$, 都随机产生.

算法实施程序: 首先对第 2 阶段使用文献 [42] 的顶点枚举算法产生顶点集合 θ_2, 随后使用 Latin 超立方抽样 (即前述 LHS 方法) 产生第 2 阶段的样本集合. 随后执行算法第 2 和 3 步产生近似的决策成本函数 $\tilde{\mathcal{Q}}_2(\cdot)$. 最后由第 4 步得到第一阶段问题的最优解和整个问题的最优值.

为检验算法的稳定性和精确性, 设置样本容量 N_2 为从 80 到 800 的 5 种不同水平, 对每一种样本容量进行一组 20 次独立的计算试验, 每一组试验计算得到的最优解在如图 1 中分别用一个箱线图

中国知网 https://www.cnki.net

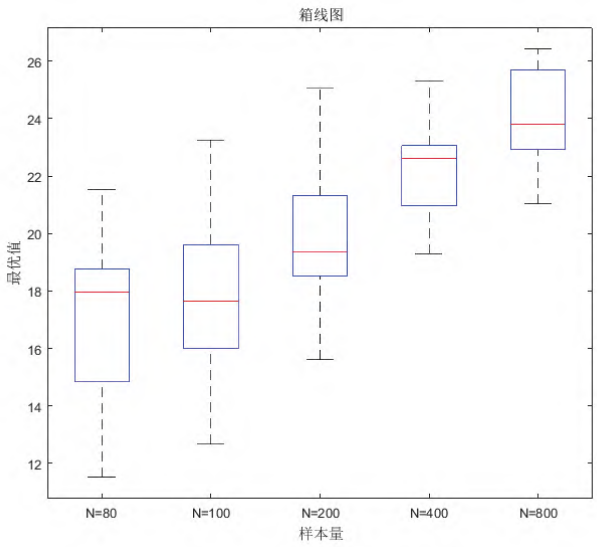


图 1　(网络版彩图) 试验 2—二阶段问题试验

(boxplot) 表述.

从图 1 中可以发现, 随着样本量容量 N_2 的增加, 箱线图的下界不断上升, 上界则相对稳定, 最优值的波动范围逐渐收窄. 同时可以注意到, 每一组 20 次试验的最大值在 $N_2 \geqslant 400$ 时已趋于稳定. $N_2 = 800$ 时箱线图整体变化幅度已不大. 因而对于本问题, $N_2 = 400$ 是一个合适的样本容量.

关于计算成本, 表 1 展示了每一组试验的平均 CPU (central processing unit) 时间, 其中第二行为包含 CVX 对输入的模型进行解释翻译的总体运行时间, 第三行则是只包含求解器运行和其他数值计算的运行时间. 由表 1 可以看出, 二者皆与样本量大致成正比. 考虑到算法最主要的部分是对每个样本点计算切平面, 我们认为这一结果是合理的. 同时这也表明, 对于大规模问题的实际计算, 应采用并行计算以节省时间.

此外, 对比第二和三行可以发现, 求解器和数值计算本身的运行是高效的, 而 CVX 平台的建模分析成本则较高. 第三行结果显示, 只包含求解器运行的 CPU 时间平均每个样本点只用 0.37 秒左右, 而包含 CVX 建模分析的 CPU 时间平均每个样本点约为 1.5 秒. 从分析数值计算成本的角度看, 求解器时间是算法效率的比较真实的反映. 同时也应看到, 如果对大规模的实际问题进行计算, 应采用某种直接调用求解器的编程方式, 减少或避免建模语言的调用, 以将计算成本控制在可接受的范围内.

试验 3 (顶点算法比较)　如前所述, 在试验 2 中, 我们对二阶段问题使用的文献 [42] 的顶点枚举算法得到集合 Θ_t 的顶点. 而对于三阶段或更多阶段的问题, 由于问题的规模, 除对叶节点仍可使用枚举算法外, 对其他各阶段应使用随机化凸包络算法以得到近似结果. 在正式对三阶段问题进行测试前, 我们先进行一个预备试验, 即在二阶段问题中比较顶点枚举算法和随机化凸包络算法的实际效果, 以验证随机凸包络方法的使用是否会带来显著的偏差.

表 1　试验 2—各组平均计算时间

样本量	80	100	200	400	800
总体时间 (秒)	124.358	151.392	305.702	598.215	1191.624
求解器时间 (秒)	32.386	39.991	78.137	153.292	307.624

中国知网　https://www.cnki.net

表 2 试验 3—两种顶点算法比较

	试验点 1	试验点 2	试验点 3	试验点 4	试验点 5	试验点 6
顶点枚举	14.6964	23.6607	12.7247	14.8258	23.3204	11.1903
随机凸包络 1	13.8357	21.3219	15.0712	13.6394	19.7277	10.8151
随机凸包络 2	14.5120	23.7920	12.8776	12.0883	22.1270	10.7807
随机凸包络 3	14.8768	19.2360	9.1681	14.5134	21.3976	11.9467
随机凸包络 4	14.3605	23.7152	12.3301	13.3212	23.7012	12.1297
随机凸包络 5	12.8152	20.2286	12.5736	13.1268	21.6990	11.6064

本试验采用的测试问题与试验 2 相同. 试验中对该问题产生 6 组试验点 (使用 LHS 抽样), 每一组试验点的样本容量为 40. 试验过程是对每一组试验点进行 6 次计算 (总共 36 次试验), 其中一次采用顶点枚举算法, 并将其得到结果作为基准, 另外 5 次则采用随机化凸包络算法进行计算. 每一次采用随机化凸包络算法计算时, 从 θ_2 中产生一个容量为 25,000 的随机样本集合, 再计算其凸包络. 试验结果在表 2 中予以展示, 其中第一行是使用顶点枚举算法所得到的最优解, 其余各行为使用随机化凸包络方法的结果.

表 2 中数据显示, 随机化凸包络方法的计算结果很稳定, 且与第一行结果十分接近. 这表明使用随机化凸包络方法的结果是可靠的, 不会导致算法运行结果的重大偏差. 因而可以在多阶段问题中使用. 此外, 本次试验中, 顶点枚举算法的平均 CPU 用时为 1.98 秒, 随机凸包络方法的平均用时为 0.62 秒, 优于穷举算法. 当样本量为 40 时, 算法的求解器时间平均为 64.506 秒.

试验 4 (三阶段问题) 接下来对一个三阶段的 DRSP 问题进行测试. 测试问题的参数设置 (m, n, r) 与二阶段问题相同, 所有参数矩阵都由随机化方式产生. 根据试验 2 的结果, $N_2 = 400$ 是一个较合适的样本容量. 为便于比较, 直接设定 $N_2 = N_3 = 400$ 为本次测试的样本容量.

首先考察计算结果的稳定性. 表 3 展示了对某随机产生的测试问题进行 12 次独立计算结果的主要统计信息, 可以看出试验结果非常稳定. 另外, 也可看出, 在同样的样本容量下, 三阶段问题计算结果的稳定性弱于二阶段问题. 我们认为这是合理的, 因为三阶段问题的复杂性相对于二阶段问题来说是显著增加的.

再观察问题复杂性和计算成本. 基于试验 2 的分析, 本次试验只记录求解器时间. 对于第三阶段问题, 算法调用顶点枚举方法, 对于测试问题中的集合 θ_3, 算法共找到 118 个顶点, 耗时约 2 秒. 另外, 算法对每个样本点需要求解一个半定规划 (semidefinite programming, SDP) 子问题. 在本次计算实践中, SDT3 求解器对每一个 SDP 子问题求解的平均 CPU 用时为 0.18 秒, 每个样本点平均耗时约 0.38 秒, 第三阶段总耗时约 151.42 秒. 以上时间与试验 2 的结果基本相同. 对于第二阶段问题, 算法调用随机化凸包络方法, 调用时对集合 Φ_2 设定的样本容量为 50,000. 由此计算产生的平均顶点个数为 492, 产生这些顶点的平均用时约 20 秒. 在此基础上, 通过 CVX 调用 SDT3 求解器对每一个 SDP 子问题求解的平均 CPU 用时为 0.82 秒, 每一个样本点耗时约 1.65 秒, 第二阶段总耗时约 660 秒. 最后, 第一阶段问题为求解一个线性规划问题, 计算耗时约 0.3 秒. 12 次测试中, 算法的求解器运行总时间平均为 832.4 秒, 如表 3 所示.

表 3 试验 4—12 次随机化计算测试的最优值统计

最小值	下四分位数	中位数	均值	标准差	上四分位数	最大值	求解器时间 (秒)
13.4887	14.0432	17.5486	16.4716	2.4791	18.7936	19.6721	832.4

中国知网 https://www.cnki.net

为考虑样本量增加的时间成本, 我们还对样本量为 800 时情形进行了单次测试. 测试中第三阶段问题总耗时约 310.165 秒, 约是样本量为 400 时的两倍, 这一规律与试验 2 基本相同. 第二阶段总耗时约 2,352 秒, 其中计算顶点耗时 32 秒, 每一个样本点求解器耗时约 2.9 秒, 本次测试求解器运行总时间为 2,664 秒, 大大超过样本量为 400 时的两倍. 这是由于第二阶段问题中, 切平面数量开始显著影响约束数量与问题规模, 同时 Θ_t 的顶点数量也大大增加, 显著影响了每个子问题的规模.

以上测试表明, 三阶段问题受到样本量增长的影响更为显著, 不再是简单的与样本量成正比, 切平面数量会明显影响问题规模. 这表明三阶段以上的问题远较二阶段问题复杂, 在实践中, 除采用并行计算等技术外, 还可进一步引入切平面削减技术等提高计算效率的工具, 以控制计算成本.

本小节对所提出的算法进行了多种数值试验, 对假设的易满足性、算法的稳定性和计算成本等进行了多方面的测试. 测试结果显示了算法的有效性, 对于中小规模的二阶段和三阶段问题, 计算成本是可接受的. 对于较大规模的实际问题, 宜结合并行计算、随机凸包络顶点算法和切平面删减等技术来降低计算成本.

实践中一个值得讨论的问题是, 如何判断得到了一个近似程度较好的解. 从算法原理上看, 解的质量主要应取决于样本点在约束区域的 "稠密" 程度, 样本点足够稠密的实际表现就是多次随机抽样的计算结果已足够稳定. 例如, 在试验 2 中, 当样本量大于 400 时, 箱线图的变化已经很小, 这表明样本量已经足够, 应能够得到较好的近似结果. 另外, 由于本算法主要利用切平面技术产生原问题下方近似, 如果能够采用某种类似于 SDDP 算法中构造上界的技术, 引入某种上方逼近, 则能够对判断解的近似程度带来极大的便利. 这是一个值得深入探讨的方面.

5 结论

本文提出了一类求解多阶段分布鲁棒线性随机规划的近似动态规划方法, 其中分布模糊集由矩约束刻画, 与多数现有文献相比, 取消了对分布离散性的要求, 这使得方法的适用范围大大拓展.

我们所提出的算法基于 Benders 分解, 主要将其用于构建各决策阶段的决策成本函数 $\mathcal{Q}_t$ 的近似函数, 从而实现动态分解的目的. 由于分布模糊集中可以包含连续分布, 且矩约束将导致转化后的模型带有锥约束, 这使得本文算法的收敛性分析比现有文献中使用的方法复杂得多. 我们使用了一个新的分析框架, 从而在上图收敛的意义下证明了各阶段的近似决策函数相对于原函数的收敛性. 最后, 我们对算法实施过程中的重要操作问题进行了详细讨论, 并对随机产生的测试问题验证了算法的有效性.

本文的工作为进一步研究如何用近似动态规划方法求解带有非离散分布的随机优化问题提供了基础. 在分布鲁棒等场景下, 如何对于多阶段问题构建类似于 SDDP 的统计上界以提高计算效率, 以及如何构造这样的上界来评估解的近似程度, 都是值得讨论的问题. 另外, 如何将本文使用的随机变量按阶段独立假设减弱为更常用的 Markov 链假设, 也值得深入探讨. 我们将在后续工作中对这些方面进行进一步研究.

致谢 感谢审稿人对本文的仔细审阅, 并提出宝贵的修改意见.

参考文献

1 Analui B, Pflug G C. On distributionally robust multiperiod stochastic optimization. Comput Manag Sci, 2014, 11: 197–220

中国知网 https://www.cnki.net

2 Ang J, Meng F, Sun J. Two-stage stochastic linear programs with incomplete information on uncertainty. European J Oper Res, 2014, 233: 16–22
3 Attouch H. Variational Convergence for Functions and Operators. Boston: Pitman, 1984
4 Bertsimas D, Sim M, Zhang M. Adaptive distributionally robust optimization. Manage Sci, 2019, 65: 604–618
5 Birge J, Louveaux F. Introduction to Stochastic Programming. New York: Springer, 2011
6 Birge J, Wets R J. Designing approximation schemes for stochastic optimization problems, in particular for stochastic programs with recourse. In: Stochastic Programming, vol. 84, Part I. Mathematical Programming Studies, vol 27. Berlin-Heidelberg: Springer, 1986, 54–102
7 Bonnans J F, Shapiro A. Perturbation Analysis of Optimization Problems. Berlin: Springer, 2013
8 Chen Y, Sun H, Xu H. Decomposition and discrete approximation methods for solving two-stage distributionally robust optimization problems. Comput Optim Appl, 2021, 78: 205–238
9 Delage E, Ye Y. Distributionally robust optimization under moment uncertainty with application to data-driven problems. Oper Res, 2010, 58: 595–612
10 Duque D, Morton D P. Distributionally robust stochastic dual dynamic programming. SIAM J Optim, 2020, 30: 2841–2865
11 Dyer M E. The complexity of vertex enumeration methods. Math Oper Res, 1983, 8: 381–402
12 Fang K T, Lin D K J, Winker P, et al. Uniform design: Theory and application. Technometrics, 2000, 42: 237–248
13 Gao S Y, Kong L, Sun J. Robust two-stage stochastic linear programs with moment constraints. Optimization, 2014, 63: 829–837
14 Georghiou A, Tsoukalas A, Wiesemann W. Robust dual dynamic programming. Oper Res, 2019, 67: 813–830
15 Guigues V. Convergence analysis of sampling-based decomposition methods for risk-averse multistage stochastic convex programs. SIAM J Optim, 2016, 26: 2468–2494
16 Hanasusanto G A, Kuhn D. Conic programming reformulations of two-stage distributionally robust linear programs over wasserstein balls. Oper Res, 2018, 66: 849–869
17 Iman R L. Latin Hypercube Sampling. Hoboken: Wiley Statistics Reference Online, 2014
18 Jiang R, Guan Y. Risk-averse two-stage stochastic program with distributional ambiguity. Oper Res, 2018, 66: 1390–1405
19 Khosravani H R, Ruano A E, Ferreira P M. A simple algorithm for convex hull determination in high dimensions. In: Proceedings of the 2013 IEEE 8th International Symposium on Intelligent Signal Processing. Piscataway: IEEE, 2013, 109–114
20 Klabjan D, Simchi-Levi D, Song M. Robust stochastic lot-sizing by means of histograms. Product Oper Manage, 2013, 22: 691–710
21 Li B, Qian X, Sun J, et al. A model of distributionally robust two-stage stochastic convex programming with linear recourse. Appl Math Model, 2018, 58: 86–97
22 Li B, Sun J, Teo K L, et al. A distributionally robust approach to a class of three-stage stochastic linear programs. Pac J Optim, 2019, 15: 219–236
23 Ling A, Sun J, Wang M. Robust multi-period portfolio selection based on downside risk with asymmetrically distributed uncertainty set. European J Oper Res, 2020, 285: 81–95
24 Ling A, Sun J, Xiu N, et al. Robust two-stage stochastic linear optimization with risk aversion. European J Oper Res, 2016, 256: 215–229
25 Ling A, Sun J, Yang X. Robust tracking error portfolio selection with worst-case downside risk measures. J Econ Dyn Control, 2014, 39: 178–207
26 Pereira M V F, Pinto L M V G. Multi-stage stochastic optimization applied to energy planning. Math Program, 1991, 52: 359–375
27 Pflug G C, Pichler A. A distance for multistage stochastic optimization models. SIAM J Optim, 2012, 22: 1–23
28 Pflug G C, Picheler A. Multistage Stochastic Optimization. Cham: Springer, 2014
29 Philpott A B, de Matos V L, Kapelevich L. Distributionally robust SDDP. Comput Manag Sci, 2018, 15: 431–454
30 Powell W B. Approximate Dynamic Programming: Solving the Curses of Dimensionality, 2nd ed. Hoboken: John Wiley & Sons, 2007
31 Rockafellar R T. Conjugate Duality and Optimization. Philadelphia: SIAM, 1974
32 Rockafellar R T, Wets R J. Variational Analysis. Berlin: Springer, 1999
33 Ruszczyński A. Handbooks in Operations Research and Management Science: Stochastic Programming. Amsterdam: Elsevier, 2014
34 Shapiro A. Analysis of stochastic dual dynamic programming method. European J Oper Res, 2011, 209: 63–72
35 Shapiro A. Topics in Stochastic Programming. CORE Lecture Series. Brussels: Universite Catholique de Louvain,

中国知网 https://www.cnki.net

2011
36 Shapiro A, Dentcheva D, Ruszczyński A. Lectures on Stochastic Programming: Modeling and Theory. Philadelphia: SIAM, 2009
37 Stein M. Large sample properties of simulations using Latin hypercube sampling. Technometrics, 1987, 29: 143–151
38 Sun J, Liao L Z, Rodrigues B. Quadratic two-stage stochastic optimization with coherent measures of risk. Math Program, 2018, 168: 599–613
39 Sun J, Yang X, Yao Q, et al. Risk minimization, regret minimization and progressive hedging algorithms. Math Program, 2020, 181: 509–530
40 Wang D, Qiao H, Zhang B, et al. Online support vector machine based on convex hull vertices selection. IEEE Trans Neural Netw Learn Syst, 2013, 24: 593–609
41 Wei Q L, Yan H. A method of transferring polyhedron between the intersection-form and the sum-form. Comput Math Appl, 2001, 41: 1327–1342
42 Wei Q L, Yan H. Generalized Optimization Theory and Models (in Chinese). Beijing: Science Press, 2003 [魏权龄, 闫洪. 广义最优化理论和模型. 北京: 科学出版社, 2003]
43 Wiesemann W, Kuhn D, Sim M. Distributionally robust convex optimization. Oper Res, 2014, 62: 1358–1376
44 Xu H, Liu Y, Sun H. Distributionally robust optimization with matrix moment constraints: Lagrange duality and cutting plane methods. Math Program, 2018, 169: 489–529
45 Xu H, Mannor S. Distributionally robust Markov decision processes. Math Oper Res, 2012, 37: 288–300
46 Yu H, Sun J. Robust stochastic optimization with convex risk measures: A discretized subgradient scheme. J Ind Manag Optim, 2021, 17: 81–99
47 Yu H, Sun J, Wang Y. A time-consistent Benders decomposition method for multistage distributionally robust stochastic optimization with a scenario tree structure. Comput Optim Appl, 2021, 79: 67–99

A Benders decomposition approximate dynamic method for distributionally robust multistage linear stochastic programming with nondiscrete distributions

Haodong Yu, Li-Zhi Liao & Jie Sun

Abstract An approximate dynamic Benders decomposition method is proposed for solving the distributionally robust multistage stochastic linear optimization problem, in which the random parameters are allowed to be nondiscrete. The random parameters are assumed to be stage-wise independent and the ambiguity set of the probability distribution is described by moment constraints. Under these assumptions, the Benders decomposition is used to construct the approximations of the cost-to-go functions of each stage so that the multistage problem can be approximately decomposed to a series of convex subproblems with conic constraints. To establish the convergence of the algorithm, a new analysis framework based on variational analysis is established, and the approximated problems are shown to have epi-convergence towards their original counterparts. Finally, the effectiveness of the algorithm is demonstrated via numerical experiments.

Keywords distributionally robustness, multistage stochastic programming, Benders decomposition, approximate dynamic programming

MSC(2020) 90C15, 90C25

doi: 10.1360/SSM-2024-0177

中国知网 https://www.cnki.net