上海交通大学硕士学位论文

电力大数据的信息价值密度评价与提升方法研究

硕士研究生：孙丰杰

学　　号：116031910081

导　　师：王承民教授

申请学位：专业学位硕士

学　　科：电气工程

所在单位：电子信息与电气工程学院

答辩日期：2019 年 1 月

授予学位单位：上海交通大学

中国知网　https://www.cnki.net

Dissertation Submitted to Shanghai Jiao Tong University
for the Degree of Master

Evaluation and Promotion Methods for the Value Density of Electric Power Big Data

Candidate：	SUN Fengjie
Student ID:	116031910081
Supervisor：	Prof. WANG Chengmin
Academic Degree Applied for：	Master of Professional Degree
Speciality：	Electrical Engineering
Affiliation：	School of Electronic Information and Electrical Engineering
Date of Defence：	Jan, 2019
Degree-Conferring-Institution：	Shanghai Jiao Tong University

中国知网 https://www.cnki.net

电力大数据的信息价值密度评价与提升方法研究

摘 要

智能电网的信息化建设积累了大量数据资源，电力系统已经进入了“大数据”时代，而如何提升电力大数据的信息价值密度是目前研究的重点。针对目前价值密度的研究存在缺乏定义和量化指标、提升手段单一导致效果有限的问题，本文围绕价值密度研究课题，从价值密度的定义，评价指标的建立，提升方法的研究，到实验仿真的验证都展开了研究分析。

本文提出了电力大数据价值密度的定义及评价指标。其中，价值密度评价指标分别从空间上内存占用、时间上运行速率两个维度计算，并且也计及了数据挖掘结果的误差。

本文分别从“脏数据”、记录、字段的维度出发，将提升价值密度的技术路线总结为“三层过滤机制”——面向数据库的“脏数据”过滤、基于改进 K-means 算法的记录“横向”过滤以及基于 FP-network 算法的字段“纵向”过滤，并针对每一层过滤进行了深入研究和阐述。

第一层过滤总结了常见的“脏数据”类型、产生原因及其相应处理方法；第二层过滤基于多初始聚类中心、多机组并行处理的改进 K-means 算法实现了记录维度的“横向”过滤；第三层过滤提出了 FP-network 算法，不仅继承了 FP-growth 算法的优点，而且只需扫描一次数据库，也方便数据库的维护和数据更新，基于该模型实现了字段维度的“纵向”过滤。

本文借助某省电力公司大数据平台，以某实际配电网的日负荷预测为例进行算例分析，验证了价值密度评价指标的有效性和改进算法的性能优势。结果表明所定义的指标能较好地反映价值密度，提出的“三层过滤机制”可以有效提升数据价值密度，特别是第二层聚类算法和第三层关联分析提升效果显著。

中国知网 https://www.cnki.net

关键词：电力大数据；价值密度；三层过滤机制；K-means 算法；FP-network 算法

中国知网 https://www.cnki.net

EVALUATION AND PROMOTION METHODS FOR THE VALUE DENSITY OF ELECTRIC POWER BIG DATA

ABSTRACT

The information construction of smart grid has accumulated a large amount of data resources, and how to improve the value density of electric power big data is the focus of current research. Study on the value density of big data lacks of quantitative evaluation index and promotion methods are limited, resulting in limited effect. In view of these problems, focusing on “value density” topic, the definition of value density, evaluation indicators, upgrading methods, and the verification of experimental simulation are studied in this paper.

This paper proposes the definition and evaluation index of the value density. And the value density evaluation indicators are calculated from the two dimensions of spatial memory occupancy and time running rate, and also take into account the error of data mining results.

Starting from different dimensions, this paper summarizes the technical route of increasing value density into a "three-layer filtering mechanism" --"dirty data" filtering for databases, record "horizontal" filtering based on improved K-means algorithm and field "vertical" filtering based on FP-network model. In-depth research and elaboration are carried out for each layer of filtration.

For the first layer of filtering, the common "dirty data" types, causes and corresponding processing methods are also summarized. For the second layer of filtering, the cluster-oriented algorithm is used to achieve record-oriented "horizontal" filtering, which is based on multi-initial clustering center and multi-unit parallel processing. For the third layer of filtering, this paper proposes FP-network algorithm. This not only inherits the advantages of FP-growth algorithm, but also only needs scanning the

中国知网 https://www.cnki.net

database once. It also facilitates data maintenance and data updates. And the field-oriented "vertical" filtering is implemented by the association analysis method.

Based on the big data platform of a provincial power company, this paper analyzes the daily load forecast of a real distribution network as an example to verify the effectiveness of the value density evaluation index and the performance advantage of the improved algorithm. The results show that the defined indicators can reflect the value density better. The proposed “three-layer filtering mechanism” can effectively improve the data value density, especially the second layer clustering algorithm and the third layer correlation analysis.

KEY WORDS: electric power big data; value density; three-layer filtering mechanism; K-means algorithm; FP-network algorithm

中国知网 https://www.cnki.net

目 录

电力大数据的信息价值密度评价与提升方法研究 ……I
摘 要 ……I
ABSTRACT ……I
第一章 绪论 ……1
1.1 研究背景和意义 ……1
1.2 国内外研究现状 ……2
1.2.1 国外研究现状 ……2
1.2.2 国内研究现状 ……3
1.3 目前研究存在的主要问题 ……4
1.4 本文主要内容 ……6
第二章 电力大数据的信息价值密度 ……8
2.1 电力大数据的特征分析、技术模型及其应用 ……8
2.1.1 电力大数据的特征分析 ……8
2.1.2 电力大数据的技术模型 ……9
2.1.3 在智能电网中的应用 ……12
2.2 价值密度定义 ……14
2.3 价值密度评价指标 ……15
2.4 本章小结 ……17
第三章 面向数据库的“脏数据”过滤 ……18
3.1 基于电力业务的数据库过滤 ……18
3.2 常见的“脏数据”类型及原因 ……19
3.3 “脏数据”处理方法 ……21
3.4 小结 ……25
第四章 基于改进 K-MEANS 算法的记录“横向”过滤 ……26
4.1 常见聚类算法比较 ……26
4.1.1 层次聚类算法 ……28
4.1.2 DBSCAN 聚类算法 ……28
4.1.3 混合高斯法 ……29
4.1.4 K-means 算法 ……30

中国知网 https://www.cnki.net

4.2 改进 K-means 聚类算法 ……32
4.2.1 改进 K-means 算法流程 ……32
4.2.2 改进 K-means 算法性能检验 ……33
4.3 算例分析 ……34
4.4 小结 ……37
第五章 基于 FP-NETWORK 算法的字段“纵向”过滤 ……38
5.1 常见关联分析 ……39
5.1.1 Apriori 算法 ……39
5.1.2 FP-growth 算法 ……40
5.2 FP-network 算法 ……40
5.2.1 FP-network 算法的网络图形式 ……41
5.2.2 FP-network 算法的矩阵形式 ……43
5.2.3 FP-network 算法的具体流程 ……43
5.2.4 与其他关联规则算法的比较 ……45
5.3 算例分析 ……47
5.3.1 实验环境和数据 ……47
5.3.2 算例分析过程 ……48
5.3.3 算例分析结论 ……53
5.4 小结 ……54
第六章 实验仿真 ……55
6.1 实验平台 ……55
6.2 “三层过滤机制”处理过程 ……57
6.2.1 面向数据库的“脏数据”过滤 ……57
6.2.2 基于改进 K-means 算法的记录“横向”过滤 ……58
6.2.3 基于 FP-network 算法的字段“纵向”过滤 ……60
6.3 价值密度评价结果分析 ……61
第七章 结论与展望 ……65
7.1 结论 ……65
7.2 展望 ……66
参 考 文 献 ……68
致 谢 ……73
攻读硕士学位期间已发表或录用的论文 ……74

中国知网 https://www.cnki.net

图 录

图 1-1 电力大数据的价值密度研究框架 ……6
图 2-1 大数据技术构架 ……11
图 2-2 MapReduce 逻辑流程 ……12
图 2-3 常见电力信息系统及对应数据总结 ……13
图 3-1 基于电力业务流程的常见电力大数据总结 ……19
图 4-1 凝聚层次聚类算法示意 ……28
图 4-2 K-Means 聚类算法示意 ……30
图 4-3 改进 K-means 聚类算法的流程 ……33
图 4-4 某电力用户日负荷曲线 ……35
图 4-5 负荷数据聚类结果 ……36
图 4-6 各种聚类算法的运行速率比较 ……36
图 4-7 各种聚类算法的 DBI 指标箱线图 ……37
图 5-1 FP-growth 算法具体示例 ……42
图 5-2 表 5-2 事务数据库对应 FP-network 网络图 ……42
图 5-3 频繁模式网络算法流程 ……44
图 5-4 更新后的 FP-network 算法网络图 ……46
图 5-5 Apriori 算法、FP-tree 算法、FP-network 算法运行效率比较 ……49
图 5-6 Apriori 算法、FP-tree 算法、FP-network 算法在不同 S_{min} 取值下的比较 ··49
图 5-7 三种算法处理不同事务数目时的最大占用内存对比分析 ……50
图 5-8 FP-network 算法的关联分析结果 ……51
图 5-9 FP-network 算法解决电力实际问题的应用流程 ……53
图 6-1 实验平台技术架构 ……56
图 6-2 实验平台实际操作截图 ……57
图 6-3 负荷数据 ……58
图 6-4 负荷数据聚类结果 ……59
图 6-5 负荷与各影响因子支持度 ……60
图 6-6 实际负荷与负荷预测结果 ……61
图 6-7 各数据集负荷预测结果相对误差 ……62

中国知网 https://www.cnki.net

表 录

表 2 -1 典型智能电网数据源 ……8
表 3-1 “脏数据”类型及相应处理方法 ……21
表 3-2 常见离群点检测方法总结对比 ……22
表 4-1 常见聚类算法总结对比 ……26
表 5-1 关联分析常见概念解释 ……38
表 5-2 数据库部分事务及对应项目集 ……41
表 5-3 FP-network 算法和 Aprori 算法、FP-growth 算法的比较 ……46
表 5-4 输电线路故障分析事务数据库 ……47
表 5-5 离散、变量化的数据库 ……48
表 5-6 FP-network 算法挖掘的强关联规则 ……51
表 6-1 天气描述定量化处理 ……58
表 6-2 负荷与各影响因子支持度 ……60
表 6-3 支持向量机模型参数 ……61
表 6-4 各数据集负荷预测相对误差及价值密度评价指标结果 ……62
表 6-5 不同采样频率数据集的价值密度评价指标对比 ……63

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景和意义

数据是事物内部机理特性或关联特性的一种外在表现，研究人员可以根据数据来认识事物。大数据是近年来出现的研究热点概念，广义上讲，大数据不仅是指日益增长的海量数据，还包含了处理海量数据的技术方法和解决问题的新思维方式[1]。大数据不仅仅是具有庞大体量的数据集合，也是一系列对数据处理和利用的理论、方法与技术的总和，还包括对数据分析挖掘和价值提取利用的思想。从哲学的角度上，大数据是一种新的认识论。它适合认识统计规律和混沌规律，依据足够的样本到全量数据，适合于挖掘关联关系。从数学的角度上，无论是数据预处理使用的运筹学，数据分析使用的统计学，还是深度分析挖掘或机器学习的算法和模型使用的计算数学和微分方程理论等，数学知识和思想都贯穿其中。

2011 年，国际著名咨询公司麦肯锡率先研究了大数据的全球趋势、关键技术等五个方面，阐述了大数据对未来人类政治、经济、生活各个方面的重大作用。这是社会进入“大数据”时代的一个重要标志，此后世界各国都掀起了研究大数据的热潮。2012 年，在瑞士召开的达沃斯论坛上，学者们达成共识，数据已经被社会认可为一种新经济资产类别[2]，并探讨了如何在新的数据产生方式下利用数据转化成社会效益。2012 年 3 月，美国政府发布了报告《大数据研究和发展倡议》，将发展大数据上升到国家战略的高度。2013 年 11 月，中国率先在互联网、金融等行业开展大数据研究，在政府有关部门倡议下，与 Alibaba、Baidu 等 11 家企业签署了大数据战略合作框架协议。

能源互联网的发展使得本就复杂的电力信息系统变得更加庞大，电力行业也进入了“电力大数据”的时代。并且随着智能电网的不断发展，将会有更加复杂、更加精细的信息系统和采集测量装置接入到电力系统中，可以预见未来的电力数据量将呈现爆炸式增长，因此如何应用电力大数据是电力行业发展的重要驱动力。

与大数据在金融及互联网方面的应用和研究相比，大数据在智能电网中的应用相对处于比较初始的阶段。智能电网数据信息模态千差万别，包括各种结构化、半结构化和非结构化数据，数据口径不一，加工整合困难，这对数据管理技术和水平提出了极高的要求。目前的电网数据管理大多依赖人工进行，自动化水平低，数据管理也局限于数据的采集、传输和存储，没有提升到对数据价值进行挖掘的

中国知网 https://www.cnki.net

高度，这极大的局限了电网的自动化、信息化水平。

电力大数据价值密度低的问题已经严重制约了电力行业大数据应用的发展。借助大数据技术，电力公司迫切希望利用自身积累的数据优势转化为公司发展、改革创新的推动力，但是大数据体量大、价值密度低，现阶段难以投入工程实践，或者利用性价比较低、严重浪费资源。因此，如何评价和提升价值密度是电力行业全面发展大数据应用的重要基础，是目前研究亟需解决的问题。

1.2 国内外研究现状

1.2.1 国外研究现状

目前，电力大数据在国外的科学研究和工程应用主要集中在欧美等发达国家，主要是国外大学、研究机构、IT 企业和一些电力公司。IT 企业如 IBM 公司、Oracl 公司等都已经发布了大数据白皮书，甚至专门针对智能电网的大数据分析系统已经被开发成功，后续将逐步进行商业推广应用[2]-[4]。

在澳大利亚，智能电表已经实现了广泛配置。根据采集到的大量精准用户数据，电力公司可以挖掘气象温度、光伏发电量、天气状况、异常事件发生时刻与持续时间、电压值等不同维度数据间的关联关系，进而得到了分布式建筑光伏发电、天气状况等不同因素对低电压事件的规律和影响[5]。

美国研究机构自 2008 年期就已经启动了智能电力大数据的研究项目，公布的主要内容包括“未来电网计划”、“太平洋西北智能电网示范项目”、“能源系统集成设备”、“输电网现代化示范项目”等研究。此外，洛杉矶市区已经成功绘制了基于街区的交互式在线用电信息地图，并投入了使用。用电信息地图整合了电力用电信息、城市人口信息、街道建筑信息等多种数据源，实现了实时的用电能耗数据展示，更加便捷直观，有助于分析不同地区能耗情况，从而做出相关投资决策 [6]-[9]。

如何精准预测用户的用电行为一直是各国电力行业研究的重点，大数据技术提供了处理海量数据的并行计算架构，能大大提高数据的实时在线并行处理能力。基于此技术的应用，法国电力公司早已开展了针对电力行业的研究计划，已经实现了对海量电力用户信息数据的瞬时、在线处理分析，并极大提高了短期用户负荷数据预测的精度[10][11]。

欧洲国家的风电发电比例相对比较高，随着风机装机容量的不同增加，风力发电的不确定性和随机性一直是影响用电安全的重要问题，电力大数据技术的发

中国知网 https://www.cnki.net

展为解决风力发电预测问题提供了新的技术手段。IBM 公司已经研发并商业化推广了一款大数据处理平台，是根据电力行业具体应用场景和行业特性所设计的大数据处理工具，可以实现对海量风电装机、发电信息，天气信息，地理信息，环境温度湿度信息等等数据的快速处理。通过对这些数据的挖掘处理，极大地提高了风电的发电量，大大延长设备的平均寿命。根据丹麦研究结构的成果显示，该平台总体数据量达到惊人的 6PB，借助平台能够在短短几小时内确定风力发电机的安装位置，并且避免了依赖于传统经验的积累，方案设计更加科学合理[12]。

综上所述，国外对于电力大数据的相关研究和应用已取得了一些成效。但是总体上，现有研究成果主要集中在示范项目，没有形成相应研究体系，尚处于起步和探索阶段。

1.2.2 国内研究现状

2012 年，国家电网公司公布了 Q/GDW 703-2012《国家电网公司公共信息模型（SG-CIM）》，这一标准模型是各个电力信息系统数据融合的重要参照对象[13]。2013 年 3 月，《中国电力大数据发展白皮书》是国内电力行业研究电力大数据热潮的开始[14]，电力系统进入了“电力大数据”时代。

2013 年起，电网公司开展了一系列电力专业领域的大数据相关技术研究，应用涉及电网的各个环节，包括输变电运行检修、电力通信、调度决策支持、智能配电网、用电管理与能效节约等，各个省电力公司也纷纷探索在生产运行中如何应用大数据技术[15][16]。2013 年 6 月，国家电网公司制订“统筹规划、协同推进、统一平台、规范建设”的总体策略，并组织编制形成《大数据应用研究报告》。

电力大数据技术在电网中已经得到了初步的应用，文献[17][18]总结分析了现阶段电力大数据相关应用的机遇、挑战和发展前景，并展望了多个典型应用场景，主要包括分析用户用电行为、监测电力计量误差、搭建数据统一平台、电力负荷预测和实时查询在线数据等方面。文献[19][20]实现了基于 Hadoop 大数据平台的用户用电行为分析。文献[21][22]针对电能计量系统的误差估计问题，分别利用基于大数据的动态时间弯曲理论和多参量退化模型展开研究。文献[23]为了提高数据处理存储性能，设计了随时间变化不断地调整数据量和负载的均衡策略，并根据这种策略，开发了一种前置通信平台的大数据存储机制，可以显著提高数据存储的效率和性能。在存储平台技术发展的基础上，还经常需要对海量数据进行查询搜索等操作，许多文献对电力大数据查询技术进行了研究，对传统数据库的查询搜索技术做出了改进和创新，比如基于分级分区策略的容错存储查询优化方法[26]，

中国知网 https://www.cnki.net

进一步提高了对电力大数据的处理能力。

关于电力大数据的价值密度，国内相关研究还比较匮乏，主要集中在数据预处理阶段属性约简方法等方面。计算机、信息工程等其他行业率先对大数据价值密度问题展开了相关研究，大多结合 MapReduce 并行计算模型，对传统的属性约简算法进行改进，提出了一些适合大数据的新方法，比如浓缩布尔矩阵并行属性约简算法[25]、多决策表的区间值全局约简算法[26]以及多粒度粗糙集模型[27]等等。电力行业结合电气自身特点，也取得了一定的研究成果。文献[28]基于 MapReduce 模型，改进了传统的属性约简算法，结合粗糙集理论提出了一种大数据集相对正域势的算法，实现了对风电海量数据的处理。文献[29]针对并发事件的独立性，对基于偏序约简的大数据预处理方法进行了研究，并应用于光伏电厂、变压器和变电站的监测、故障数据的处理。还有一些研究通过 Spark 等计算架构，提高了属性约简的效率[30]。

总体上，国内电力行业目前仍处于电力大数据的研究热潮中，许多研究问题亟待解决，还存在很大的研究空白和广阔的研究空间。特别是本文的研究课题，关于电力大数据价值密度的相关研究，包括定义、评价指标、提升方法机制等方面都比较匮乏。

1.3 目前研究存在的主要问题

随着智能电网的发展，电力行业进入了“电力大数据”时代，一方面带动了电力业务的发展，但是另一面带来了新的挑战。电力大数据亟需解决的一个问题就是如何提升其价值密度。但是目前对于电力大数据价值密度的研究还比较匮乏，电力行业尚未对价值密度形成规范定义，国内外现有研究对价值密度的评价也只是停留在模糊定性的“高/低”层面上，并没有相应定量评价的指标。

比较类似的数据质量研究已经形成一个较完整的学科，其评价指标包括：准确性、世系、结构一致性、完整性、合理性、可识别性等等[31][32]，但没有涉及数据价值密度领域。此外，还有部分研究将大数据作为资产，对其进行经济学范畴的价值评估[33]-[36] ，提出了收益现值法、博弈方法、市场价值法、重置成本法等评价方法，但都没有从信息角度衡量价值密度。

除缺少相关定义及评价指标外，价值密度的提升方法研究也存在一些问题，特别是最常用的聚类和关联分析方法，在处理电力大数据时都有一定的不足。

对于聚类分析，K-means 算法在常见的聚类算法中具有较快的计算速度、良好的可扩展性，比较适用于数值型聚类[37][38]。因此，许多大数据研究提出了基于

中国知网 https://www.cnki.net

Hadoop、spark 等并行计算平台的 K-means 算法[39]-[43]，大多采用 MapReduce 并行计算框架，比单机的计算性能有明显提高。但是其并行平台只是作为提高计算效率的工具，K-means 算法受初始聚类中心的影响较大，不良的初始聚类中心可能导致聚类效果很差的问题没有得到改善，难以满足电力大数据的需求。

对于另一类数据约简的常用方法——关联分析，是通过挖掘海量数据对象，检索数据库中存在的频繁项集合，从而分析不同对象之间关联性或得到蕴藏在数据中的关联规则[44]。其中，Apriori 算法是最早广泛使用的关联分析方法，FP（frequent pattern）-growth 算法及其各种变式则是目前最常用的关联方法。但是这两种方法在处理电力大数据时，都存在一些问题和不足：

Apriori 算法原理简单，通过数据库地不断遍历，统计各个项目集的数目，不断缩小检索的范围。但是缺点十分明显，其算法原理要求在检索频繁项的过程中不断存储大量的侯选对象，处理电力大数据 GB 甚至 TB、PB 级的体量时存储、计算负担极大；此外，大规模数据库的多次遍历带来了极大的资源浪费，对计算机性能是极大的挑战[45]。

FP-growth 算法是针对 Apriori 算法的不足所提出的的[46][47]。改进的优点主要包括：（1）避免了类似 Apriori 算法大量候选集合的存储，FP-growth 算法是通过建立有向树状结构的频繁模式树 FP-tree 进行关联分析；（2）FP-growth 算法在寻找频繁 1-项集只和建立频繁模式树时各扫描一次数据库，检索数据库次数的降低大大减少了计算负担，提高了计算效率。但是 FP-growth 算法在处理电力大数据时也有存在一些问题：（1）FP-growth 算法虽然不需要存储候选集，但是相应地需要对频繁模式树递归更新，处理海量数据时仍然十分复杂；（2）每次数据库更新都需要重新建立频繁模式树，然而电力大数据的特点是时刻产生新数据、不断更新信息，FP-growth 算法的可扩展性较差，难以满足实际需求。

实际上，国内外学者已经提出了一些适用于电力大数据的数据约简改进方法[28]-[30]。这些算法可以一定程度地提升电力大数据的价值密度，但是一方面从根本上缺少对价值密度的明确定义和评价指标，因此难以量化分析和比较这些方法的提升效果；另一方面，这些研究大多仅从属性约简的维度分析，对价值密度提升作用有限，缺少对其他维度提升方法的研究和探讨，比如从记录的角度等等。此外，现有研究仅仅通过单一技术手段起到的提升效果十分有限，对于电力大数据价值密度的研究尚未形成相关体系，缺乏提升价值密度全面可行的技术路线。

中国知网 https://www.cnki.net

1.4 本文主要内容

鉴于现有研究存在的问题和空白，本文的总体研究思路如下图所示：

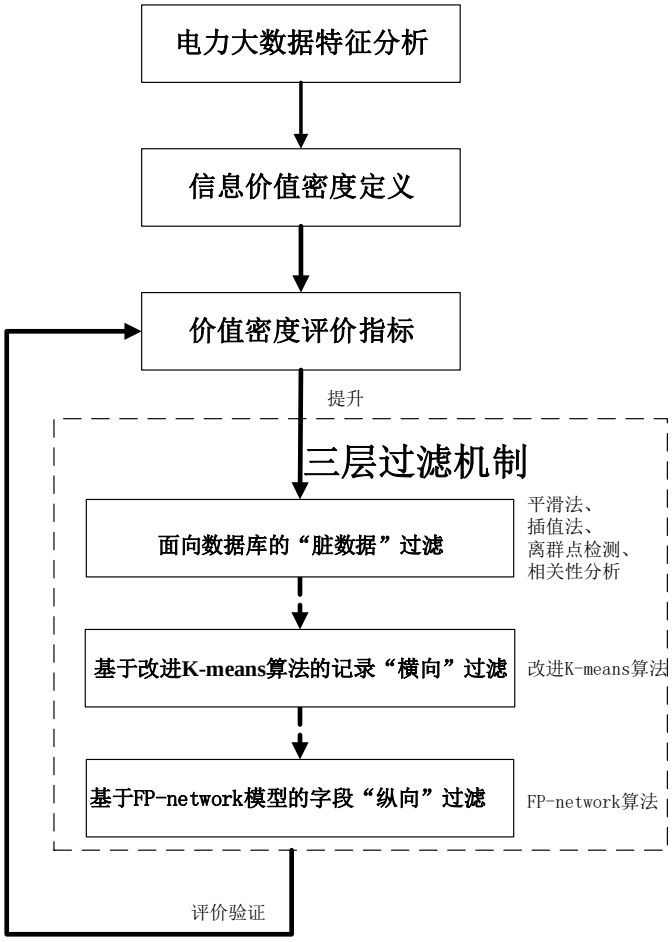


图 1-1 电力大数据的价值密度研究框架

Figure 1-1 Research Framework of Value Density for Electric Power Big Data

对于数据库，通常将表的行称为“记录”，是属性值的一个集合；将表的列称为“字段”，表征数据的属性。以电力用户负荷预测为例，假设已将所有原始数据汇总成一张“表”，通常“记录”是按日期排列的一条条用电数据；“字段”应当包括与负荷相关且满足预测要求的属性，如气温、平均风速、平均湿度、平均降水、日类型（周一至周日）、节假日（国庆节、中秋节等）、天气状况、地区平均GDP、人口数目、气压等等。

在对电力大数据特征分析和电力信息系统发展现状总结的基础上，本文首先对电力大数据价值密度做出相关定义，提出量化评价的方法。然后分别从数据库、记录、字段等不同维度出发，研究如何提升电力大数据的价值密度。在文中将相关提升方法的技术路线总结为“三层过滤机制”——面向数据库的“脏数据”过

中国知网 https://www.cnki.net

滤、基于改进 K-means 算法的记录“横向”过滤、基于 FP-network 算法的字段“纵向”过滤。

本文所作的主要工作包括以下内容：

（1）针对目前研究的空白，本文提出了电力大数据价值密度的定义及评价指标。其中，评价指标分别从空间上内存占用、时间上运行速率两个维度计算，并计及了数据过滤造成的信息损失等误差。

（2）针对第二层过滤 k-means 算法的自身缺陷，本文提出了基于多初始聚类中心、多机组并行处理的改进 K-means 算法，弥补其太过依赖于初始聚类中心导致聚类效果差的问题，提高了算法的收敛性，也一定程度的提高了算法效率。

（3）针对第三层过滤关联分析方法处理电力大数据时的不足，本文提出了新的关联分析方法——FP-network 方法，将 FP-growth 算法的频繁模式有向树状图简化为一个无向网络图，在计算机中以矩阵形式进行处理分析。FP-network 方法弥补了 FP-growth 算法的缺点，更加适合处理电力大数据。

（4）结合（2）、（3）所改进的聚类算法和关联算法，本文对提升价值密度的方法进行了总结比较，补充完善了工程实践的相关技术路线，在本文中将其定义为“三层过滤机制”——面向数据库的“脏数据”过滤、基于改进 K-means 算法的记录“横向”过滤、基于 FP-network 算法的字段“纵向”过滤。

（5）本文借助某省电力公司大数据平台，以某实际配电网为例进行算例分析，验证了本文所提出的价值密度评价指标的有效性和改进算法的性能优势。

中国知网 https://www.cnki.net

第二章 电力大数据的信息价值密度

要研究如何提升电力大数据的信息价值密度，应当首先对价值密度作出定义，并提出量化评价的指标作为后续研究的基础。因此，本章的主要工作是基于电力大数据的特点，提出价值密度的定义和评价指标。后续章节将在此基础上，围绕如何改善评价指标进行研究分析。

2.1 电力大数据的特征分析、技术模型及其应用

一方面，随着智能电网的发展和信息化时代的建设，越来越多的测量、采集、通信设备嵌入到电力系统中，电力数据呈现指数级增长，亟需处理这些数据的技术方法；另一方面，电力公司迫切渴望利用自身数据积累优势转化为企业发展管理的驱动力，主动寻求对于海量数据处理创新的方法。电力行业已经进入了“电力大数据”时代。

2.1.1 电力大数据的特征分析

电网在运行过程中每时每刻都在产生着大量数据，这些数据主要来自于各种监测、计量、和控制系统，同时天气、气候、用户、交通、环境、社会经济、政策法规等外部数据也与电网的发展和运行密切相关。除此之外，为支撑电网规划、运行、建设，电力公司及其科研机构积累了大量的仿真计算、试验、实验和监测数据，这些数据为电网规划和运行决策提供重要的依据。

根据内部结构，电力大数据可以分为结构化数据和非结构化数据。电力大数据中大部分都是结构化数据，并且随着电网信息数据库更加规范统一，结构化数据正在迅速增长。视频、图像等数据则属于非结构化数据类型。

电力系统中常见的信息系统主要包括：生产管理系统、PMS 系统、SCADA 系统、GPS 系统、配电自动化系统、OMS（调度管理）系统、营销业务管理系统、ERP 系统、95598 客服系统、经济社会类数据等。这些数据源的总体状况如表 2 -1 所示。

表 2 -1 典型智能电网数据源
Table 2 -1 Typical Smart Grid Data Sources

编号	数据源系统	数据格式
1	配电自动化	结构化数据

中国知网 https://www.cnki.net

2	生产管理系统	结构化数据
3	地理信息系统	半结构化/非结构化数据
4	调度自动化系统	结构化数据
5	用电信息采集	结构化数据
6	负荷控制系统	结构化数据
7	负荷监测系统	结构化/半结构化数据
8	营销业务应用系统	结构化数据
9	电能质量监测系统	结构化/半结构化数据
10	电网气象信息系统	非结构化数据
11	95598 客服系统	非结构化数据
12	ERP 系统	结构化数据
13	地区社会经济数据	结构化/非结构化数据

这些数据源共同构成了“电力大数据”集，涉及电网中的调度、运检、营销等多个业务和环节。这些数据具有大数据典型的“4V”特征——体量大（Volume）。；类型多（Variety）；速度快（Velocity）；价值密度低（Value）。

由于电力行业的自身特性，电力大数据还具备以下特征：

（1）数据源多样：智能电网接入或开发了多套信息系统，比如 PMIS、SCADA、用电采集系统、D5000 系统等等，这些都是电力大数据的数据源。

（2）空间广泛性：智能电网的监测装置遍布整个电网，从用户侧的智能电表，到各条馈线、各个等级的变压器和变电站中的各类测量系统，都产生并存储着大量数据。

（3）时间跨度大：电力大数据的时间跨度尺度多样，采样频率从各类波形数据的 us、测量单元数据的 ms、SCADA 系统的 s、智能电表数据的 min 到设备检测的 h 甚至“天”，相差非常大。

（4）信息实时性：许多电力大数据实际都是流数据，为了便于电力公司在线确定电网实时运行状态，许多业务应用要求对电力大数据进行实时处理。

2.1.2 电力大数据的技术模型

大数据的研究方法和解决问题的思维方式，与传统方法相比有很大的差异。传统研究方法是以机理为核心。主要分为以下四个步骤。

（1）假设、简化

根据大量的先验知识，尽可能深入的了解研究对象的物理本质，在此基础上建立物理试验模型或数学模型。通常需要对条件或环境做出诸多的假设，将复杂

中国知网 https://www.cnki.net

的情况进行适当的简化。

（2）基于机理建立物理或数学模型

在建立物理模型时，往往需要做出一定的等值和微缩处理；在建立数学模型时，可能需要线性化、离散化等处理；在参数选择时，在缺少详细数据的情况下，通常选取一些典型参数进行后续计算。

（3）实验、仿真、计算

根据建立的物理或数学模型，通过实验仿真，测试或者计算相关指标、性能、状态等数据。

（4）机理解释

针对实验研究、仿真和计算结果，做出机理性解释。有时为了支持机理解释的正确性，需要对仿真计算结果进行重现科学实验

传统研究方法物理概念清晰，是比较成熟的系统方法论。然而，随着科学研究的不断深入，传统研究方法很多时候难以满足新场景，例如复杂事物难以直接研究作用机理，庞大系统建模试验比较困难等[48]。大数据研究方法则是不考虑研究对象的机理或物理原理，基于收集大量数据并实现多源数据融合的基础上，利用黑盒子思想，只研究输入和输出之间的相关关系。大数据研究方法强调如果将大量的个体数据组成一个有机的整体，将零散或孤立的数据加以整理成整体会增加数据的价值；相反，将整体的数据割裂开来，会削弱得到数据的实用价值。

大数据方法可以对当前数据和多维宏观时间相关特征进行综合分析，与传统的研究方法并不冲突，可以相互补充完善，进一步推动科研体系建设，促进科研方法的发展。

目前经典的大数据处理模型是由 Usama Fayad 设计的多阶段处理模型，主要技术框架包括数据的采集、存储、处理、分析挖掘、可视化、安全与隐私保护等诸多环节，各环节采用的技术和分析方法也不相同，具体如图 2-1 所示。

中国知网 https://www.cnki.net



图 2-1 大数据技术构架

Figure 2-1 Technology Architecture of Big Data

如图 2-1，技术框架中的核心技术包括：

（1）数据采集

电力大数据具有数量巨大、复杂多样、分散放置等特征，这给数据抽取、转换及加载过程带来了极大的挑战。为确保电力大数据整个采集过程完整高效，需要根据数据类型及特征选择相应的采集策略，主要可分为流式数据采集、数据库采集及文件采集三种。

（2）数据存储

电力大数据需要根据数据特点选用合适的数据存储方式，保证具有足够的存储容量和高效的查询索引性能。常用方法是构建易于拓展的分布式存储系统，随着数据规模的扩大，动态增加存储节点。针对不同的数据类型，采用不同的存储引擎，同时还需要构建各存储系统之间的连接器，实现数据快速融合。

目前常用的大数据存储和管理方案包括 HDFS（Hadoop 分布式文件系统），Tachyon，QFS（Quantcast 文件系统）和 ClusterFS 等。高容错性，可扩展性，高并发性和低成本的存储服务器设备是最广泛需求的大数据存储系统。

（3）数据处理

大数据处理技术为了提高处理数据的速度和改善应对大规模数据库的能力，通常采用 MapReduce 等方式进行并行处理，相对于单机而言处理能力大大增强。

其中，MapReduce 是通过计算机集群分布式并行处理，从而大大提高单机处

中国知网 https://www.cnki.net

理性能的一种技术方法。

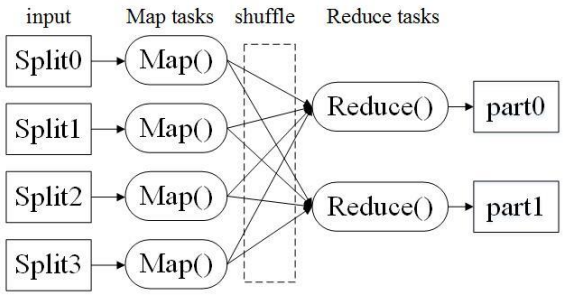


图 2-2 MapReduce 逻辑流程

Figure 2-2 Logical flow chart of MapReduce

如上图 2-2 所示，MapReduce 并行计算技术流程主要分为五个步骤： Input；Map； Shuffle； Reduce； Output[48]。

此外，电力大数据的应用范围十分广泛，根据实际电力业务需求，对时间处理的要求以及本身电力信息系统的数据量大小也各不相同，根据处理时间的要求将业务划分为在线、进线和离线处理。

（4）数据分析挖掘

由于电力大数据具有体量大、种类多、速度快、来源广等特征，传统的数据分析算法很多已不再适用，需要采用新的数据构架、数据分析方法或对现有的数据分析方法进行改进。例如，经常需要结合云计算技术，将大数据集的挖掘任务划分为多台计算机并行处理以提高效率。或者基于 Hadoop、Spark 等并行分布框架改进传统的挖掘算法，适应电力大数据的处理需求。

（5）数据安全与隐私保护

电力大数据包括电网安全运行数据、电网调度数据、电力企业运营管理数据以及用户用电行为等隐私数据，这些数据在大数据构架的逻辑层面上高度集中，随之而来的即是数据安全与隐私问题，因此需要改进和扩展现有的安全技术，以保证大数据安全性和隐私性的要求。

2.1.3 在智能电网中的应用

本文总结了常见的电力信息系统及其对应的数据信息，如图 2-3 所示。智能电网嵌入的信息系统多种多样，总体上可分为两大类：电力公司自身的信息系统和电网外部的信息系统。其各自包含的具体系统名称，及其对应的具体数据信息内容详见图中说明。

中国知网 https://www.cnki.net

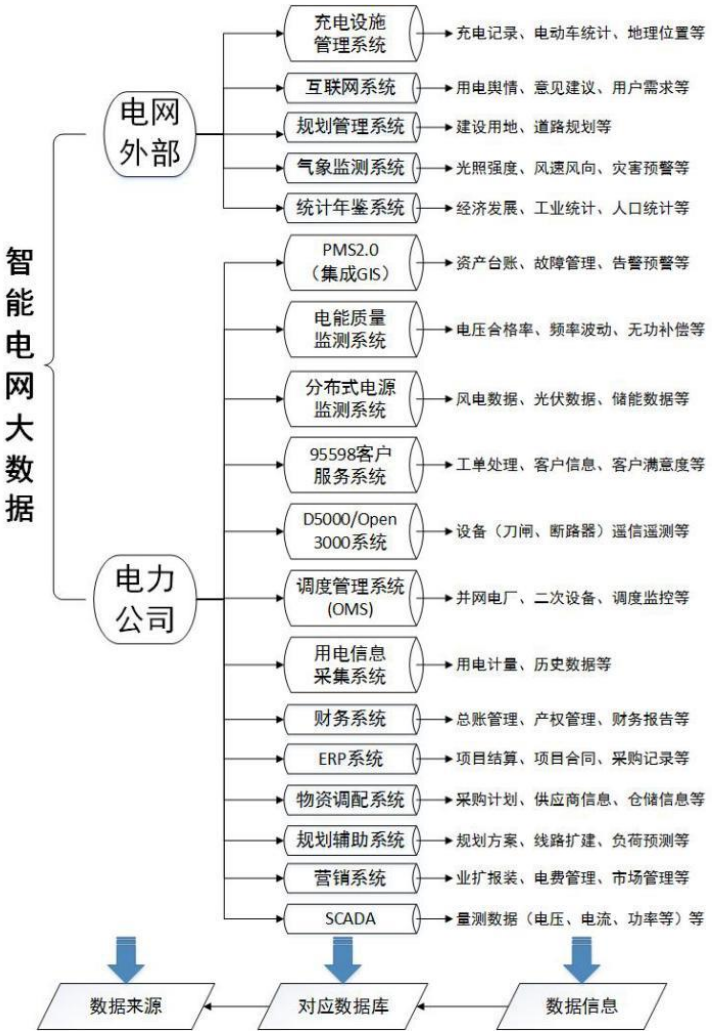


图 2-3 常见电力信息系统及对应数据总结

Figure 2-3 Summary of common electric power information system and corresponding data

电力大数据在智能电网中的应用十分广泛，已经逐渐延伸到电力公司的各个业务领域。根据业务需求分为三大类应用：面向电力用户服务、面向电力公司管理、面向政府决策等[50]。具体应用包括但不限于：

（1）电力用户画像构建

基于用电信息系统的电力用户数据和 GIS 系统、气象监测系统等环境、天气信息等，可以分析电力用户的用电信息，构建用户画像，实现对用户用电行为的短期精准预测。在此基础上，可以将预测结果用于调度系统提前规划调度方案，或者用于营销系统针对不同用户画像量身定制相应的营销策略，提升服务质量。

（2）电力设备故障分析

安全性是电力系统运行的重中之重。由于电力系统的设备分布范围广，种类多，相对故障比例较低，传统的分析方法大多依赖于历史经验的积累。借助电力

中国知网 https://www.cnki.net

大数据技术，可以有效整合各个地区、各个电压等级的全部设备故障数据，通过数据挖掘技术分析设备故障的影响因素，一方面可以有效避免相关类似故障的再次发生，为设备生产厂商提供有效意见反馈；另一发面，可以实现设备故障的预测判断，提前安排检修计划，提高电力系统的安全性。

（3）防窃电行为分析

电网运行中的窃电行为屡禁不止，既给电网的安全性造成了威胁，也严重损耗了电力公司的经济效益。由于窃电行为具有人为主观引导，行为模式多种多样，传统识别监测方法难以有效监控。通过电力大数据技术，可以挖掘窃电行为与用电信息数据如电压、电流、相位等信息之间的联系，通过监测数据的变化判断是否发生窃电行为。

（4）可能再生能源精准预测

随着可再生能源发电比例的不断提高，由于自身特性，可再生能源发电具有很大的不确定性和随机性，严重影响电力系统的用电安全，电力大数据技术的发展正可以为解决可再生能源发电预测问题提供新的技术手段。通过收集大量历史数据，包括发电数据、气象数据、温度数据、光照数据、风力数据、地理信息数据等等，挖掘数据间的规律信息，依赖于海量数据可以建立更为精准的可再生能源出力预测模型。

2.2 价值密度定义

如第一章所述，国内外对于大数据的价值密度研究比较缺乏，尚未有研究做出比较严谨的定义。这无疑严重影响到后续对于提升价值密度方法的相关研究。因此，本文在此尝试作出相关定义。

考虑到 2.1 节电力大数据的特性，本文还参考了其他领域对相关价值密度的定义。例如经济学中，将商品的价值密度定义为单位重量商品的价值；计算机科学中将作业的价值密度定义为作业在 t 时刻的价值与作业的剩余执行时间的比值[51]。

需要强调的是，不同于某些研究，本文所研究的“数据价值”，不是将数据作为资产的经济价值，而是数据本身所含的信息价值，即数据信息对于实现特定业务目标的贡献和作用。

本文作出相关定义如下：对于特定的一个业务目标，给定原始数据集 S，若数据集 S_1（$S_1 \subseteq S$）是满足结果精度要求的最小规模子集，则称 S_1 是 S 的有（或高）价值数据集；相应地，称 S_2（$\complement_S S_1$）为 S 中的无（或低）价值数据集。

中国知网 https://www.cnki.net

即以数据集 S_1 进行数据挖掘得到的结果，与以全部数据集 S（$S_1 \subseteq S$）进行数据挖掘得到的结果的误差 e 满足精度要求 ε，且以 S_1 的任意一个真子集进行数据挖掘时其结果误差都将不再满足 ε。

数据的价值密度定义为有（或高）价值数据集 S_1 所占原始数据集 S 的比重。这个比重既包括空间上内存占用的比重，也包括时间上运行速率的比重，2.3 节将详细研究这部分。

2.3 价值密度评价指标

提出价值密度评价指标时应该遵循以下原则：

（1）指标的合理性：充分考虑指标的内涵和物理意义，所定义的指标能够全面反映电力大数据的价值密度。

（2）指标的可测性：所定义的指标可以通过电力大数据计算或度量，所需数据要规范、易收集。

（3）指标的可比性：所定义的指标应该是客观的数值，能够实现不同数据集的直接比较。

（4）指标的独立性:同一层次的指标不应具有包含关系，尽量减少彼此间的相关性。

考虑上述原则，本文从空间、时间两个维度提出了评价指标。

将 VD_space 定义为原始数据集 S 的空间价值密度评价指标，反映了有价值数据集 S_1 相对 S 的内存占用情况，可以量化评价电力大数据的空间价值密度。

将 VD_time 定义为 S 的时间价值密度评价指标，反映了 S_1 相对 S 的运行速率情况，可以量化评价电力大数据的时间价值密度。

指标公式如下：

$$VD_space = \frac{memory_S_1}{memory_S} \times (1 - e_S_1) \times 100\%,\ e < \varepsilon \tag{2-1}$$

$$VD_time = \frac{time_S_1}{time_S} \times (1 - e_S_1) \times 100\%,\ e < \varepsilon \tag{2-2}$$

式中，

$memory_S$：表示 S 占用内存的大小；

$memory_S_1$：表示 S_1 用内存的大小；

$time_S$：表示 S 进行数据挖掘的计算时间；

$time_S_1$：表示 S_1 进行数据挖掘的计算时间；

中国知网 https://www.cnki.net

e_S：表示 S 进行数据挖掘的结果与实际结果的误差，这部分误差主要与挖掘模型和算法有关；

e_S_1：表示 S_1 进行数据挖掘的结果与实际结果的误差。这部分误差既与挖掘算法的固有属性有关，可近似认为与 e_S 相等；也与 S_1 相较于 S 的部分信息损失有关，可近似用 $(1-\frac{1-e_S_1}{1-e_S})$ 表征。

将 VD 定义为综合价值密度评价指标，是 VD_space 和 VD_time 的均方根，综合考虑了时间、空间两个维度。

$$VD=\sqrt{\frac{VD_space^2+VD_time^2}{2}},\ e<\varepsilon \tag{2-3}$$

对于误差参数有多种计算方式，针对不同的应用场景，可以具体分析，选择合适的计算方式。但应注意，若需要比较价值密度指标的大小，比较对象应该选取同一种误差计算方式。

以日负荷预测为例，$y(i)$ 和 $\hat{y}(i)$ 分别表示第 i 时刻的实际负荷和预测结果，预测误差通常可以采用以下计算方式：

$$e_1=\frac{1}{n}\sum_{i=1}^{n}\left|\frac{y(i)-\hat{y}(i)}{y(i)}\right|\times 100\% \tag{2-4}$$

$$e_2=\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left|\frac{y(i)-\hat{y}(i)}{y(i)}\right|^2}\times 100\% \tag{2-5}$$

e_1 表示平均误差；e_2 表示均方根误差，对日负荷预测结果中某时刻特大或特小误差更加敏感。可根据不同业务需求的实际情况具体选择误差评测指标。

根据上式(2-1)-(2-3)，本文提出的价值密度评价指标具有以下特点：

（1）依赖性：价值密度指标依赖于特定的业务目标，如果面向不同的业务需求，即使同一数据集也很可能有不同的指标计算结果。

（2）非线性：价值密度指标考虑了内存占用、运行速率和误差的非线性关系以及时间、空间维度间的非线性关系。

（3）易计算：价值密度指标简单直观，计算方便，适合工程实践推广。

（4）多维度：式(2-1)考虑了空间维度，与数据库结构、数据编码方式、存储规则等有关；式(2-2)考虑了时间维度，与挖掘算法的效率等有关。实际应用可能会侧重于不同维度，比如对于实时性要求较高的电力业务会更加关注数据集的时间价值密度指标。

中国知网 https://www.cnki.net

2.4 本章小结

本章首先总结分析了电力大数据的特征，既包括大数据的共性特征，也包括电力行业的自身特性；并对智能电网的“数据-系统-业务”之间的关系进行了梳理，介绍了大数据技术在智能电网中的常见应用场景。

在此基础上，本章对电力大数据的价值密度做出了相关定义，并提出了相应的评价指标，既包括空间价值密度评价指标，也包括时间价值密度评价指标，以及综合评价指标。这些指标可以从不同的维度衡量大数据的价值密度，为后续章节研究如何提升价值密度提供量化比较的基础。

中国知网 https://www.cnki.net

第三章 面向数据库的“脏数据”过滤

根据第二章相关定义和评价指标，提升电力大数据价值密度的关键在于如何从海量基础数据中提取对电力业务目标有贡献的数据集，理想结果应当是从原始数据集 S 中提取出有（或高）价值数据集 S_1，然后利用这部分数据进行挖掘分析。本章是“三层过滤机制”中的第一层——面向数据库的“脏数据”过滤。

3.1 基于电力业务的数据库过滤

如第二章所述，本文对电力大数据的价值密度作出的定义及提出的评价指标都是依赖于电力业务目标的，如果电力业务发生了变化，相应的价值密度指标的结果也会发生变化。这是数据集信息价值的固有属性所导致的，即脱离了应用场景来讨论数据集的信息价值是没有任何意义的。

智能电网的实际运行过程中应用场景多种多样，具体电力业务种类繁多。同样的，电力大数据来源广泛，电网内部和电网外部的许多信息系统都是其数据源。如果不区分信息系统，对所有的电力业务都采用全部的电力大数据集，一方面将耗费大量的财力物力，资源浪费严重；另一方面，庞大的数据集含有太多的无用数据，反而会对数据挖掘的结果造成不良影响，影响挖掘算法的准确性。

因此，首先应该基于不同的电力业务，对电力大数据集进行数据库过滤。结合电气背景知识，选择与该电力业务密切相关的数据库和信息系统，过滤掉其余的无关数据库。如图 3-1 所示，图中总结涵盖了几乎所有常见的电力信息系统、所对应的主要业务部门及信息系统所包含的数据信息。如来源于电力公司的电力大数据，按业务流程分为两大类：生产业务部门和管理业务部门。其中，生产业务部门包括主要的运检、调度、营销等部门； 管理业务部门主要包括财务部门、物资部门、发策部门等等。各个业务部门有主要负责维护管理的电力系统，如运检部门主要负责维护管理 PMS 系统、分布式电源信息采集系统等等；发策部门主要负责运维规划辅助系统等。但同时，各部门根据电力公司的业务流程，互相之间合作协助，存在着数据信息之间的传递。如运检部门需要整理相关运行、检修等信息，为发策部门作出规划决策等提供参考依据。

中国知网 https://www.cnki.net

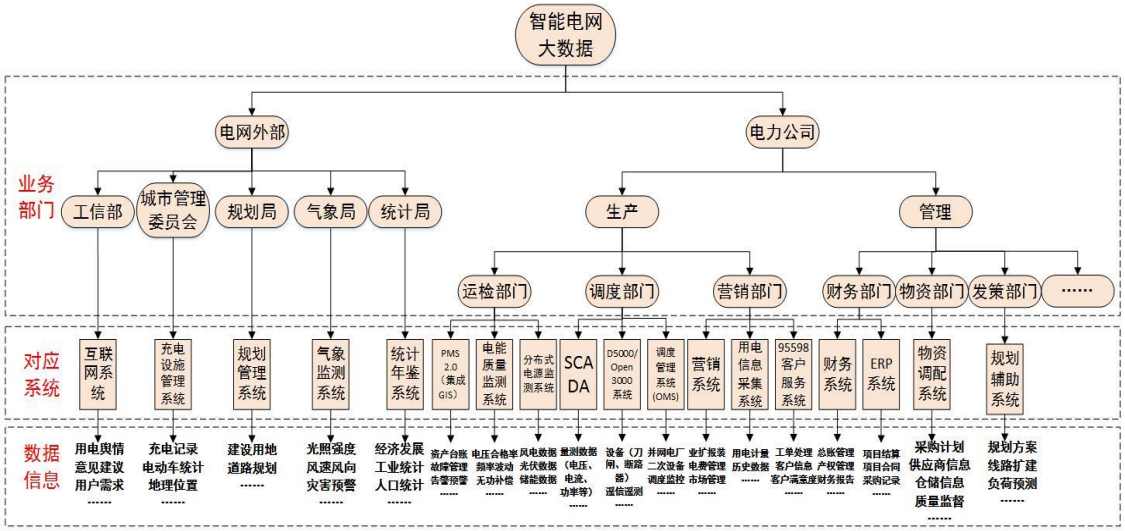


图 3-1 基于电力业务流程的常见电力大数据总结

Figure 3 -1 Summary of Common Big Data Based on Power Business Process

图 3-1 总结了信息系统与包含的源数据、信息系统与对应的电力业务之间的联系，可以实现基于电力业务的数据库过滤，为后续电力大数据研究建立了良好的基础。假设此时电力业务是故障分析，根据图 3-1 所示，电力系统的故障分析数据集通常是由来源于运维管理系统、PMIS 系统、SCADA 系统，地理信息系统等数据库的故障设备信息、保护动作状态、二次系统监测数据、时间地点、环境等数据组成。因此，在分析故障时预先有针对地仅提取相关信息系统的数据库，过滤掉其他繁多的信息系统数据库，大大提高了电力大数据的价值密度，避免分析庞大冗余的无关数据库，节省了计算资源，提高了处理效率。

此外，各个信息系统之间存在一定的交互关系，对于某些数据的采集既可能共享一个数据源头，也可能有彼此独立的采集装置。如用电信息采集系统采集了所有电力用户的用电信息，采集范围涵盖了负荷管理系统、配变监测系统和集中抄表系统。同时，用电信息采集系统也为其他信息系统和业务部门提供用电数据信息，进而实现负荷监测、防窃电、预购电分析、有序用电、台区线损分析、计量在线监测的多种功能。因此在开展相关业务时，这部分数据应当从数据源头——用电信息采集系统提取。

3.2 常见的“脏数据”类型及原因

电力大数据由于信道错误、远程终端故障、干扰信号影响等会产生一定的“脏数据”，显然这部分数据不仅降低了价值密度，甚至会影响最终业务结果的准确性。因此，“脏数据”的过滤是十分有必要的。

中国知网 https://www.cnki.net

由第二章分析可知，电力大数据来源广泛、体量庞大，通常不同电力部门只维护本部门的信息系统，部门间存在信息壁垒。但随着信息系统应用的不断深入，各电力部门跨专业业务协同与信息共享需求日益增强，特别是电力公司的精益化管理和创新发展对业务协同、流程贯通提出了更高要求。因此，大数据技术通过搭建云计算平台，将来源于不同信息系统的数据进行处理整合，形成统一的数据仓库，方便统一存储、查询、管理和处理。

整合后的电力统一数据仓库不可避免地存在“脏数据”。这既可能是由源信息系统导致，如信息通道出错导致采集错误数据；也可能是在整合数据仓库时产生“脏数据”，主要是跨专业业务协同与信息共享不足造成数据规范不统一、数据冗余等等。

本节对常见的“脏数据”类型及其成因进行了分析汇总，主要包括以下内容：

（1）数据缺失

数据缺失主要分为两种情形：缺少某些日期或对象的记录；某条记录里缺少字段。造成的原因可能有很多种，如采集系统故障导致出现空值，某段时间设备检修缺少数据，某些偏远地区可能没有配备采集装置和信道，或者人为误操作导致数据缺失等。

数据缺失造成的影响不言而喻，一方面缺少某些关键信息可能导致最终结果的偏差；另一方面，数据缺失可能会造成数据的离散性，导致某些算法无法收敛。

（2）数据异常

目前电力信息系统还不成熟，许多系统在采集输入数据后不进行异常检测判断，直接写入后台数据库，很可能会造成数据异常，具体包括多种情形：

a）数据输入格式错误。比如将日期格式输入成了字符串，信息系统无法识别此输入而出现乱码或预先值等。

b）数值超出范围。这主要是由于采集装置出错造成的错误数据，如节点电压、电流值明显超出电压等级等。

c）数据的正负性异常。这部分主要是由于采集装置安装方向颠倒导致测量顺序相反等造成，如电源的输出功率测量为负值等等。

（3）数据不同步

由于采集装置遍布各个电压等级，从变电站、线路，到用户，不同源的数据间存在着采集频率不一致的问题，如常见的采集频率有 24 点/日、48 点/日、96 点/日等；此外，由于设备的投入和退出，许多数据的采集起始和截止时间也不同，这也影响了数据的信息价值密度。

中国知网 https://www.cnki.net

（4）数据冗余

数据冗余主要是由于电力大数据来源广泛，不同信息系统之间缺少明确的测量分工和信息共享，存在许多重复内容，具体包括异名同义、同名异义、字段重复、记录重复等情形。

a）异名同义主要是由于不同信息系统之间没有严格统一的数据规范，导致汇总时同一字段有多种不同格式。比如有的记录输入为北京，有的输入 BJ，有的却输入 beijing，但系统无法识别 BJ 和 beijing 是同一事物。此外，由于电力公司的历史更新等问题，即使同一套信息系统，也经常存在不同的数据输入规范。

b）同名异义是指不同信息系统间由于缺少统一的数据字典，使用了同一种编号或代码分别指代了不同含义的事物。

c）字段、记录重复同样由于上述原因，导致汇总后的数据仓库存在完全相同的字段或者记录，这类“脏数据”相对而言比较容易发现和处理。

（5）信息冗余

不同于数据冗余，信息冗余是指数据本身虽然正确，但却不可用的情形。比如地址写成“上海市闵行区东川路”，但在分析“区”级别的区域时，还要把“闵行”提取出来。另外，对于某些数值类型数据，在分析具体问题时并不关心其本身数值的大小，而是更关心其所处的区间和范围，通常要对其进行二值化、哑编码等处理。

3.3 “脏数据”处理方法

基于 3.2 节对于常见“脏数据”类型和成因的总结，本节针对不同类型的“脏数据”，给出具体的处理方法，从而实现电力大数据价值密度的提升。

表 3-1 “脏数据”类型及相应处理方法

Table 3-1 "Dirty data" type and corresponding treatment methods

“脏数据”	具体含义	方法
数据缺失	数据为空集	替代法、 平滑回归法
数据异常	格式不一致、超出量纲、正负值异常等等	离群点检测、 数据拟合
数据不同步	不同记录的采集频率不同；不同字段的采集频率不同；不同次采集起止时间不同	插值法、 强制同步法
数据冗余	异名同义、同名异义、字段重复	数据集成、

中国知网 https://www.cnki.net

信息冗余	定量特征只关心所属区间；定性特征需要处理	相关性分析 对定量特征二值化、对定性特征哑编码

表 3-1 总结了现有研究常用的处理方法。其中，对一些比较重要的处理方法具体解释如下。

（1）替代法

处理缺失数据，通常两类方法：a）不将空值纳入分析范围，但这种做法会减少分析的数据量。b）需要对其进行补值。最简单的补植方法就是相近数据填充，如采用中位数、均值、众数等统计数据替代。本文考虑到电力大数据的特点，采用邻近数据的平均值来替代，即选取空值数据的前 N 个有效数据与后 N 个有效数据组成替代窗口，计算其平均值。

（2）离群点检测

通常情况下，离群点多是噪声信息，然而在一些应用中，这些罕见的数据却可能蕴藏着更大的价值信息。

本文总结比较了常用的离群点检测方法，结果如下表所示。

表 3-2 常见离群点检测方法总结对比

Table 3-2 Summary and comparison of common outlier detection methods

离群点检测方法	方法介绍	优点分析	缺点分析
基于统计的方法	建立概率分布模型，低概率分布的数据即离群点	原理简单易懂，便于实现	需要明确数据集的分布；难以检测高维数据集
基于邻近性的方法	利用距离等参数量化数据间的邻近性，邻近性差的数据即离群点	简单；直观；具有全局阈值	不适用于大数据集；对参数的选择敏感
基于密度的方法	低密度区域中的数据对象即离群点	能够处理多密度数据集	计算量较大，较难处理大规模数据集；阈值的选择依赖于尝试和经验
基于聚类的方法	对数据对象聚类，评估其属于该簇的程度	高效；可以处理大规模数据集	检测效果依赖于聚类算法的聚类质量

总体上，基于统计的检测方法，由于统计学原理的应用条件，适合已知数据集分布的检测。基于聚类的检测方法也常与密度方法相结合，如 DBSCAN 聚类算法本身就是利用密度作为聚类簇的依据。因为聚类方法比较高效，本文选取基于聚类的离群点检测方法。

中国知网 https://www.cnki.net

（3）相关性

本文利用相关性分析，可以检验电力大数据集中的异名同义、重复字段、重复记录等数据冗余，从而实现过滤，提升了信息价值密度。

本文总结介绍统计学和数据挖掘领域常用的相关性分析方法：

a）协方差

协方差的计算公式如下：

$$\mathrm{cov}(X,Y)=\frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{n-1} \tag{3-1}$$

协方差可以衡量不同对象间的相关性，协方差大于零表示对象间正相关，即变化趋势相同；反之，协方差小于零表示负相关。协方差等于零表示不相关，即对象相互独立。但是协方差无法评估对象间的相关程度，只能定性地地反映。

b）相关系数

相关系数可以反应数据对象间的相关密切程度，其取值区间为[-1 1]。“1”表示两个对象完全线性相关，“-1”表示两个对象完全负相关，“0”则表示两个对象不相关。以下是相关系数的计算公式。

$$r_{xy}=\frac{s_{xy}}{s_x s_y} \tag{3-2}$$

其中r_{xy}表示相关系数，S_{xy}表示协方差，S_x表示X的标准差，S_y表示y的标准差。下面分别是S_{xy}、S_x和S_y的计算公式：

$$s_{xy}=\frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{n-1} \tag{3-3}$$

$$s_x=\sqrt{\frac{\sum(x_i-\bar{x})^2}{n-1}} \tag{3-4}$$

$$s_y=\sqrt{\frac{\sum(y_i-\bar{y})^2}{n-1}} \tag{3-5}$$

相关系数法弥补了协方差法的缺陷，可以通过数值大小评估相关程度的强弱。并且数值的正负还可以反映正负相关。因此，本文在处理数据冗余“脏数据”类型时，选择相关系数法。

（4）无量纲化

电力大数据的种类繁多，特别是对于指标类数据，不同的指标数据有时难以直接比较和处理。因此，根据电力业务需求，有时需要对数据进行无量纲化处理。

本文总结了几种常用的无量纲化方法。

a）直线型无量纲化方法

中国知网 https://www.cnki.net

线性无量纲化方法假设转化后的无量纲值与实际值之间是线性关系，主要有以下几种计算公式：

i.极值法

利用数据的极值（极大值或极小值）计算数据的无量纲值 x_i^* 。

计算公式主要有：

$$x_i^* = \frac{x_i}{\max x_i} \tag{3-6}$$

$$x_i^* = \frac{\max x_i - x_i}{\max x_i} \tag{3-7}$$

$$x_i^* = \frac{x_i - \min x_i}{x_i} \tag{3-8}$$

$$x_i^* = \frac{x_i - \min x_i}{\max x_i - \min x_i} \tag{3-9}$$

ii.标准差法

其计算公式为：

$$x_i^* = \frac{x_i - \bar{x}}{s} \tag{3-10}$$

其中，

$$s = \sqrt{\frac{1}{n}\sum (x_i - \bar{x})^2} \tag{3-11}$$

b）折线型无量纲化法

折线型无量纲化计算公式如下：

$$x_i^* = \begin{cases} 0 & x_i < a \\ \dfrac{x_i - a}{b - a} & a \le x_i < b \\ 1 & x_i \ge b \end{cases} \tag{3-12}$$

c）曲线型无量纲化方法

曲线类型的无量纲化方法适用于实际值和无量纲值是非线性关系。根据不同的对应关系，其计算公式也很多，如：

i.升半 r 型分布

$$x_i^* = \begin{cases} 0 & 0 \le x_i \le a \\ 1 - e^{-k(x-a)} & x_i > a \end{cases} \tag{3-13}$$

中国知网 https://www.cnki.net

ii.半正态型分布

$$x_i^* = \begin{cases} 0 & 0 \le x_i \le a \\ 1 - e^{-k(x-a)^2} & x_i > a \end{cases} \tag{3-14}$$

式中，k，a，b 为曲线待定参数。

3.4 小结

本章主要介绍了提升电力大数据价值密度的“三层过滤机制”中第一层过滤——面向数据库的“脏数据”过滤。本章主要对智能电网中常见的“脏数据”类型和产生原因都进行了总结分析，并针对不同类型的“脏数据”给出了相应的处理方法，具体处理过程可详见第六章算例分析。

中国知网 https://www.cnki.net

第四章 基于改进 K-means 算法的记录“横向”过滤

第三章从数据库、“脏数据”的维度对电力大数据进行过滤，在此基础上，本章的主要内容是“三层过滤机制”的第二层——面向记录的“横向”过滤。聚类算法本身的应用十分广泛，如 3.3 节利用聚类算法进行离群点检测。本章基于改进的 K-means 聚类方法，将从记录的维度进行“横向”研究分析，进一步提升电力大数据的信息价值密度。

4.1 常见聚类算法比较

许多电力大数据记录都表现出相类似的规律和特性，导致信息熵比较小。第二层过滤基于聚类算法，可以选取具有相同规律和“共性”的簇，既可以提取业务目标所需求的特征簇，也可以对相同特征的簇进行简化，从而提高了价值密度。本文比较分析了常见的聚类算法[52]-[54]，总结如下。

表 4-1 常见聚类算法总结对比

Table 4-1 Comparison of common clustering algorithms

聚类原理	常见算法	优点	缺点
基于层次的聚类	BIRCH、DIANA、Chameleon 等算法	算法简单易懂；可处理局部簇	需要存储相似度，不适合处理大规模数据；扩展性较差，不能实现增量式聚类；时间复杂度高
基于划分的聚类	K-means 算法及其各类变体算法	可实现增量式聚类，适合大规模数据	对初始簇中心敏感；对异常点比较敏感
基于密度的聚类	DBSCAN 算法及其各类变体算法	能检测异常点；适合发现不同形状的簇	对存在密度相差较大的簇聚类效果较差；需要指定聚类最小对象数及邻域个数
基于网络的聚类	STING、CLIQUE 等算法	处理速度快	无法处理分布混乱的数据；易导致维数灾难；精确性较低
基于模型的聚类	高斯混合、SOM 等算法	软聚类，结果以概率形式表示	执行效率低
基于模糊的聚类	模糊 C 均值等算法	服从正态分布的对象聚类效果较好；能检测孤岛点	算法收敛性较差；聚类效果依赖于初始聚类中心

中国知网 https://www.cnki.net

聚类算法常用“距离”来度量数据对象的相似性，常用的距离计算方法主要包括：

（1）闵可夫斯基(Minkowiski)距离

$$dist(X,Y)=(\sum_{i=1}^{n}|x_i-y_i|^p)^{\frac{1}{p}} \tag{4-1}$$

特别地，

a)当 p=1，（4-1）式是曼哈顿距离(Manhattan)

$$M_dist=\sum_{i=1}^{n}|x_i-y_i| \tag{4-2}$$

b)当 p=2，（4-1）式是欧式距离(Euclidean)

$$E_dist=(\sum_{i=1}^{n}|x_i-y_i|^2)^{\frac{1}{2}} \tag{4-3}$$

c)当 p 为无穷大，（4-1）式是切比雪夫距离(Chebyshev)

$$C_dist=\max_i|x_i-y_i| \tag{4-4}$$

一般情况下欧式距离比较常用；当数据量出现扁平化时，常用切夫雪比距离。

（2）余弦相似度

假设两个样本有 2 个特征向量 a,b，则这两个样本的夹角余弦相似度公式如下：

$$cos(\theta)=\frac{a^T\cdot b}{|a||b|} \tag{4-5}$$

（3）KL 距离（相对熵）

$$D(P||Q)=\sum_x P(x)log(\frac{P(x)}{Q(x)}) \tag{4-6}$$

（4）杰卡德相似系数(Jaccard)

适用于样本只有（0,1）的情况，又叫二元相似性。具体计算公式如下：

$$J(A,B)=\frac{|A\cap B|}{|A\cup B|} \tag{4-7}$$

$$dist(A,B)=1-J(A,B) \tag{4-8}$$

（5）Pearson 相关系数

$$\rho_{XY}=\frac{Cov(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}} \tag{4-9}$$

$$dist(A,B)=1-\rho_{XY} \tag{4-10}$$

中国知网 https://www.cnki.net

4.1.1 层次聚类算法

层次聚类算法通常分为凝聚型层次聚类和分裂型层次聚类。凝聚型层次聚类自下而上，首先将所有数据点本身看作聚类结果，然后找出距离最近的两个簇将它们合为一个，不断重复以上步骤直到达到预设的簇的个数。反之，分裂型层次聚类开始时将全部数据点视作一个整体，然后自上而下筛选排除不符合的数据点，不断进行分裂。

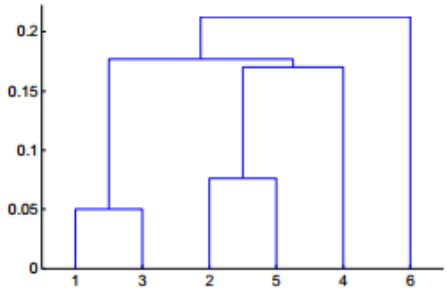


图 4-1 凝聚层次聚类算法示意

Figure 4-1 Schematic diagram of agglomerative hierarchical clustering algorithm

以采用最小距离的凝聚层次聚类算法为例说明，如上图 4-1 所示，具体步骤如下：

(1) 首先将图中编号 1-6 的数据点当做 6 个独立的簇，分别计算它们两两之间的距离。

(2) 距离最小或者小于阈值的数据点合并为一个新簇，如图中编号为 1 和 3、2 和 5 的数据点。

(3) 根据（2）更新划分的聚类结果，重新计算簇两两之间的距离。

(4) 计算结果若满足预设的聚类条件，停止运行算法；否则，转步骤（2）。

层次聚类算法虽然原理简单，但是计算量特别大，不适合处理大规模数据。

4.1.2 DBSCAN 聚类算法

DBSCAN 聚类算法，基本思想是通过是否紧密相连来判断样本点是否属于同一个簇，经常用于消除“脏数据”中的离群点数据。根据数据点的密度大小，DBSCAN 聚类算法将数据点依次分为三类：核心点；边界点；噪音点。

基于以上数据点的划分，算法具体实现流程为：

（1）首先，确定最小半径 *eps* 和邻域中的最小数量点 *MinPs*。

（2）给定密度的定义，确定数据集中每个聚类的核心点，边界点和噪音点。

中国知网 https://www.cnki.net

（3）最后，将数据集划分成几个簇。通常，包含最少元素的簇就是数据集的噪音点数据。

其中，DBSCAN 聚类算法的聚类效果依赖于两个重要参数的选取：最小半径 *eps* 和邻域中的最小数量点 *MinPs*。最小半径的大小影响聚类结果的最终簇数，理论上选取过大或过小的极端情况是全部对象聚类为一个簇或每个数据点单独是一个聚类簇。邻域中的最小数量点 *MinPs* 的选取是划分核心点、噪声点的重要依据，选取数值过小会导致将数据对象误判断为噪声点。

因此，DBSCAN 聚类算法的显著优势是有对抗噪音（可发现离群点）的能力，可以发现任意形状的样本；但是缺点是计算密度单元的计算复杂度大，不能很好反应高维数据，以及高维数据难以定义密度等。

4.1.3 混合高斯法

高斯混合模型（GMM）首先假设数据点服从高斯分布，用两个参数——均值和标准差来描述簇的形状。

GMM 算法的具体流程如下：

（1）给定聚类簇的数目，并随机初始化每个簇的高斯分布参数。即使是从一个较差的高斯分布开始，算法也能很快对其优化。

（2）给定每个簇的高斯分布，计算每个数据点属于特定簇的概率。

（3）基于这些概率，计算一组新的高斯分布参数，使得能最大化簇内数据点的概率。

（4）重复迭步骤（2）和（3），直到收敛，即分布在迭代中基本再无变化。

GMM 方法有两个很重要的优点。由于设置了标准偏差参数，GMM 聚类结果的簇可以呈现任何椭圆形状，而不是被限制为圆形，比 K-means 算法更灵活。实际上，K-mean 算法可以视作是 GMM 的一个特殊情况，即每个簇的协方差在所有维度上都接近 0。

其次，由于 GMM 使用了概率，每个数据点可以有多个簇。因此，如果一个数据点位于两个重叠的簇的中间，可以简单地定义它的类，即属于类 1 的概率是百分之 X，属于类 2 的概率是百分之 Y，即 GMM 支持混合类情况。

4.1.4 K-means 算法

K-mean 算法是最经典的基于划分的聚类算法，其他划分聚类算法多为 K-means 算法的变式。通常采用距离作为度量相似性的指标，即数据点距离越接

中国知网 https://www.cnki.net

近，则相似性越大，越可能被划分为同一个簇。

K-means 算法的核心数学公式为：

$$J(c,u)=\sum_{i=1}^{k}\sum_{x\in C_i}\left\|x^{(i)}-u_c(i)\right\|^2 \tag{4-11}$$

式中，各样本点到质心的距离平方和设为 $J(c,u)$；k 为聚类簇数；C_i 为第 i 个聚类簇；$u_c(i)$ 为聚类簇 C_i 的质心。

K-means 算法的目标是将各样本点到质心的距离平方和 $J(c,u)$ 调整到最小。如果当前 $J(c,u)$ 并不是最小值，保持所有簇的质心点 $u_c(i)$ 不动，然后为了减小 $J(c,u)$，调整每个数据点的所属类簇。同理，数据点的所属类簇不变，也可调整每个类簇的质心点，从而达到减小 $J(c,u)$ 的目的。

K-means 聚类算法的示意如图 4-2 所示，其中灰色点为质心点，可以清楚地看到质心点在聚类过程中的不同移动。

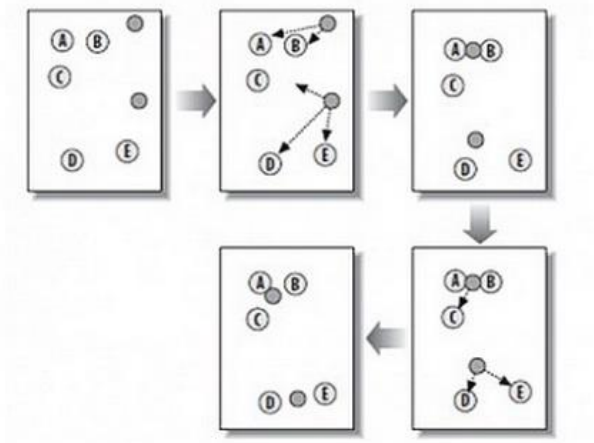


图 4-2 K-Means 聚类算法示意

Figure 4-2 Schematic diagram of K-Means clustering algorithm

具体算法流程包括：

（1）在数据中随机选择 K 个质心点（图 4-2 图中 K=2）。

（2）求所有数据点到 K 个质心点的距离，距离小于阈值的数据点移至质心点。

（3）将质心点移到其类群的中心。

（4）重复上述步骤（2）和（3），直到质心点不再移动或者达到设定的最大迭代次数。

基于上述分析，可以分析 K-means 算法的相关计算性能：

中国知网 https://www.cnki.net

（1）时间复杂度：$O(tKmn)$

其中，t 表示聚类的迭代次数，K 表示聚类结果数目，m 表示原始数据的记录数目，n 表示原始数据的字段数目。

（2）空间复杂度：$O((m+K)n)$

其中，各个变量含义与上述时间复杂度相同。

K-means 算法需要预先给定聚类簇数目，即 K 值。针对如何有效的确定 K 值，本文总结了常用的几种方法：

（1）可视化数据

最简单但十分有效的方法是利用可视化技术处理数据，通过简单地观察分析，选取合适的 K 值。

（2）与层次聚类结合[55]

结合层次凝聚的方法选取适当的簇数目，并且可以得到一个粗略地初始聚类，进而利用 K-means 算法来改善聚类效果。

（3）轮廓系数法[56]

选择不同的 K 值，计算其轮廓系数，选择轮廓系数较大的 K 值。

$$s(i)=\frac{b(i)-a(i)}{\max\{a(i),b(i)\}} \tag{4-12}$$

式中，*S(i)*表示数据点 *i* 的轮廓系数值；*a(i)*是数据点 *i* 与同簇内其他数据点的平均距离，称为凝聚度；*b(i)*是数据点 *i* 与最近簇中的所有样本的平均距离，称为分离度。

除此之外，还有一些其他方法，如 Canopy 算法[57]、贝叶斯信息准则方法（BIC）、肘部法则等，都能为 K-means 算法有效地确定 K 值。

基于上述分析，K-means 算法适合处理数值型聚类，并且易于扩展至并行化计算框架，是目前最常用的聚类方法之一。但是，传统的 K-means 算法仍然存在一些不可避免的缺陷：

（1）K-means 算法对初始聚类中心十分敏感，聚类效果很大程度上依赖于初始聚类中心的选择。

（2）属于硬聚类，每个样本点只能属于一类。

（3）对异常值免疫能力差。

（4）对团状数据点聚类效果好，对于带状数据点聚类效果较差。

中国知网 https://www.cnki.net

4.2 改进 K-means 聚类算法

4.2.1 改进 K-means 算法流程

由 4.1 节分析可知，传统的 K-means 算法相较于其他算法速率较快、有良好的可扩展性，但是在处理电力大数据 GB 甚至 TB 级别的体量时仍然差强人意。目前许多大数据方面的研究提出了基于 Hadoop、spark 等并行计算平台的 K-means 算法，这大大提高了单机的聚类计算效率。但是并行化计算平台的引入并没有解决 K-means 算法另一个重要问题：太过依赖于初始聚类中心，导致聚类效果较差甚至大规模数据集时难以收敛。

因此，本文提出了一种基于多初始聚类中心、多机组并行处理的改进 K-means 算法。不仅仅将并行计算机组作为提高计算速率的工具，其核心思想是通过多台机组并行处理，机组间互相交叉迭代，尽可能削弱初始聚类中心对于结果的影响。具体的算法流程如图 4-3 所示，主要步骤如下：

（1）选定 *m* 台计算机组建集群系统，将 *n* 个输入复制 *m* 份，分发给 *m* 台计算机。

（2）选取 *m* 组 K-means 聚类算法的初始聚类中心，派发给各个计算机节点。

（3）每个计算机节点独立执行一次 K-means 聚类：

a)获取计算机 CPU 的内核数 *c*;

b)将 *n* 个输入分成 *c* 份，派发给各个内核；

c)各内核中的数据分别与聚类中心进行相似度计算；

d)汇总各内核中的数据与聚类中心的相似度矩阵，得到每个计算机节点上 *n* 个输入和矩阵中心的相似度矩阵；

e)根据相似度矩阵将输入归入各类簇，并根据新的聚类情况更新聚类中心；

f)当完成预设迭代次数（或类间距离）时，结束本次聚类。

（4）将类间距离最大的一组聚类结果作为当前最优解，若当前最优解已满足预设要求，则得到聚类结果；否则采用类似粒子群算法的移动规则，产生新的 *m* 组初始聚类中心，转步骤（2）。

中国知网 https://www.cnki.net

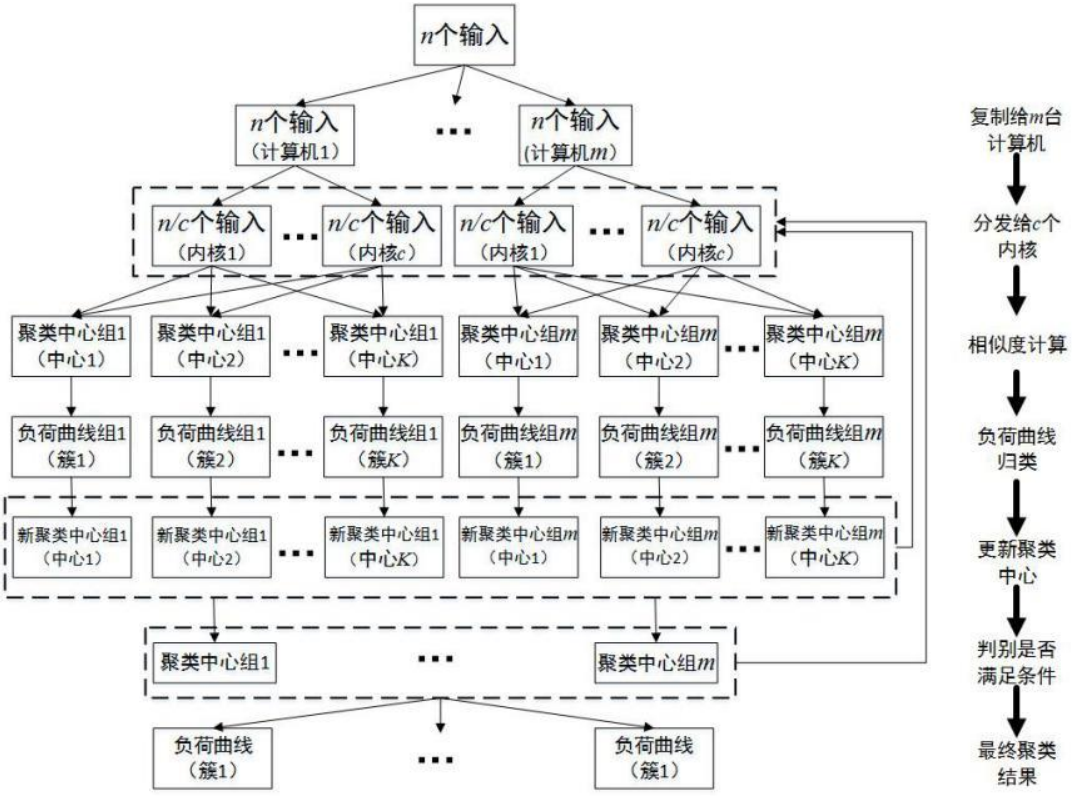


图 4-3 改进 K-means 聚类算法的流程

Figure 4-3 Flow chart of improved K-means clustering algorithm

因此，本文提出的改进 K-means 算法在保留 K-means 算法优点的基础上，弥补了其依赖初始聚类中心的不足，大大改善了聚类的效果，提高了收敛性。

此外，改进 K-means 算法也一定程度地提高了算法的计算效率。由 4.1.4 节分析可知，聚类计算的复杂性与迭代次数、聚类簇数、特征属性数目、记录数目等有关。通过对数据复制拆分，表面上每台计算机所做聚类分析的计算量几乎与传统 K-means 算法相当，但是 k-means 算法太过依赖于初始聚类中心，尤其是处理大量数据时收敛性较差，导致迭代次数较多，相应增加了计算量。而本文改进的 K-means 算法通过多初始聚类中心、多机组处理、多核心拆分数据实现不同机组间互相交叉迭代，每次迭代的修正效果要优于 K-means 算法，从而迭代次数更少，计算量更小，更加适用于处理规模大、种类多的电力大数据。

4.2.2 改进 K-means 算法性能检验

为进一步检验改进 K-means 聚类算法的性能，本文分别从运行速率、聚类有效性两方面进行测试。

其中，运行速率可以采用 CPU 的运行时间作为指标衡量，聚类的有效性通常

中国知网 https://www.cnki.net

要考虑紧凑度和分离度。紧凑度是衡量同一个聚类簇内部的数据点之间是否足够“紧凑”，常用的度量方式包括到簇中心的平均距离、方差等等；分离度则是衡量某个聚类簇内部的数据点到其他簇的距离是否足够“远”。

常见的聚类有效性指标包括 *SSE*（sum of squared error）、*CHI*（Calinski-Harabasz Index）、*DBI*（Davies-Bouldin Index）等指标[58][59]。

（1）*SSE* 指标

记为 I_{SSE}，其计算公式为：

$$I_{SSE}=\frac{1}{K}\sum_{i=1}^{K}\|X_i-C_i\|_2^2 \tag{4-13}$$

其中，K 为聚类数；X_i 为表示类簇 i 中的数据点；C_i 为类簇 X_i 的聚类中心。

（2）*CHI* 指标

记为 I_{CHI}，其计算公式为：

$$I_{CHI}=\frac{1}{K}\sum_{i=1}^{K}\frac{trB(i)/(i-1)}{trW(i)/(K-1)} \tag{4-14}$$

其中，K 为聚类数，i 表示当前的类簇；$trB(i)$ 表示类间离差矩阵的迹；$trW(i)$ 表示类内离差矩阵的迹。

（3）*DBI* 指标

记为 I_{DBI}，其计算公式为：

$$I_{DBI}=\frac{1}{K}\sum_{K=1}^{K}R_K \tag{4-15}$$

$$R_K=\max_{k\neq j}\frac{d(X_k)+d(X_j)}{d(C_k,C_j)} \tag{4-16}$$

其中，K 为聚类数，C_i 为类簇 X_i 的聚类中心，$d(X_i)$ 为类簇 X_i 的平均内部距离，$d(C_k,C_j)$ 为两个聚类中心向量间的欧氏距离。

综上，*DBI* 指标综合考虑了类间的分散性和类内的紧凑性，更适合评价电力大数据的聚类有效性，因此本文选取 *DBI* 指标衡量聚类的有效性。易知 I_{DBI} 越小，聚类效果越好。改进 K-means 算法与常见聚类算法的性能测试结果详见下一节。

4.3 算例分析

在智能电网中，存在着海量的用户负荷数据，若不对原始数据进行过滤提高其价值密度，进行研究分析将会带来极大的计算负担。因此利用聚类分析将用电规律相近的负荷日期归为一类，提取相同类的规律和共性可以大大提高电力大数

中国知网 https://www.cnki.net

据的价值密度。以某实际配电网用户日负荷曲线为例。其用电信息采集频率为 15 分钟每次，采集其中某用户近三年来的用电日负荷数据，如下图所示。

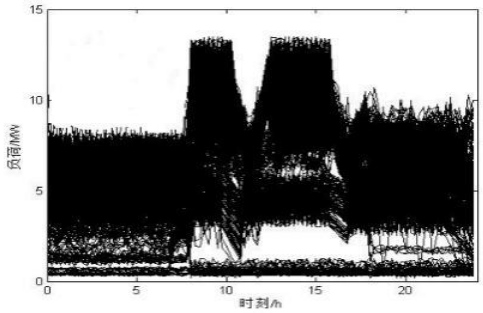
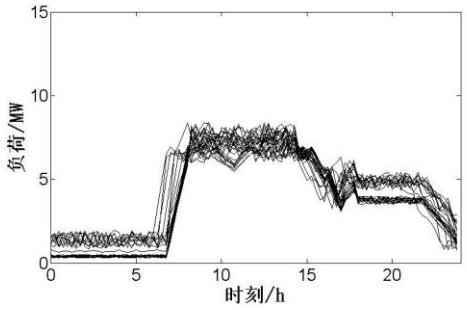


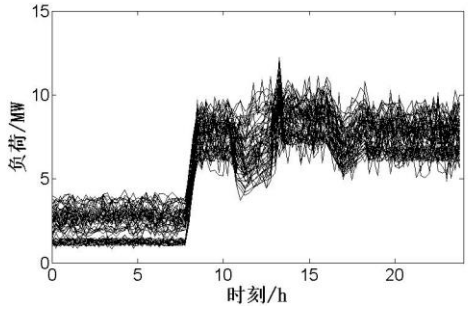
图 4-4 某电力用户日负荷曲线

Figure 4-4 Daily load curve of a certain power user

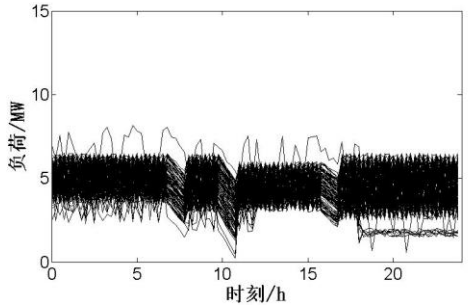
利用本文所提出的改进 K-means 聚类算法，根据 4.2 节的具体算法流程，可以将用户用电规律相近的负荷日期进行聚类。聚类结果如图 4-5 所示。



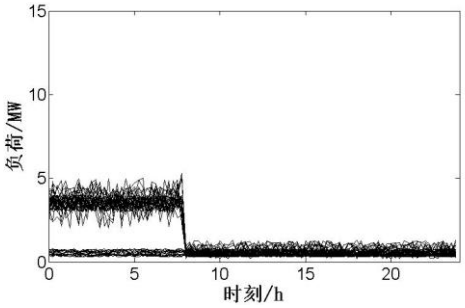
(a)聚类 1



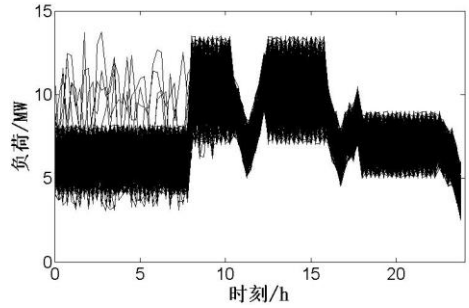
(b)聚类 2



(c)聚类 3



(d)聚类 4



中国知网 https://www.cnki.net

(e)聚类 5

图 4-5 负荷数据聚类结果

Figure 4-5 Clustering results of load data

对于每一个用户来说，其历史负荷曲线因为天气、节假日等影响会产生走势各异的不同曲线类型。某用户近三年的负荷数据可以聚类为图 4-5 中五类曲线，如图所示，不同类在幅值大小及曲线走势上均存在较大的差异。简单分析发现属于聚类 5 的用电日负荷数据最多，且主要为工作日负荷；聚类 3 的数据对象主要为周末负荷；聚类 4 的数据对象含有大量的节假日如国庆节等负荷。

根据日负荷曲线的聚类结果，可以进一步分析用户用电行为特征，实现短期负荷的精准预测。基于改进 K-means 算法的处理结果，对属于不同类簇的负荷对象或日期进行预测时，可以只提取属于该类簇的数据，过滤其余类簇的数据，从而实现了基于改进 K-means 算法的记录“横向”过滤，大大提升了信息价值密度。这部分内容将在第六章详细讨论分析。

为进一步检验改进 K-means 聚类算法的性能，本文对比了常见聚类算法，分别从运行速率、聚类有效性两方面进行测试，结果下图 4-6 所示。

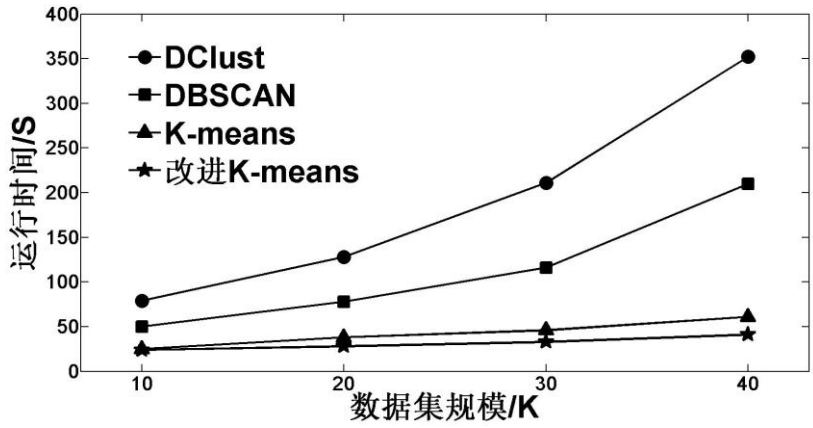


图 4-6 各种聚类算法的运行速率比较

Figure 4-6 Comparison of running speed of various clustering algorithms

中国知网 https://www.cnki.net

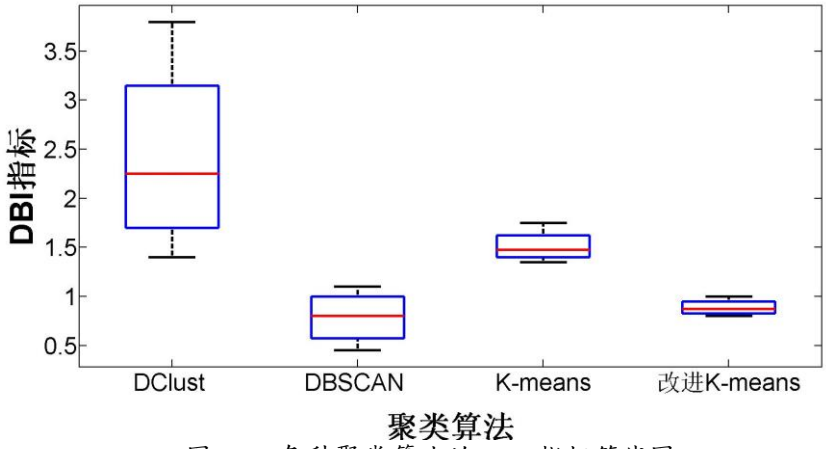


图 4-7 各种聚类算法的 DBI 指标箱线图
Figure 4-7 Boxplot for DBI index of various clustering algorithms

由图 4-6 可知改进算法进一步提高了 K-means 的运行速率，计算效率明显高于其他算法，且数据集规模越大时优势越明显。

如图 4-7 所示，改进 K-means 算法更为关键的优势是在于聚类有效性得到了提升，尤其是处理大规模数据时效果最优，且性能基本保持稳定波动性最小。

综上所述，本文改进的 K-means 算法在计算速率和聚类效果方面都有明显优势，而且随着数据集规模的扩大，优势更加明显。

4.4 小结

本章利用聚类算法实现了基于改进 K-means 算法的记录“横向”过滤，提升了电力大数据的价值密度。首先对常见聚类算法进行了比较研究，也对目前基于 Hadoop、spark 等平台的并行化处理算法进行了分析，针对 K-means 算法的不足，提出了一种基于多初始聚类中心、多机组并行处理的改进 K-means 算法，并对算法的聚类有效性和运行速率进行了算例测试，结果验证了算法的优势和有效性。

中国知网 https://www.cnki.net

第五章 基于 FP-network 算法的字段“纵向”过滤

第三章、第四章内容分别从“脏数据”、记录的角度实现对电力大数据的过滤，提升了信息价值密度。本章的主要内容是“三层过滤机制”的第三层过滤——基于 FP-network 算法的字段“纵向”过滤，从数据库的字段即属性维度出发，研究如何提升其价值密度。

传统的数据约简算法如灰色关联度分析、主成分分析等，尽管可以实现数据属性降维，但是灰色关联分析算法主要针对“小样本”、“贫信息”的不确定性系统，可以实现“少数据建模”，与大数据的处理方式不同；主成分分析方法存在要求样本服从某个典型的概率分布、要求各字段之间彼此无关、计算量较大等问题，都难以处理电力大数据庞大的体量。

关联分析是从大量数据的项集之间发现频繁出现的模式以及隐藏在其中的规律和联系，本质上是一种无监督的学习方法[60]。关联分析一方面计算简单，算法复杂度相对较低；另一方面，适合利用计算机群并行化处理。因此，本章主要采用关联分析方法实现字段属性过滤。

下表是关联分析中常用到的一些概念及其解释。

表 5-1 关联分析常见概念解释

Table 5-1 Interpretation of common concepts in relevance analysis

概念	解释
项目（item）	数据库中的一个属性字段
项集（itemset）	项目的集合。包含 k 个项的项集称为 k 项集，k 也叫项集的维度
支持计数（support count）	包含项集的个数，又称为项集的频率、计数、支持计数，记为 *sup_count*
支持度（support）	设 A 为一个数据库，B 为一个项集，则定义支持度为 A 中包含项集 B 的个数与 A 的总个数之比，记为 *sup*（B）。关联规则 $B\rightarrow C$ 的支持度，记为 *sup*（$B\cap C$）
置信度（confidence）	B、C 都是项集，对 $B\rightarrow C$ 的关联规则，则定义可信度为 A 中即包含 B 也包含 C 的个数与 A 中包含 B 的个数之比，即项集 $B\cap C$ 与项集 B 的支持度之比，记为 *conf*（$B\rightarrow C$）
最小支持度	衡量支持度的一个阈值，是项集出现的最少次数，

中国知网 https://www.cnki.net

（minimun support）	也是项集在统计意义上的最小重要度，记为 *min_sup*
最小置信度 （minimum confidence）	衡量置信度的一个阈值，表示规则的最小的可靠度，记为 *mini_conf*
频繁项目集 （frequenct itemset）	满足最小支持度的项集。若 *sup*（*B*）≥ *min_sup*,则 *B* 为频繁项目集
非频繁项目集 （not frequenct itemset）	不满足最小支持度额项集。若 *sup*（*B*）<*mini_sup*, 则 *B* 为非频繁项目集
最大频繁项目集 （maximal frequenct itemset）	不是任何其他频繁项目集的子集的频繁项目集。

5.1 常见关联分析

现有的关联规则挖掘方法主要是 Apriori 算法及 FP-growth 算法，之后的研究大多都在它们的基础上展开。

5.1.1 Apriori 算法

Apriori 算法的核心思想是：基于逐层搜索的迭代方法，利用 *K*—项集寻找检索（*K*+1）—项集。即首先遍历数据对象，筛选出所有频繁 1—项集的集合，记为 L_1；然后基于 L_1，检索出所有频繁 2-项集的集合 L_2；同理，利用 L_2 得到频繁 3-项集的集合 L_3，直到再不能找到更大的频繁 *K*—项集[61]。因此，生成每个项集 *L* 时，Apriori 算法都需要扫描一次数据库，大大增加了计算负担。

经过上述方法，可以从数据库中找出频繁项集，但是有时需进一步挖掘频繁项集之间的关联规则。关联规则的置信度计算公式为：

$$confidence(A \Rightarrow B) = P(B \mid A) = \frac{\sup_count(A \cap B)}{\sup_count(A)} \qquad (5\text{-}1)$$

式中各变量含义详见表 5-1。

因此，可以将关联规则的产生表示为以下两步：

（1）对于每个频繁项集 *I*，产生 *I* 的所有非空子集 *S*；

（2）对于 *I* 的每个非空子集 *S*，如果满足

$$\frac{\sup_count(I)}{\sup_count(s)} \geq \min_conf \qquad (5\text{-}2)$$

则输出规则“*S*⇒（*I*-*S*）”。

Apriori 算法原理简单，通过数据库地不断遍历，统计各个项目集的数目，不

中国知网 https://www.cnki.net

断缩小检索的范围。但是缺点十分明显，其算法原理要求在检索频繁项的过程中不断存储大量的侯选对象，处理电力大数据 GB 甚至 TB、PB 级的体量时存储、计算负担极大；此外，大规模数据库的多次遍历带来了极大的资源浪费，对计算机性能是极大的挑战。

5.1.2 FP-growth 算法

FP-growth 算法是为了弥补 Apriori 算法的不足所提出的的，是目前最常用的关联分析方法。FP-growth 算法改进 Apriori 算法的优点主要包括：

（1）避免了类似 Apriori 算法大量候选集合的存储，FP-growth 算法是通过建立有向树状结构的频繁模式树 FP-tree 进行关联分析。

（2）FP-growth 算法在寻找频繁 1-项集只和建立频繁模式树时各扫描一次数据库，检索数据库次数的降低大大减少了计算负担，提高了计算效率；而 Apriori 算法每增加一项最大频繁集，都要对数据库进行访问，I/O 开销很大。

但是 FP-growth 算法在处理电力大数据时也有存在一些问题：

（1）FP-growth 算法虽然不需要存储候选集，但是相应地需要对频繁模式树递归更新，处理海量数据时仍然十分复杂，这极大地影响了算法的时间和空间效率。

（2）每次数据库更新都需要重新建立频繁模式树，然而电力大数据的特点是时刻产生新数据、不断更新信息，FP-growth 算法的可扩展性较差，难以满足实际需求。

基于上述分析，传统的关联分析方法主要是 Apriori 算法和 FP-growth 算法在处理电力大数据时都存在一些问题，不能满足计算需求。下面针对上述问题，提出了一种新的关联分析方法——FP-network 方法，更加适合处理大规模的海量电力数据。基于 FP-network 方法，第三层面向字段的“纵向”过滤，可以提取与电力业务关联性较强的字段，过滤关联性较弱的字段，实现提升电力大数据价值密度的目标。

5.2 FP-network 算法

电力大数据常见的信息系统数据库大多以事务数据库为主，大部分属于结构化数据，存储内容是事务和项目之间的联系。如表 5-2，T_{001} 表示事务的编号，其对应的 $I_1I_2I_5$ 表示该事务包含这三个项目。易知，事务编号按数字顺序排列，取决

中国知网 https://www.cnki.net

于具体存储内容的多少，理论上可无限增加；项目集合则是一个事务数据库包含的属性字段，通常数目远远小于事务数目。如表中，项目集合为[$I_1I_2I_3I_4I_5$]。

表 5-2 数据库部分事务及对应项目集

Table 5-2 Partial transaction of database and corresponding item set

事务	项目集
T_{001}	I_1,I_2,I_5
T_{002}	I_2,I_4
T_{003}	I_2,I_3
T_{004}	I_1,I_2,I_4
T_{005}	I_1,I_2,I_3
T_{006}	I_2,I_3
T_{007}	I_1,I_3
T_{008}	I_1,I_2,I_3,I_5
T_{009}	I_1,I_2,I_3

5.2.1 FP-network 算法的网络图形式

根据上述事务数据库列表内容，图 5-1 是按照传统的关联分析 FP-growth 算法，建立频繁模式树的具体流程。左边是扫描数据库建立的各个项目频数表，根据节点链表生成右边的频繁模式树，即 FP-tree 模型。由图可知，仅表 5-2 所示的简单示例，要建立频繁模式树已经十分复杂，如果处理体量庞大的电力大数据，频繁模式树将更加复杂，大大增加了计算负担。此外，右边 FP-tree 图是只有一个顶点的有向树状图，对于同一个项目，比如I_5，在树状图中可能存在多个节点。这就造成处理数据库更新维护时，需要重新建立频繁模式树，扩展性较差，难以应对电力大数据时刻产生、时时更新的情况[62]。

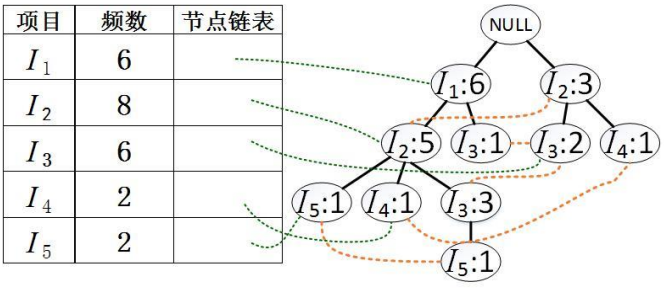


图 5-1 FP-growth 算法具体示例

Figure 5-1 Specific examples of FP-growth algorithm

为了满足电力大数据的处理要求，第三层面向字段的“纵向”过滤提出了 FP-network 算法，不同于 FP-growth 模型的频繁模式有向树状图，FP-network 算

中国知网 https://www.cnki.net

法是一个无向的网络图。在 FP-network 网络图中定义了以下几个变量：

a_i：表示弧容量，即遍历一次数据库，统计包含第 i 条弧的数目；

f_j：表示节点频数，即遍历一次数据库，统计包含节点 j 的数目；

n_j：表示节点负容量，即遍历一次数据库，扫描每条事务，统计节点 i 最后被扫描的次数。

同样以表 5-2 事务数据库示例，按照 FP-network 算法建立无向网络图的具体步骤为：

（1）事务数据库中 T_{001}-T_{009} 对应网络图中的路径；事务数据库中项目集合 $[I_1I_2I_3I_4I_5]$ 对应网络图中的五个节点。

（2）检索第一条事务 T_{001} 包含项目 $I_1I_2I_5$，因此对应 FP-network 中的 f_1、f_2 和 f_3 分别加 1；T_{001} 包含 I_1 I_2 和 I_2 I_5 两条弧，因此对应 FP-network 中的弧容量 a_1 和 a_2 分别加 1；检索 T_{001} 时 I_5 项目最后被扫描，因此 FP-network 中对应节点负容量 n_5 减 1。

（3）根据步骤（2）同理依次扫描事务 T_{001}-T_{009}，直至遍历一次数据库。

根据上述步骤，建立的 FP-network 算法的网络图如下图 5-2 所示。

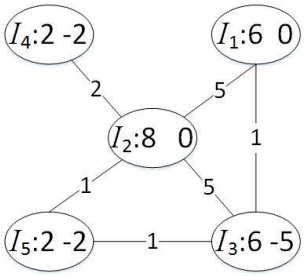


图 5-2 表 5-2 事务数据库对应 FP-network 网络图

Figure 5-2 Transaction Database Corresponds to FP-network Network Diagram

由图可知，FP-network 算法网络图的主要特征包括：

（1）区别于 FP-growth 算法的频繁模式有向树状图，FP-network 网络图本质上是一个无向图。并且事务数据库中的项目与网络图中的节点一一对应，不存在一对多的情形，简化了对应关系，节省了存储资源。

（2）FP-network 网络图存在以下约束：

$$\sum_{i=1}^{\mathrm{n}} a_i = \sum_{j=1}^{m} f_j + \sum_{j=1}^{m} n_j \qquad (5\text{-}3)$$

其中，n 为 FP-network 算法网络图中弧的数目，m 为相应的节点数目。

（3）FP-network 算法的网络图形式虽然简化了 FP-growth 算法的树状图，但

中国知网 https://www.cnki.net

是可能会扩大某些事务数量，导致挖掘出部分错误信息。例如表 5-2 所示数据库中有 2 条事务，分别为I_1, I_2, I_3, I_5和I_1, I_2, I_5，包含项目I_5。从 FP-network 算法的网络图中，却可以找到 4 条路径，分别为I_1, I_2, I_3, I_5、I_1, I_2, I_5、I_1, I_3, I_5、I_2, I_5包含I_5对应的节点，而I_1, I_3, I_5、I_2, I_5路径对应的事务实际上在表 5-2 中并不存在。

5.2.2 FP-network 算法的矩阵形式

由于频繁模式网络算法的网络图形式存在不足，其计算机存储和处理采取事务（路径）-项目（节点）的关联矩阵，即$T = f\ (B, I)$。仍采用上表事务数据库示例的数据，将其转化为矩阵表达形式：

$$B=\begin{bmatrix}1&1&0&0&1\\0&1&0&1&0\\0&1&1&0&0\\1&1&0&1&0\\1&1&1&0&0\\0&1&1&0&0\\1&0&1&0&0\\1&1&1&0&1\\1&1&1&0&0\end{bmatrix} \qquad I=\begin{bmatrix}6&0\\8&0\\6&-5\\2&-2\\2&-2\end{bmatrix} \tag{5-4}$$

其中，矩阵B表示事务-项目的关联矩阵，元素b_{ij}取值为 1 或 0，表示事务 T 与项目 I 之间是否相互关联。

电力大数据的数据库由于统计时间较长、频率较快、范围较大，项目集合 I 的取值相对于事务 T 可以近似忽略不计。因此频繁模式网络算法的时间复杂度主要与事务 T 的取值有关，可近似表示为$O(T)$。此外，相较于 Apriori 算法需要存储大量候选集、FP-growth 算法需要迭代产生频繁模式树，FP-network 算法仅需要存储矩阵I和布尔矩阵B，节约了存储资源，降低了算法的空间复杂度。对于算法复杂度的具体算例验证详见 5.3 节。

5.2.3 FP-network 算法的具体流程

5.2.1 小节和 5.2.2 小节分别给出了频繁模式网络 FP-network 算法的网络图形式和矩阵形式。其中网络图形式展现方式更加简单直观，但是可能会造成冗余信息的产生；矩阵形式更加适合计算机的存储处理。算法的具体流程主要如下：

（1）根据实际需求，确定$S_{\min}$（最小支持度阈值)的合适取值;

（2）扫描一次数据库，统计各个项目的频数信息。若$f_j > S_{\min}$，保留该项目节点；反之，删去。建立矩阵B和I；

中国知网 https://www.cnki.net

（3）从节点负容量为非零的节点 k 寻找频繁项集；

（4）删去 B 中除了包含 k 节点取 1 的 I（$I=\{i|b_{ik}=1\}$）外的数据，并且仅保留 k 节点之前的节点信息，更新 B 和 I 数据；

（5）如果 $|n_k|\geq S_{\min}$，则 k 节点作为一个频繁项目集的元素之一；反之，不做任何处理。删去此节点信息，更新 B 和 I 。转（2），直至检索全部非零节点负容量的项目节点。

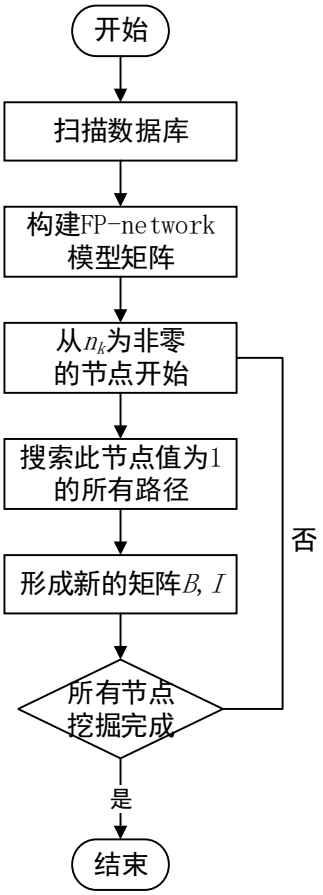


图 5-3 频繁模式网络算法流程

Figure 5-3 Flow chart of frequent pattern network algorithm

仍以表 5-2 示例，设 $S_{\min}=2$，I_1-I_5 的节点频数均大于等于 2，不删除任何项目节点。I_3 的节点负容量非零，从 I_3 开始寻找频繁相集，对应 B 中的数据为第 3 列，其中第 3、5、6、7、8、9 行取值为 1，删去其他数据信息，更新 B 和 I 如下所示。

中国知网 https://www.cnki.net

$$B=\begin{bmatrix}0&1&1\\1&1&1\\0&1&1\\1&0&1\\1&1&1\\1&1&1\end{bmatrix}\qquad I=\begin{bmatrix}4&0\\5&0\\6&-6\end{bmatrix}\tag{5-5}$$

$|n_k|\geq S_{\min}$,则 I_3 作为一个频繁项集的元素，删去 I_3，更新 B 和 I 如下所示。

$$B=\begin{bmatrix}0&1\\1&1\\0&1\\1&0\\1&1\\1&1\end{bmatrix}\qquad I=\begin{bmatrix}4&-1\\5&-5\end{bmatrix}\tag{5-6}$$

I_2 也是频繁项集的元素，删去 I_2，更新 B 和 I，得到频繁项集为 I_1, I_2, I_3。同理从 I_4 挖掘得频繁项集为 I_2，I_4；从 I_5 挖掘得频繁项集 I_1，I_2，I_5，此时算法终止。根据统计学原理，频繁项集的所有子集也是频繁项集，因此上述挖掘的频繁项集及其所有子集共同构成了表 5-2 所示数据库对象间的关联关系。

5.2.4 与其他关联规则算法的比较

如上文所述，当产生新的电力大数据或者原有信息系统维护更新造成数据信息有所变化时，以及根据业务需求调整挖掘结果的范围和精度（通过调整 $S_{\min}$ 的取值实现）时，FP-growth 算法需要重新扫描数据库，并重新构建频繁模式树。频繁模式网络 FP-network 算法采用关联矩阵的形式，并且 B 中节点的顺序是任意的，因此处理数据更新问题不需要再次遍历数据库，可以方便地进行维护更新。

例如若调换原数据库中 I_5 和 I_1 的顺序，无需重新遍历数据库，只需要对 B 和 I 做出如下调整：

$$B=\begin{bmatrix}1&1&0&0&1\\0&1&0&1&0\\0&1&1&0&0\\0&1&0&1&1\\0&1&1&0&1\\0&1&1&0&0\\0&0&1&0&1\\1&1&1&0&1\\0&1&1&0&1\end{bmatrix}\qquad I=\begin{bmatrix}2&-1\\8&0\\6&-1\\2&-1\\6&-6\end{bmatrix}\tag{5-7}$$

对应的 FP-network 算法的网络图如下所示：

中国知网 https://www.cnki.net

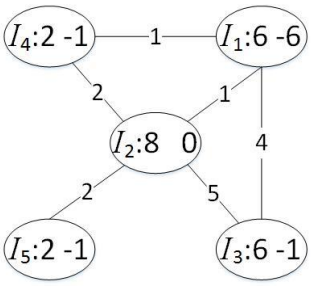


图 5-4 更新后的 FP-network 算法网络图

Figure 5-4 Updated FP-network diagram

按照 5.2.3 节所述 FP-network 算法的具体流程，对于更新后的矩阵 B 和 I ，从 I_3 开始挖掘，得频繁项集 I_2,I_3,I_1；其次，从 I_4 挖掘，得频繁项集 I_2, I_4；最后，从 I_1 挖掘得频繁项集 I_5, I_2, I_1，算法停止。因此，面对数据更新后的数据库，频繁模式网络 FP-network 算法无需再次遍历，仅维护更新 B 和 I 即可，即可得到更新后的频繁模式挖掘结果。

这验证了 FP-network 算法采用矩阵形式，并且节点顺序任意，可以更好地应对电力大数据的维护更新问题。其具体处理情形主要包括以下两种：

（1）当事务数据库增加事务信息时，相应地增加第 j 行和第 i 列到矩阵 B，计算更新的 f_j, n_j ;;

（2）当事务数据库不变化，但是根据业务需求，需要调整 $S_{\min}$ 时，对 B 和 I 不作任何处理，仍然基于原矩阵处理分析。

基于上述分析，总结 FP-network 算法、Aprori 算法、FP-growth 算法如表 5-3 所示：

表 5-3 FP-network 算法和 Aprori 算法、FP-growth 算法的比较

Table 5-3 Comparison of FP-network, Aprori and FP-growth

算法	时间复杂度	空间复杂度	实现	更新维护
Apriori	生成一个频繁 N-项集需要扫描 N次数据库；	存储大量候选集，甚至出现组合爆炸的问题	原理简单	困难
FP-tree	扫描两次数据库	采用递归算法，需要频繁进出栈操作，占用大量内存	树的计算机生成十分繁琐	困难
FP-network	仅需扫描一次数据库	以布尔矩阵存储，占用内存最小	仅需对矩阵进行处理	方便

中国知网 https://www.cnki.net

5.3 算例分析

同第四章的改进 K-means 算法，本章提出的 FP-network 算法是一种适合处理电力大数据的新数据挖掘算法。除可以应用于基于 FP-network 算法的字段“纵向”过滤外（这部分算例分析详见第六章），也可以用于挖掘电网的关联规则，分析电网实际问题。本节算例分析测试了 Apriori、FP-growth、FP-network 的算法性能，并验证了如何应用 FP-growth 算法分析智能电网的一些研究问题。

5.3.1 实验环境和数据

实验环境和测试条件为：Windows 10 操作系统，4GB 内存，Intel(R)Core(TM) i5-4430 CPU@3.00GHz 的 CPU。本章算例实验采用 python 编程，具体处理过程和结果如下。

根据某省电力公司的统一业务数据平台，以输电线路故障分析为例，从平台中采集相关故障数据，构成表 5-4 输电线路故障分析事务数据库。由于 FP-network 算法的使用条件限制，需要离散处理表 5-4 中的“时间”属性。考虑到故障分析的实际需求，年份忽略不计，具体处理如下：T_1 表示春季（3-5 月）；T_2 表示夏季（6-8 月）；T_3 表示秋季（9-11 月）；T_4 表示冬季（12-次年 2 月）。

将表 5-4 实际数据库处理为表 5-5，此时可以应用 FP-network 算法。

表 5-4 输电线路故障分析事务数据库

Table 5-4 Transaction database for transmission line fault analysis

事务	时间	区域	电压等级(kv)	故障元件	故障类型	成功合闸	损失
T_{001}	2011/3/2	北部地区	220	导线及地线	雷击	是	较轻
T_{002}	2011/11/9	西部地区	110	导线及地线	舞动	否	较轻
T_{003}	2011/7/6	中部地区	220	导线及地线	大风	否	较轻
T_{004}	2011/8/17	中部地区	500	绝缘子	外力破坏	否	一般
T_{005}	2012/4/27	北部地区	220	杆塔及基础	覆冰	是	一般
T_{006}	2012/6/23	中部地区	500	金具	舞动	是	严重
T_{007}	2012/2/4	中部地区	220	绝缘子	雷击	是	一般
T_{008}	2014/6/8	南部地区	220	导线及地线	雷击	是	较轻
T_{009}	2012/7/31	东部地区	220	绝缘子	外力破坏	否	严重

表 5-5 离散、变量化的数据库

中国知网 https://www.cnki.net

Table 5-5 Discrete and variable transaction database

事务	时间	区域	电压等级	故障元件	故障类型	成功合闸	损失
T_{001}	T_1	L_4	V_2	FC_1	FT_3	Y	IN_1
T_{002}	T_3	L_3	V_1	FC_1	FT_2	N	IN_1
T_{003}	T_2	L_5	V_2	FC_1	FT_5	N	IN_1
T_{004}	T_2	L_5	V_3	FC_3	FT_1	N	IN_2
T_{005}	T_1	L_4	V_2	FC_2	FT_4	Y	IN_2
T_{006}	T_2	L_5	V_3	FC_4	FT_2	Y	IN_3
T_{007}	T_4	L_5	V_2	FC_3	FT_3	Y	IN_2
T_{008}	T_2	L_2	V_2	FC_1	FT_3	Y	IN_1
T_{009}	T_2	L_1	V_2	FC_3	FT_1	N	IN_3

5.3.2 算例分析过程

测试环境条件如上文所述，设$S_{\min}$=0.5%，测试传统的关联分析方法和所提出的 FP-network 算法在处理不同体量数据库时的计算性能，算法比较如图 5-5。

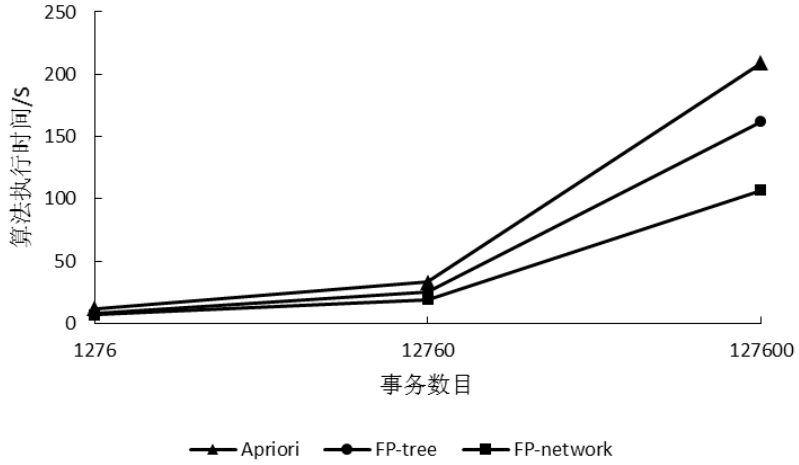


图 5-5 Apriori 算法、FP-tree 算法、FP-network 算法运行效率比较

Figure 5-5 Comparisons of operating efficiency of Apriori, FP-tree and FP-network algorithms

如图 5-5 所示，FP-network 算法在处理不同的事务数目，包括 1276、12760、127600 时的算法执行时间都要少于 Apriori 算法和 FP-tree 算法。较少数据库事务数目时，三种算法的执行时间都比较少，FP-network 算法的运行速率优势得不到体现。随着数据量的增加，FP-network 算法的运行速率明显要优于 Apriori 算法和 FP-tree 算法，而 Apriori 算法的运行速率较差。这验证了所提出的的 FP-network

中国知网 https://www.cnki.net

算法在处理电力大数据时的运行速率优势。

另一方面，设置不同的S_{min}取值，对比分析 Apriori 算法、FP-tree 算法、FP-network 算法的算法性能，结果如图 5-6 所示。

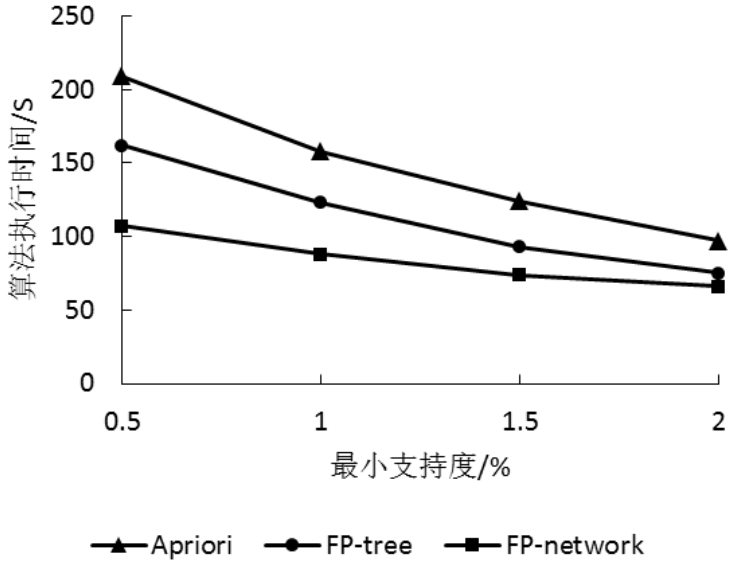


图 5-6 Apriori 算法、FP-tree 算法、FP-network 算法在不同S_{min}取值下的比较

Figure 5-6 Comparison of Apriori algorithm, FP-tree algorithm and FP-network algorithm with different min_sup

不同S_{min}取值对于原始数据量的大小没有影响，但是取值越大，挖掘的频繁模式越“粗糙”，相应耗时更短，运行更快；取值越小，挖掘的频繁模式更加“精细”，相应耗时更长，运行较慢。

根据上图对比结果，S_{min}分别取 0.5%、1%、1.5%、2%，在四组取值的场景下，本文所提出的 FP-network 算法的执行时间要快于 Apriori 算法和 FP-growth 算法。三种算法的运行速率随S_{min}的取值呈现出相同的变化规律：S_{min}增大，算法的运行速率变快；S_{min}减小，运行速率都有所减慢。另外，观察曲线的变化趋势，FP-network 算法的执行时间随S_{min}变化的波动范围较小，基本可以维持在相对较好的数值，这验证了 FP-network 算法可以较好的适应不同取值的S_{min}，更加适合电力大数据多场景下的挖掘处理。

上述实验对算法的运行速率进行了比较测试，下面实验测试了三种算法的空间复杂度。借助操作系统内存检测工具，分别测试 Apriori 算法、FP-growth 算法、FP-network 算法在处理不同事务数目规模时的最大占用内存，对比结果如下图。

中国知网 https://www.cnki.net

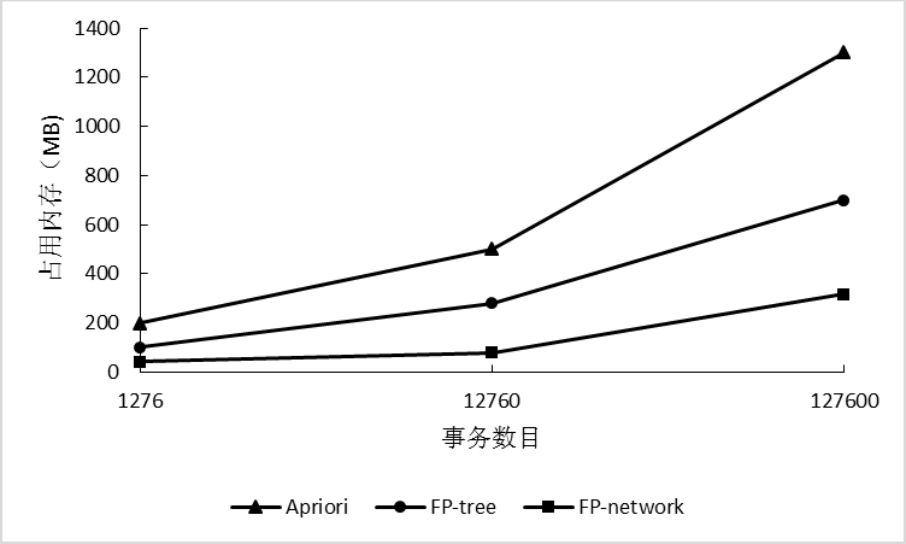


图 5-7 三种算法处理不同事务数目时的最大占用内存对比分析

Figure 5-7 Contrastive analysis of maximum memory occupied by Apriori algorithm, FP-growth algorithm and FP-network algorithm when dealing with different transaction numbers

由图 5-7 可知，频繁模式网络算法处理不同的事务数目时，都明显比其余算法更加节省存储资源，并且随着数据体量的增加，内存占用差距更加显著。图中曲线的变化趋势，验证了前文所述 Apriori 算法在关联分析的过程中需要存储大量候选集，占用内存较大，事务数目较多时占用内存呈指数增长。FP-growth 算法在 Apriori 算法的基础上进行了改进，占用内存有了明显改善，但是算法执行过程中需要迭代产生频繁模式树，导致经常需要进出栈操作，占用内存仍然较大。FP-network 算法执行过程中，只需要存储关联矩阵，极大的降低了算法的空间复杂度，从而节省内存资源，提高了处理海量数据的能力。

上述实验分别验证了 FP-network 算法时间上运行速率的优势和空间上内存占用的优势，这些优势在处理电力大数据庞大的数据体量或对处理速度有很高要求的电力业务问题时更加显著。

第三层面向字段的“纵向”过滤基于 FP-network 算法可以实现属性约简，提升了电力大数据的价值密度，关于这部分算例将在第六章展开讨论。另一方面，FP-network 算法不仅可以用于过滤冗余信息，提升价值密度，其本质是一种适合处理大规模数据的关联分析方法，可以应用于电力系统的多个场景。下面仍以 5.3.1 节输电线路故障分析的相关实验数据，通过具体算例，研究如何利用 FP-network 算法解决实际电力业务需求。

设 S_{min}=0.5%，对表 5-5 故障分析数据库利用 FP-network 算法挖掘得到所有频繁项集，在此基础上挖掘频繁项集之间的关联规则，结果如图 5-8。

中国知网 https://www.cnki.net

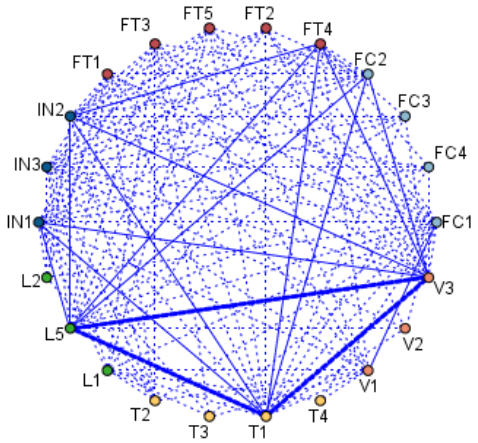


图 5-8 FP-network 算法的关联分析结果

Figure 5-8 Association analysis results of FP-network algorithm

根据频繁项集包含的元素进行组合，如图可得到上百条关联规则，但真正有价值的关联关系只有很少的一部分，大多数关联性十分薄弱，近似可认为是偶然事件或者彼此独立，没有关联关系。图 5-8 中不同项目之间的连线表示彼此间的关联关系，连线粗细表示关联关系的强弱。计算关联规则的置信度，选取其中大于 75%，可认为是强关联规则，如表 5-6。

表 5-6 FP-network 算法挖掘的强关联规则

Table5-6 Strong Association Rules Mining by FP-network Algorithms

编号	关联规则	支持度（%）	置信度(%)
1	$\{T_1\ L_5\ V_2\ IN_3\}\rightarrow\{FC_1\ FT_2\}$	0.7	100
2	$\{T_2\ L_2\ FT_1\}\rightarrow\{FC_1\}$	1.4	90
3	$\{\ V_3\ FC_3\}\rightarrow\{T_4\ L_5\}$	5.7	85
4	$\{L_1\ V_1\}\rightarrow\{FC_1\}$	3.2	91
5	$\{FT_4\}\rightarrow\{T_1\ L_5\ V_3\}$	6.4	84

根据表 5 6 中 FP-network 算法所挖掘的强关联规则，进一步分析其中项目、事务对应的具体电气行业意义，以及相互之间关联关系所包含的电气规律。表 5-6 是针对输电线路故障分析的数据库进行关联分析的结果，不同编号的规则对应着电力系统设备故障的影响因素，故障发生规律等等。由此可以挖掘原始数据库中海量数据所蕴藏的价值和信息，从而改善电网运行安全，便于预防故障发生和安排日常检修计划等。表 5-6 对应的具体关联规则主要如下：

（1）由输电线路历史故障数据库中包含的强关联规则 $\{T_1L_5V_2IN_3\}\rightarrow\{FC_1FT_2\}$ 分析：中部区域 220KV 电压等级的电网在春季易发生线路故障，主要是导线及地线舞动造成的。

中国知网 https://www.cnki.net

（2）由输电线路历史故障数据库中包含的强关联规则$\{T_2L_2FT_1\}\rightarrow\{FC_1\}$分析：在夏季，南部区域电网出现的线路故障主要以导线及地线故障为主，可能与外力破坏（如违规施工）等有关。

（3）由输电线路历史故障数据库中包含的强关联规则$\{V_3FC_3\}\rightarrow\{T_4L_5\}$分析：500KV 电压等级的线路绝缘子故障主要集中在冬季的中部区域电网。

（4）由输电线路历史故障数据库中包含的强关联规则$\{L_1V_1\}\rightarrow\{FC_1\}$分析：导线及地线故障经常发生在东部区域 110KV 电压等级的电网。

（5）由输电线路历史故障数据库中包含的强关联规则$\{FT_4\}\rightarrow\{T_1L_5V_3\}$分析：在春季，中部区域的 500KV 电压等级电网常常发生输电线路覆冰。

挖掘分析了输电线路故障的相应关联规则，为电力部门的发展决策和日常工作提供主要参考。如根据（1），在春季季节，中部区域的检修公司要加强线路巡检，尤其是 220KV 的线路，做好应对导线舞动的准备，提前消除相关隐患；根据（2），南部区域的电力公司应该加强日常管理工作，特别是对于相关施工单位要做好安全宣传教育，落实审查相应施工资质，减少施工带来的线路故障，避免不必要的经济损失。

5.3.3 算例分析结论

FP-network 算法挖掘智能电网的关联规则时主要分为以下几个步骤：数据采集、数据预处理、数据挖掘、结果分析应用。下面图 5-9 以电力系统故障分析为例说明应用的具体流程：

中国知网 https://www.cnki.net

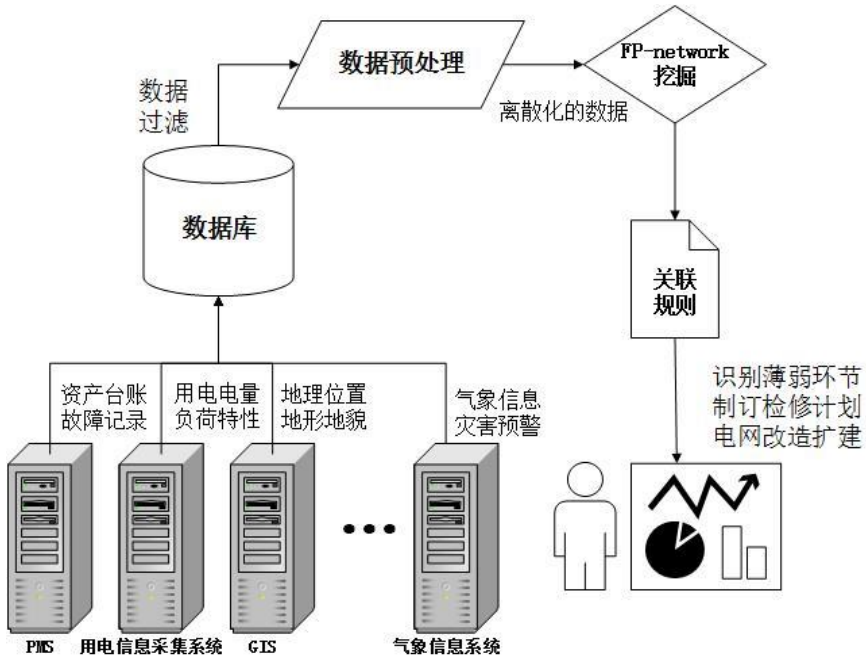


图 5-9 FP-network 算法解决电力实际问题的应用流程

Figure 5-9 Application flow of FP-network algorithms to solve electric power practical problems

5.3 节对 FP-network 算法进行了算例分析，包括 FP-network 算法和 Apriori 算法、FP-growth 算法处理不同规模数据库时的运行效率、应对不同 S_{min} 取值的算法表现以及挖掘不同事务数目时的空间复杂度等多个测试，也对如何利用 FP-network 算法解决电力实际问题进行了实验分析。5.3 节算例分析的主要结论包括：

（1）与频繁模式树算法相比，频繁模式网络 FP-network 算法是一个无向的网络图，比有向树状结构图更加简洁明了，但是同时网络图的形式可能会导致冗余信息的产生。

（2）FP-network 算法与 Apriori 算法、FP-growth 算法类似，不能含有处理连续变量的数据对象。

（3）FP-network 算法在关联分析过程中仅对数据库进行一次遍历，且无需存储候选集或者频繁模式树，提高了算法的运行速率，降低了内存占用，从而可以更快更好地处理更大规模的数据量。

（4）FP-network 算法在处理数据的更新和维护时更加简便，算法具有较好的扩展性，可以应对电力大数据不断更新的问题。

中国知网 https://www.cnki.net

5.4 小结

本章介绍了“三层过滤机制”中的第三层过滤——基于 FP-network 算法的字段“纵向”过滤，其实现是基于本章所提出的 FP-network 算法。FP-network 算法是针对现有关联分析算法，主要是 Apriori、FP-growth 算法的不足所提出的，通过算例分析验证了算法的优势，并介绍了如何利用 FP-network 算法挖掘电网中的关联规则，实现故障分析等应用。

中国知网 https://www.cnki.net

第六章 实验仿真

第二章至第五章围绕电力大数据的价值密度，分别从定义与评价指标、基于“脏数据”的第一层过滤、基于改进 K-means 算法的第二层过滤、基于 FP-network 算法的第三层过滤进行了研究分析，其中第四章、第五章分别对改进 K-means 算法和 FP-network 算法的性能进行了算例测试。本章将基于上述内容，验证评价指标的有效性和相关特性，整体地实验测试“三层过滤机制”对于价值密度的提升作用，且对每一层过滤的提升效果展开比较分析。

6.1 实验平台

普通的实验环境难以达到处理电力大数据的计算性能，因此必须借助大数据平台。国家电网公司通过信息化总体架构 SG-ERP 建设的全面推进，促进了数据共享和业务融合，部分省公司已经进行了一体化平台的建设。

本文实验平台为某省电力公司全业务统一数据中心平台。该平台基础硬件采用 150 台 X86 服务器，基于阿里飞天操作系统系统搭建；分布式计算架构利用基于 Hadoop 文件系统的分布式文件处理系统构建；处理框架主要利用基于 MapReduce 的分布式计算技术；云关系数据库采用 RDS、PG 和分布式数据库服务 DRDS 组成；挖掘算法集成 R 语言，流计算采用阿里 OSPS 架构。具体架构如下图 6-1 所示。

中国知网 https://www.cnki.net

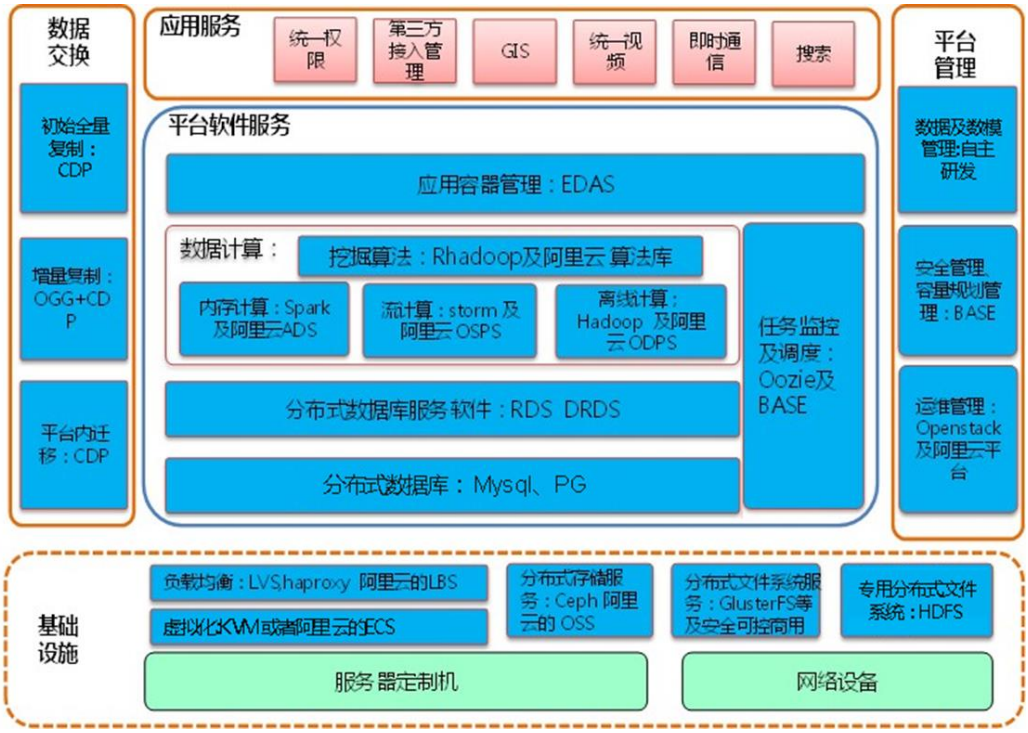


图 6-1 实验平台技术架构

Figure 6-1 Technical architecture of experimental platform

目前，该电力公司 39 套信息系统的全量数据已基本完全接入，云平台统一数据库数据存储总量 111.34TB，结构化数据总量 42.47TB，非结构化数据总量 68.87TB，HBASE 数据总量 11.01TB，RDS/ADS 等在线区数据总量 3982/114.57GB；其中 ODPS（离线结构化数据库）中数据表 35124 张，工作任务 34989 个，包括 27076 个数据同步任务，7913 个数据加工处理任务。

中国知网 https://www.cnki.net



图 6-2 实验平台实际操作截图

Figure 6-2 Screenshots of the actual operation of the test platform

如上图 6-2 所示，实验平台对电力系统中常用的信息系统进行了整合接入，借助平台可以实现跨业务、海量数据的查询和处理，完全可以满足本文算例的需求。

6.2 “三层过滤机制”处理过程

6.2.1 面向数据库的“脏数据”过滤

本章算例以基于电力大数据的短期日负荷预测为业务目标，对象电网为 90 万用户的某市级电网，其用电信息采集频率为 15 分钟每次。用户负荷短期预测主要需要的数据库主要包括气象监测数据库、用电信息采集数据库、95598 客户服务数据库、营销数据库等，统计过去近三年的数据集，记为 D，大小约为 30770MB。其中，D 数据集存在的主要“脏数据”问题包括：

（1）不同类型的变压器一天内采集的负荷数据点个数不同，有 24 点、48 点、96 点等。本文采用插值法等将数据同步成 96 点，具体方法已在第三章详述。

（2）部分负荷数据没有及时入库，造成缺失。用平滑回归法填补数据空集。

（3）个别入库数据点数值明显偏大或偏小，超出正常范围，造成负荷曲线波动较大，如图 6-3(a)所示。采用离群点监测法对异常数据进行拟合剔除，处理后

中国知网 https://www.cnki.net

的负荷曲线如图 6-3(b)所示，明显去除了异常的波动。

（4）许多定性特征需要定量化处理，如对天气信息的描述，如下表所示；许多定量特征需要划分区间，如温度数据可以划分为几档：寒冷/低温/正常/高温/炎热/等。

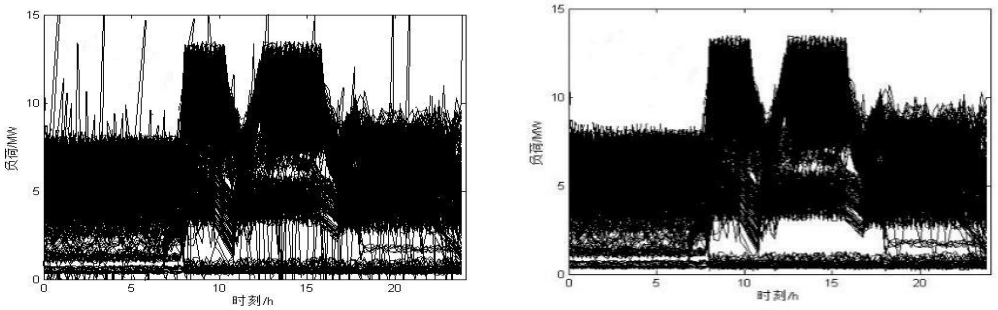
表 6-1 天气描述定量化处理

Table 6-1 Quantitative processing of weather description

天气	晴	多云	大雾	小雨	中雨	大雨	雨夹雪	小雪	中雪	大雪	暴雨/暴雪
量化	0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1

（5）不同数据库间含有部分重复信息，存在冗余等，如多个信息系统都含有同一用户的相关信息。利用相关性分析进行检测，并删除相关冗余信息。

对 D 进行“脏数据”过滤，将处理后的数据集记为 D_1，大小约为 29750MB。D_1 相对 D 而言，存储大小有所减少，主要是由于删去了大量冗余的数据。某用户的原始实际负荷数据及“脏数据”处理后的数据如图 4 所示。



(a)原始负荷数据　　(b)“脏数据”过滤后的负荷数据

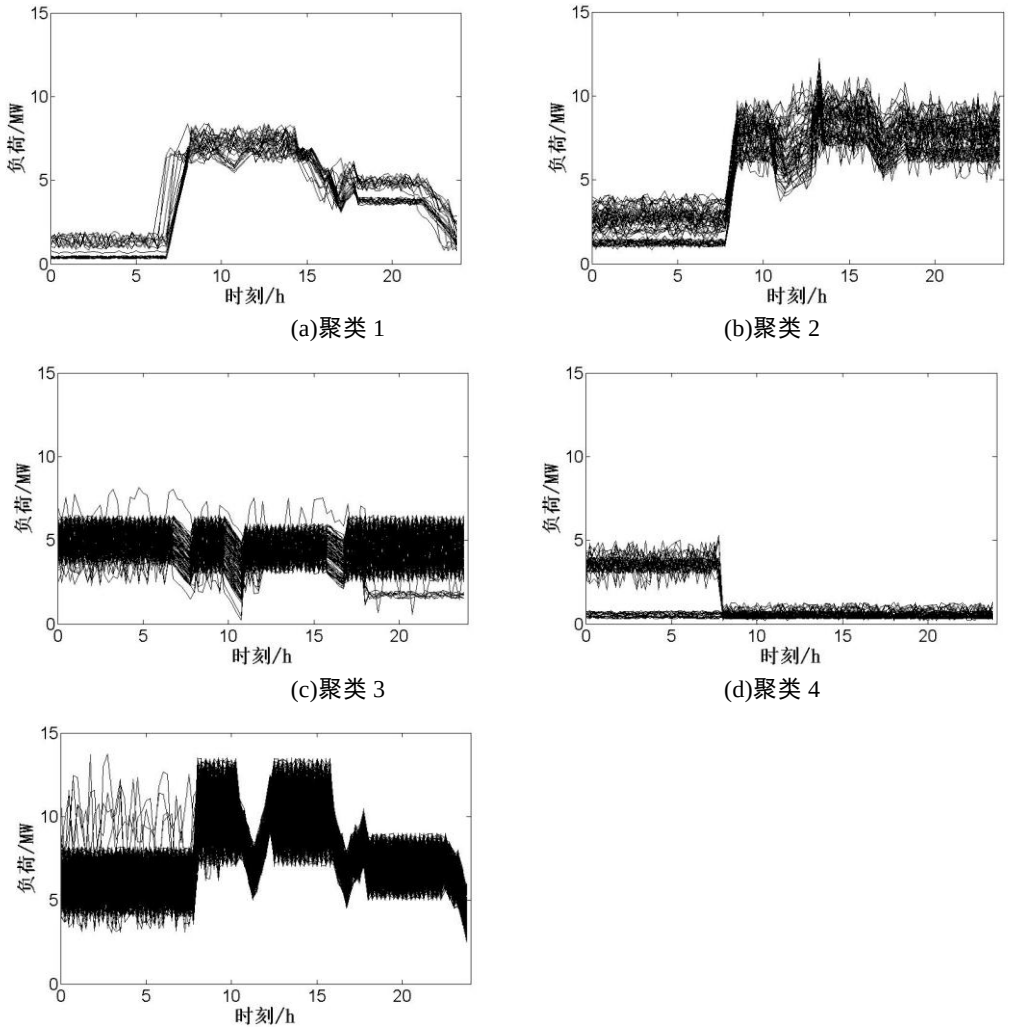
图 6-3 负荷数据

Figure 6-3 Load data

6.2.2 基于改进 K-means 算法的记录“横向”过滤

第一层过滤后得到 D_1 数据集，其中仍然存在着海量的用户负荷数据，若不对 D_1 数据集再一步进行过滤提高其价值密度，直接进行研究分析将会带来极大的计算负担。因此利用聚类分析将用电规律相近的负荷日期归为一类。对于每一个用户来说，其历史负荷曲线因为天气、节假日等影响会产生走势各异的不同曲线类型。利用改进 K-means 聚类算法可以将海量用户用电规律相近的负荷日期归为一类。某用户近三年负荷数据的聚类结果如图 6-4 所示。

中国知网 https://www.cnki.net



(a)聚类 1　(b)聚类 2

(c)聚类 3　(d)聚类 4

(e)聚类 5

图 6-4 负荷数据聚类结果

Figure 6-4 Clustering results of load data

不同聚类结果在幅值大小及曲线走势上均存在较大的差异。简单分析发现聚类 5 的负荷数据最多，且主要为工作日负荷；聚类 3 主要为周末负荷；聚类 4 含有大量的节假日如国庆节等负荷。若预测的对象属于聚类 1，则仅需要聚类 1 数据作为机器学习的对象，2、3、4、5 类数据均可舍弃，这一过程可以采用 CART 决策树模型[63]，根据信息增益度将样本按其若干影响属性值不断划分，建立分类规则实现。

上述仅对某一用户做了预测，为了得到系统总负荷，需要借助实验平台对每个用户都执行上述操作。经过第二层过滤后的全部数据集记为 D_2。

中国知网 https://www.cnki.net

6.2.3 基于 FP-network 算法的字段“纵向”过滤

根据电气背景知识，与负荷数据比较相关的字段可能包括环境气温、平均风速、平均湿度、平均降水、日类型（周一至周日）、节假日（国庆节、中秋节等）、天气状况、地区平均 GDP、人口数目、气压等等。经过对 D_2 进行 FP-network 关联分析，可以得出影响用户负荷变化规律的关键字段，进一步减少了数据维度，提升数据的价值密度。

负荷与各相关影响因子的支持度如图 6-5 所示。

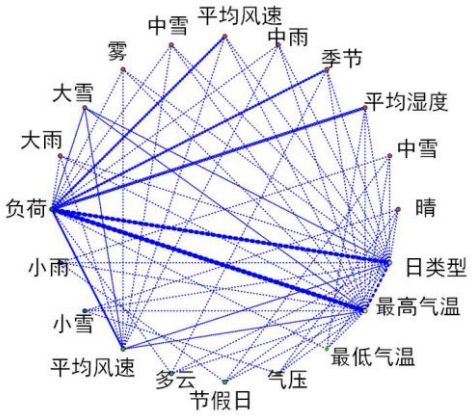


图 6-5 负荷与各影响因子支持度

Figure 6-5 Support degree of loads and influence factors

如图 6-5 所示，其中，连线的粗细表示关联程度的强弱。进一步，下表 6-2 针对每一簇的负荷数据分别进行了 FP-network 关联分析，尽管不同簇的支持度数值有所不同，总体上呈现与图 6-5 相同的规律：最高气温、平均湿度、日类型对于负荷的影响最大。经过计算，其累计方差贡献率超过 85%，因此提取这三个字段，过滤后的数据集记为 D_3。

表 6-2 负荷与各影响因子支持度

Table 6-2 Support degree of loads and influence factors

对象	最高气温	平均风速	平均降水	平均湿度	日类型	季节
聚类 1	0.7533	0.2214	0.2137	0.6588	0.4472	0.2356
聚类 2	0.6899	0.1798	0.3314	0.7072	0.4031	0.2290
聚类 3	0.8012	0.1598	0.1908	0.6334	0.4632	0.1995
聚类 4	0.7734	0.2019	0.2567	0.6013	0.5051	0.1876
聚类 5	0.7573	0.2509	0.2336	0.6694	0.4275	0.2198
总计	0.7686	0.2257	0.2373	0.6660	0.4440	0.2168

经过三层过滤后，实现了对原数据集 D 的价值密度提升。在此基础上，本文

中国知网 https://www.cnki.net

采用支持向量机（SVM）模型完成短期日负荷预测。δ^2 是高斯核的宽度参数，C、ε 是支持向量机模型的学习参数[64]，其具体参数设置详见表 6-3 所示。

表 6-3 支持向量机模型参数

Table 6-3 Support vector machine model parameters

对象	ε	δ^2	C
聚类 1	0.0011	20	110
聚类 2	0.0016	28	200
聚类 3	0.0015	37	601
聚类 4	0.0092	32	123
聚类 5	0.0071	87	115

6.3 价值密度评价结果分析

为进一步验证三层过滤机制对于价值密度的提升作用，分别以数据集 D、D_1、D_2、D_3 为输入数据，各自进行负荷预测得到四组结果。预测结果与预测日真实负荷的误差如图 6-6 和图 6-7 所示，其中 e_1、e_2 的计算详见式(2-4)、(2-5)。

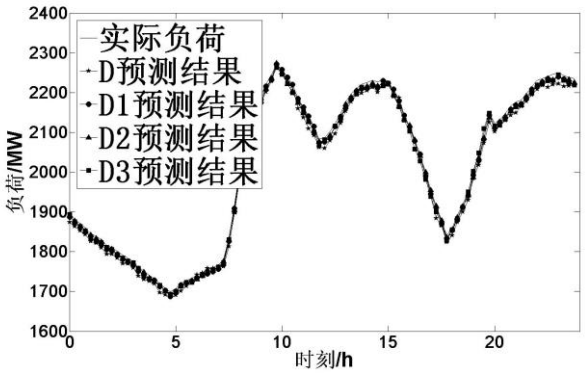


图 6-6 实际负荷与负荷预测结果

Figure 6-6 Actual load and load forecasting results

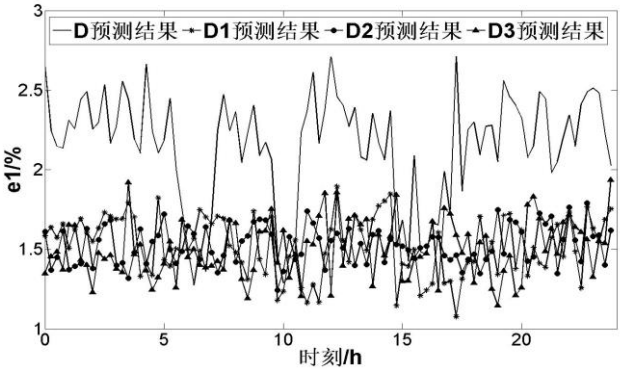


图 6-7 各数据集负荷预测结果相对误差

Figure 6-7 Relative error of load prediction results for all data sets

中国知网 https://www.cnki.net

由上图可知，数据集 D、D_1、D_2、D_3 的预测结果比较接近，其误差均符合短期电力负荷预测的精度（95%及以上）要求。其中数据集 D 的预测误差相对较大，D_2 的预测误差较小。误差分析和价值密度结果如表 6-4 所示。

表 6-4 详细计算了各数据集的相对误差及价值密度评价指标等。

表 6-4 各数据集负荷预测相对误差及价值密度评价指标结果

Table 6-4 Relative error of load prediction results and value density evaluation index for all data sets

数据集	相对实际负荷		相对数据集 D 的预测结果		空间		时间			价值密度 VD/%
	e_1/%	e_2/%	e_1/%	e_2/%	内存/MB	价值密度/%	过滤时间/min	运行时间/min	价值密度/%	
D	2.39	1.68	\	\	30770	13.46	\	248	20.50	17.34
D_1	1.75	1.23	0.67	0.45	29750	13.83	4	236	21.10	17.85
D_2	1.69	1.22	0.72	0.47	7280	56.47	5	82	69.45	63.30
D_3	1.90	1.45	0.80	0.54	4120	98.10	7	31	98.10	98.10

由表 6-4 可知：

从误差角度来看，经过三层过滤后，可近似认为 D_3 为所定义的“有价值数据集”S_1，从而可知 D_3 的价值密度指标接近 100%，相差部分主要与 D_3 的结果误差有关。表 6-4 中“相对实际负荷”一列表示数据集 D、D_1、D_2、D_3 预测结果与预测日真实结果的相对误差。对于 D_1、D_2、D_3 而言，这部分误差既包括负荷预测算法固有属性造成的精度误差，可近似认为与数据集无关；又包括 D_1、D_2、D_3 相较于 D 的数据信息损失所带来的误差，本文更加关心信息损失造成的误差，因此特别计算了 D_1、D_2、D_3 与 D 的预测结果之间的相对误差，即“相对数据集 D 的预测结果”一列。其中第一层过滤由于过滤了异常数据，改善了结果的相对误差；但是第三层过滤本质是提取电力大数据的“共有属性”，不可避免的造成了一些“个性”信息的损失，所以 D_3 相对误差有所增加，导致价值密度有所损失。工程实践中，应根据业务需求灵活调整支持度阈值，若结果要求精度较高，应将支持度阈值调低，多保留一些字段，从而减少信息损失造成的误差。

从运行时间角度来看，三层过滤机制的运行时间远小于负荷预测模型的运行时间。另外，根据第四章、第五章分析的算法性能，所采用的聚类和关联算法具有较好的可扩展性，即新数据入库时，无需对原数据库再次过滤。因此三层过滤机制本身运行时间忽略不计。

从价值密度指标角度来看，原始数据集 D 价值密度较低，若以 D 进行负荷预测不仅占用大量内存，也耗费大量时间，造成资源浪费。D、D_1、D_2、D_3 价值密度指标不断提升，证明了三层过滤机制的有效性，尤其是第二层过滤和第三层过

中国知网 https://www.cnki.net

滤提升效果较为显著，既明显减少占用内存，也大大降低预测模型的运行时间。这证明了所定义的指标能够较好地反映大数据的价值密度，考虑了相对误差，更加客观合理。

由于目前几乎尚未有研究提出价值密度的评价指标，无法与本文指标形成有效对比。为进一步检验指标的特性，分别在负荷数据集不同规模的子集上测试，按采样频率为 12 点/日、24 点/日、48 点/日、96 点/日抽取，其电力特征仍然不变，计算结果如表 6-5 所示。

表 6-5 不同采样频率数据集的价值密度评价指标对比

Table 6-5 Comparison of value density indices of data sets with different sampling frequencies

采样频率/日	相对实际负荷 e_1/%				*VD_space*/%				*VD_time* /%				*VD*/%			
	D	D_1	D_2	D_3	D	D_1	D_2	D_3	D	D_1	D_2	D_3	D	D_1	D_2	D_3
12 点	8.91	8.44	9.32	9.67	27.88	28.03	70.36	90.33	40.15	41.22	83.79	90.33	34.56	35.24	77.36	90.33
24 点	7.28	6.97	7.16	7.48	24.17	24.93	66.57	92.52	33.72	34.01	79.65	92.52	29.33	29.81	73.40	92.52
48 点	4.35	4.12	4.05	4.20	18.46	18.97	60.07	95.80	24.39	24.76	73.88	95.80	21.62	22.05	67.33	95.80
96 点	2.39	1.75	1.69	1.90	13.46	13.83	56.47	98.10	20.50	21.10	69.45	98.10	17.34	17.85	63.30	98.10

由表 6-5 可知：

对比每一行结果，不同采样频率的数据集基本呈现相同规律：价值密度指标随过滤不断改善，第二层、第三层提升效果最有效；时间价值密度指标略高于空间价值密度指标。这也与表 6-4 结果一致，验证了指标的合理性。

其次，对比每一列结果：采样频率越低，误差越大，12 点/日、24 点/日的预测结果已经不能满足工程实践的精度要求，其结果误差也造成了 D_3 价值密度相对较低；但是，采样频率越低，D、D_1、D_2 价值密度指标却越高。这是由于频率降低，尽管误差增大，但是数据集规模大大减少，有价值数据占得比重反而会有所增加。这表明价值密度指标是数据集信息价值密/疏的表征，与数据集规模、相对误差大小呈现出非线性关系，其中受数据集规模影响更大。

综上所述，本章算例验证了本文所提出的时间价值密度和空间价值密度评价指标的有效性，可以较好地反映电力大数据的价值密度属性，并且计算简短，可以互相比较，适用于工程实践推广。

本章算例整体地测试了“三层过滤机制”对于电力大数据价值密度的提升作用，该技术路线层层递进，从“脏数据”、记录、字段等多个维度进行过滤，基本涵盖了现有数据约简、属性降维等技术方法所考虑的所有方面。算例结果证明了该技术路线切实可行，便于实现，耗时较少，提升效果十分显著。

中国知网 https://www.cnki.net

针对“三层过滤机制”中的每一层过滤，第一层过滤虽然提升价值密度的效果不明显，但是有效改善了预测结果的误差，对于提高数据挖掘精度十分必要。第二层过滤和第三层过滤的提升效果最为显著，大大提高了电力大数据的时间价值密度和空间价值密度，充分证明了本文提出的改进 K-means 算法和 FP-network 算法对于电力大数据价值密度具有较好的提升效果。

此外，限于电力公司数据保密等条件制约，本文算例采用的数据量未达到 TB 级，但足以验证相关规律和结论。若后续实验条件允许，进一步研究应考虑更大规模的数据量。

中国知网 https://www.cnki.net

第七章 结论与展望

7.1 结论

本文围绕电力大数据的价值密度这一研究课题，从价值密度的定义，评价指标的建立，提升方法的研究，到实验仿真的验证都展开了研究分析。其中，本文从不同的维度出发，将提升价值密度的技术路线总结为“三层过滤机制”——面向数据库的“脏数据”过滤、基于改进 K-means 算法的记录“横向”过滤、基于 FP-network 算法的字段“纵向”过滤，并针对每一层过滤进行了深入研究和阐述。

基于本文所做的主要工作，结论总结如下：

（1）本文首次提出了电力大数据价值密度的定义及评价指标，为后续研究如何提升价值密度提供了定量分析的基础和依据。

其中，本文定义的价值密度依赖于特定的业务目标，即价值具有相对性。本文所提出的价值密度评价指标分别从空间上内存占用、时间上运行速率两个维度计算，分别衡量数据不同维度的价值密度。并且，评价指标也考虑到了数据挖掘结果的误差，主要包括两部分：数据挖掘算法的固有属性所导致的误差和数据过滤造成的信息损失。

（2）经过算例测试，“三层过滤机制”可以有效地提升电力大数据的价值密度。该技术路线层层递进，从“脏数据”、记录、字段等多个维度进行过滤，基本涵盖了现有数据约简、属性降维等技术方法所考虑的所有方面。结果证明了该技术路线切实可行，便于实现，耗时较少，提升效果十分显著。其中以第二层过滤和第三层过滤的提升效果最为明显。

（3）针对第一层过滤，本文对电力信息系统、常用的数据信息及对应的电力业务部门进行了梳理总结，建立起基于电力业务流程的“数据-系统-业务”对应关系。此外，本文分析研究了常见的“脏数据”类型及其产生原因，针对每一类型的“脏数据”给出了相应的具体处理方法。

第一层过滤虽然提升价值密度的效果不明显，但是有效改善了预测结果的误差，对于提高数据挖掘精度十分必要。

（4）针对第二层过滤，本文改进了传统 K-means 聚类方法，提出基于多初始聚类中心、多机组并行处理的改进算法，弥补了传统 K-means 聚类方法太过依赖于初始聚类中心导致聚类效果差的问题，并可以提高海量数据的聚类速度。

中国知网 https://www.cnki.net

经过算例测试，算法的有效性和优势已经得到了验证，并且可以显著提升电力大数据的时间价值密度和空间价值密度。

（5）针对第三层过滤，本文提出了 FP-network 算法，相较于现有的 FP-growth 算法，其具有以下特点：

a）与频繁模式树算法相比，频繁模式网络 FP-network 算法是一个无向的网络图，比有向树状结构图更加简洁明了，但是同时网络图的形式可能会导致冗余信息的产生。

b）FP-network 算法与 Apriori 算法、FP-growth 算法类似，不能含有处理连续变量的数据对象。

c）FP-network 算法在关联分析过程中仅对数据库进行一次遍历，且无需存储候选集或者频繁模式树，提高了算法的运行速率，降低了内存占用，从而可以更快更好地处理更大规模的数据量。

d）FP-network 算法在处理数据的更新和维护时更加简便，算法具有较好的扩展性，可以满足电力大数据不断更新的处理要求。

（6）本文围绕如何提升电力大数据的价值密度，提出了改进的 K-means 算法和 FP-network 算法，其本质都是大数据的处理方法，除可应用于本课题的研究方向外，也可以应用于解决其他电力大数据的相关问题。

7.2 展望

本文围绕电力大数据的信息价值密度评价与提升方法课题展开了相关研究，做了大量的研究工作，得到了一些比较有价值的结论。但是受限于客观条件的制约和自身能力学识有限，一些研究工作还存在着不足，电力大数据的价值密度相关课题仍然有很多问题亟待深入研究：

（1）由于现有研究领域的缺乏和不足，本文提出的价值密度定义和指标缺少可参照比对的对象，仍有待于电力系统普遍应用的验证。

（2）本文提出的“三层过滤机制”，在提升电力大数据价值密度的同时，不可避免的造成了部分信息的损失。通常情况下这部分损失较小，但是某些情况下可能个别罕见数据反而价值更大，这部分损失就显得比较重要。此外，本文用误差来衡量信息损失比较粗略，后续研究可以考虑如何评估这部分损失。

（3）限于电力公司数据保密等条件制约，本文算例采用的数据量未达到 TB 级，与海量的电力数据相比仍然较小，但足以验证相关规律。若后续实验条件允许，进一步的研究应当考虑使用更大规模的数据量进行测试分析。

中国知网 https://www.cnki.net

随着智能电网的不断发展和信息化时代的进一步建设，电力大数据技术的应用将会更加广泛。如何提升电力大数据的价值密度，将是一个重要的研究方向，仍然有着很大的研究价值。

中国知网 https://www.cnki.net

参 考 文 献

[1] 张东霞,苗新,刘丽平,张焰,刘科研.智能电网大数据技术发展研究[J].中国电机工程学报,2015,35(01):2-12.

[2] 张沛. 电力大数据应用现状及前景[J]. 电气时代, 2014(12):24-27.

[3] 栾文鹏, 余贻鑫, 王兵. AMI 数据分析方法[J]. 中国电机工程学报, 2015, 35(1):29-36.

[4] Wu X, Zhu X, Wu G Q, et al. Data Mining with Big Data[J]. IEEE Transactions on Knowledge & Data Engineering, 2013, 26(1):97-107.

[5] 赵腾,张焰,张东霞.智能配电网大数据应用技术与前景分析[J].电网技术,2014,38(12):3305-3312.

[6] Yang G F , Zheng H Y , Ouyang H , et al. A Data Integration Platform Research of Power Grid Whole Life Management Based on BIM[J]. Applied Mechanics and Materials, 2013, 347-350:1935-1939.

[7] Ortjohann E, Leksawat S, Schmelter A, et al. Integration of clustering power systems approach and data management infrastructure for smart grids[C]// International Symposium on Power Electronics. 2014.

[8] Corrigan D, Zikopoulos P, Parasuraman K, et al. Harness the Power of Big Data The IBM Big Data Platform[J]. Business, 2013:9-15.

[9] Electric Power Research Institute. Distribution Modernization Demonstration[R]. USA: 2013.

[10] Kezunovic M, Xie L, Grijalva S. The role of big data in improving power system operation and protection[C]// Bulk Power System Dynamics & Control-ix Optimization, Security & Control of the Emerging Power Grid, Irep Symposium. 2013.

[11] Tokoro N. Smart Cities and Competitive Advantage: A New Perspective on Competitive Edge[M]// The Smart City and the Co-creation of Value. 2016.

[12] Dewen W , Zhiwei S . Big Data Analysis and Parallel Load Forecasting of Electric Power User Side[J]. Proceedings of the Csee, 2015, 35(3):527-537.

[13] 张秀东. 电力调控大数据集成及管理技术研究与应用[D]. 2016.

[14] 李达富, 陈如杰. 浅析智能电网中的电力大数据应用[J]. 广西电力, 2018.

中国知网 https://www.cnki.net

[15] 王继业. 大数据在电网企业的应用探索[J]. 中国电力企业管理, 2015(9):18-21.

[16] Zhan J, Huang J, Niu L, et al. Study of the key technologies of electric power big data and its application prospects in smart grid[C]// Power & Energy Engineering Conference. 2015.

[17] 苗新，张东霞，孙德栋. 在配电网中应用大数据的机遇与挑战[J]. 电网技术，2015，39(11)：3122-3127.

[18] 王璟，杨德昌，李锰，等. 配电网大数据技术分析与典型应用案例[J]. 电网技术，2015，39(11)：3114-3121.

[19] 郑海雁,金农,季聪,等.电力用户用电数据分析技术及典型场景应用[J].电网技术，2015，39(11)：3147-3152.

[20] 王相伟，史玉良，张建林，等. 基于 Hadoop 的用电信息大数据计算服务及应用[J]. 电网技术，2015，39(11)：3128-3133.

[21] 朱承治，李题印，李先锋，等. 基于动态时间弯曲和云模型的电能计量动态误差估计[J]. 电网技术，2015，39(11)：3208-3215.

[22] 张秋雁，程含渺，李红斌，等. 数字电能计量系统误差多参量退化评估模型及方法[J]. 电网技术，2015，39(11)：3202-3207.

[23] 史玉良，王相伟，梁波，等. 基于 MongoDB 的前置通信平台大数据存储机制[J]. 电网技术，2015，39(11)：3176-3181.

[24] 麦鸿坤，肖坚红，吴熙辰，等. 基于 R 语言的负荷预测 ARIMA 模型并行化研究[J]. 电网技术，2015，39(11)：3216-3220.

[25] 杨勇,朱影.一种基于 MapReduce 的粗糙集并行属性约简算法[J].重庆邮电大学学报(自然科学版),2015,27(01):89-96.

[26] 徐菲菲,雷景生,毕忠勤,苗夺谦,杜海舟.大数据环境下多决策表的区间值全局近似约简[J].软件学报,2014,25(09):2119-2135.

[27] 李丹.多粒度粗糙集模型下的矩阵属性约简算法[J].计算机工程与应用,2017,53(19):168-172.

[28] 曲朝阳,陈帅,杨帆,朱莉.基于云计算技术的电力大数据预处理属性约简方法[J].电力系统自动化,2014,38(08):67-71.

[29] 李刚,焦谱,文福拴,宋雨,尚金成,何洋.基于偏序约简的智能电网大数据预处理方法[J].电力系统自动化,2016,40(07):98-106.

中国知网 https://www.cnki.net

[30] 毛冬，裴旭斌，沈志豪,等. 电力大数据属性约简方法的研究[C]// "电子技术应用"智能电网会议. 2017.

[31] 宗威，吴锋.大数据时代下数据质量的挑战[J].西安交通大学学报(社会科学版)，2013，33(05)：38-43.

[32] 李红,牛成英,孙秋碧,林嘉燕.大数据时代数据融合质量的评价模型[J].统计与决策,2018,34(21):10-14.

[33] 程永新.大数据时代的数据资产管理方法论与实践[J].计算机应用与软件,2018(11):326-329.

[34] 张驰. 数据资产价值分析模型与交易体系研究[D].北京交通大学,2018.

[35] Prasanna Tambe．Big Data Investment，Skills，and Firm Value[J]. Management Science，2014，60(6)：págs．1452-1469.

[36] 刘琦，童洋，魏永长，等. 市场法评估大数据资产的应用[J]. 中国资产评估，2016(11)：33-37.

[37] 毛典辉.基于 MapReduce 的 Canopy-Kmeans 改进算法[J].计算机工程与应用,2012,48(27):22-26+68.

[38] XU Yujie, QU Wenyu, et al. Efficient k-means++ Approximation with MapReduce[J]. IEEE Computer Society, 2014,25(12):3135-3144.

[39] 周华平，刘光宗，张贝贝. 基于索引偏移的 MapReduce 聚类负载均衡策略[J]. 计算机科学，2018，45(5):303-309.

[40] Alemi M, Haghighi H, Shahrivari S. CCFinder: using Spark to find clustering coefficient in big graphs[J]. Journal of Supercomputing, 2017:1-28.

[41] Baydoun M, Ghaziri H, Al-Husseini M. CPU and GPU parallelized kernel K-means[J]. Journal of Supercomputing, 2018(1):1-24.

[42] Xu T S, Chiang H D, Liu G Y, et al. Hierarchical K-means Method for Clustering Large-Scale Advanced Metering Infrastructure Data[J]. IEEE Transactions on Power Delivery, 2017, 32(2):609-616.

[43] Sinha A, Jana P K. A hybrid MapReduce-based k -means clustering using genetic algorithm for distributed datasets[J]. Journal of Supercomputing, 2017(8):1-18.

[44] Agrawal R, Imieliński T, Swami A. Mining association rules between sets of items in large databases[J]. Acm Sigmod Record, 1993, 22(2):207-216.

[45] HAN T, KAMBER M. Data Mining: Concepts and Techniques[M]. Beijing: Higher Education Press, 2001：143-177.

中国知网 https://www.cnki.net

[46] Savasere A, Omiecinski E, Navathe S B. An Efficient Algorithm for Mining Association Rules in Large Databases[C]. International Conference on Very Large Data Bases. Morgan Kaufmann Publishers Inc. 1995:432-444.

[47] Han J, Pei J, Yin Y. Mining frequent patterns without candidate generation[C].Acm Sigmod International Conference on Management of Data. ACM, 2000:1-12.

[48] 刘凤魁. 基于密度峰值聚类算法的电力大数据异常值检测及用电行为分析研究[D].中国电力科学研究院,2017.

[49] MapReduce 的大数据处理平台与算法研究进展[J]。软件学报，2017,28(3)：514-543.

[50] 王继业, 季知祥, 史梦洁,等. 智能配用电大数据需求分析与应用研究[J]. 中国电机工程学报, 2015, 35(8):1829-1836.

[51] 李荣胜, 赵文峰, 徐惠民. 基于价值密度和截止期的网格作业调度算法[J]. 计算机工程, 2011, 37(12):16-18.

[52] 周涛,陆惠玲.数据挖掘中聚类算法研究进展[J].计算机工程与应用,2012,48(12)：100-111.

[53] 韩俊,谈健,黄河,等.基于改进 K-means 聚类算法的供电块划分方法[J].电力自动化设备，2015，35(6)：123-129.

[54] 曾志雄. 基于划分和层次的混合聚类算法研究[D]. 云南大学, 2007.

[55] 马金徽. 高维混合类型数据聚类算法研究[D]. 内蒙古科技大学, 2011.

[56] 高悦, 王文贤, 杨淑贤. 一种基于狄利克雷过程混合模型的文本聚类算法[J]. 信息网络安全, 2015(11):60-65.

[57] Zhang G, Zhang C, Zhang H. Improved K-means Algorithm Based on Density Canopy[J]. Knowledge-Based Systems, 2018:S0950705118300479.

[58] 周爱武, 于亚飞. K-Means 聚类算法的研究[J]. 计算机技术与发展, 2011, 21(2):62-65.

[59] 张斌，庄池杰，胡军. 结合降维技术的电力负荷曲线集成聚类算法[J]. 中国电机工程学报，2015，35(15):3741-3749.

[60] 张丽. 关联规则挖掘研究[J]. 赤峰学院学报（自然版）, 2009, 25(5):17-18.

[61] 曾志勇, 闫亚丽. 面向 XBRL 的 DC-Apriori 挖掘算法研究[J]. 现代计算机：普及版, 2015(9):27-30.

中国知网 https://www.cnki.net

[62] 赵宪中，刘涌，侯梓浪,等. 基于事务—项目关联矩阵的频繁模式网络(FP-network)挖掘算法研究[J]. 现代制造，2017(33):135-137.

[63] 牛东晓，王建军. 基于粗糙集和决策树的自适应神经网络短期负荷预测方法[J]. 电力自动化设备，2009，29(10)：30-34.

[64] 凌武能，杭乃善，李如琦. 基于云支持向量机模型的短期风电功率预测[J]. 电力自动化设备，2013，33(7)：34-38.

中国知网 https://www.cnki.net

致　谢

时光飞逝，转眼间紧张而又充实的硕士生活即将画上句号。在上海交通大学的学习生活期间，我得到了很多老师、同学和朋友的关怀和帮忙。在学位论文即将完成之际，我要向所有期间给予我支持、帮忙和鼓励的人表示我最诚挚的谢意。

首先要感谢我的导师、上海交通大学电子信息与电气工程学院的王承民老师以及谢宁老师。两位老师在我的研究生期间给予了我很大的帮助和关怀，对我论文的研究方向做出了指导性的意见和推荐，在论文撰写过程中及时对我遇到的困难和疑惑给予悉心指点，提出了许多有益的改善性意见，投入了很多的心血和精力。并且在生活上和就业上也给予了很大的关心和支持。特别是在科研的初始阶段，王承民老师十分耐心地按部就班地引领我入门，并提供了许多锻炼的机会和平台，良好的环境使我可以快速学习成长。还要感谢姚维燕老师，将实验室的日常行政管理和财务管理打理得井井有条，为大家的科研学习保障了良好的后勤条件和硬件支持。

同时也要感谢实验室的师兄师姐、师弟师妹们，大家在实验室一起科研，一起参与项目，互相学习，互相帮助，共同成长进步。无论是科研学习，或者是业余生活，良好的实验室氛围，温馨的师兄弟情谊，让我们共同度过了一段美好难忘的时光。

此外，还要感谢我的朋友以及同学们在论文编写中带给的大力支持和帮忙，给我带来极大的启发。也要感谢参考文献中的作者们，透过他们的研究文章，使我对研究课题有了很好的出发点。

最后，谢谢论文评阅老师们的辛苦工作。

毕业在即，在今后的工作和生活中，我会铭记师长们的教诲，继续不懈努力和追求，来报答所有支持和帮忙过我的人!

中国知网　https://www.cnki.net

攻读硕士学位期间已发表或录用的论文

[1]孙丰杰,王承民,谢宁. 面向智能电力大数据关联规则挖掘的频繁模式网络模型[J]. 电力自动化设备,2018,38(05):110-116.

[2]孙丰杰,谢宁,王承民,范明天,张祖平. 2017 年国际供电会议配电系统规划研究成果综述[J]. 电网技术,2018,42(09):2733-2741.

[3]孙丰杰,马静,徐加银,叶斌. 不同投资主体电池储能系统的经济性[J]. 电池,2018,48(02):117-121.

[4] SUN Fengjie , WANG Chengmin , ZHENG Weimin , et al. Application of a new FP-network mining algorithm based on association matrix in power system[C]// IEEE Conference on Energy Internet & Energy System Integration. IEEE, 2017.

[5]马静,徐加银,孙丰杰等. 电网侧和新能源侧的蓄电池储能系统经济性模型:中国，CN108199399A[P]. 2018.06.22.（已公开）

[6]陈飞,郑伟民,王蕾,孙丰杰等. 基于事务-项目关联矩阵的频繁模式网络挖掘算法及系统:中国, CN107908776A[P]. 2018.04.13.（已公开）

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文《电力大数据的信息价值密度评价与提升方法研究》，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

孙丰杰

日期：2019 年 1 月 18 日

中国知网 https://www.cnki.net